

# Data Science

Rafael Roberto Dias

1ª Turma 2020



# O que veremos hoje pela manhã?



## Horário Assunto

09:30	Qualidade dos Dados
10:30	Variáveis Relevantes
11:30	Introdução Machine Learning

# E hoje à tarde?



## Horário Assunto

13:30	Modelo de Associação
14:30	ML Workflow
15:30	Modelos Preditivos
16:30	Resolução AgroXP
17:30	Modelos Classificadores



# Welcome to R

1 – Softwares Estatísticos

2 – Detalhes Linguagem R

3 – Aprendendo R & RStudio

4 – Analisando Qualidade dos Dados

5 – Variáveis Relevantes



# Analisando Qualidade dos Dados

- Objetivo nesta etapa do estudo é verificar a qualidade dos dados para entender quais têm potencial de fazer parte do estudo
- Foco maior em verificar se existem dados faltantes ou nulos que podem interferir no estudo
- Também aqui começa o entendimento de como cada variável ajuda a explicar o evento em estudo
- Aqui começam as descobertas do Cientista de Dados

# Analisando Qualidade dos Dados

- Objetivo nesta etapa do estudo é verificar a qualidade dos dados para entender quais têm potencial de fazer parte do estudo
- Foco maior em verificar se existem dados faltantes ou nulos que podem interferir no estudo
- Também aqui começa o entendimento de como cada variável ajuda a explicar o evento em estudo
- Aqui começam as descobertas do Cientista de Dados

# Analisando Qualidade dos Dados

- Objetivo nesta etapa do estudo é verificar a qualidade dos dados para entender quais têm potencial de fazer parte do estudo
- Foco maior em verificar se existem dados faltantes ou nulos que podem interferir no estudo
- Também aqui começa o entendimento de como cada variável ajuda a explicar o evento em estudo
- Aqui começam as descobertas do Cientista de Dados

# Analisando Qualidade dos Dados

- Objetivo nesta etapa do estudo é verificar a qualidade dos dados para entender quais têm potencial de fazer parte do estudo
- Foco maior em verificar se existem dados faltantes ou nulos que podem interferir no estudo
- Também aqui começa o entendimento de como cada variável ajuda a explicar o evento em estudo
- **Aqui começam as descobertas do Cientista de Dados**

# Welcome to R

1 – Softwares Estatísticos

2 – Detalhes Linguagem R

3 – Aprendendo R & RStudio

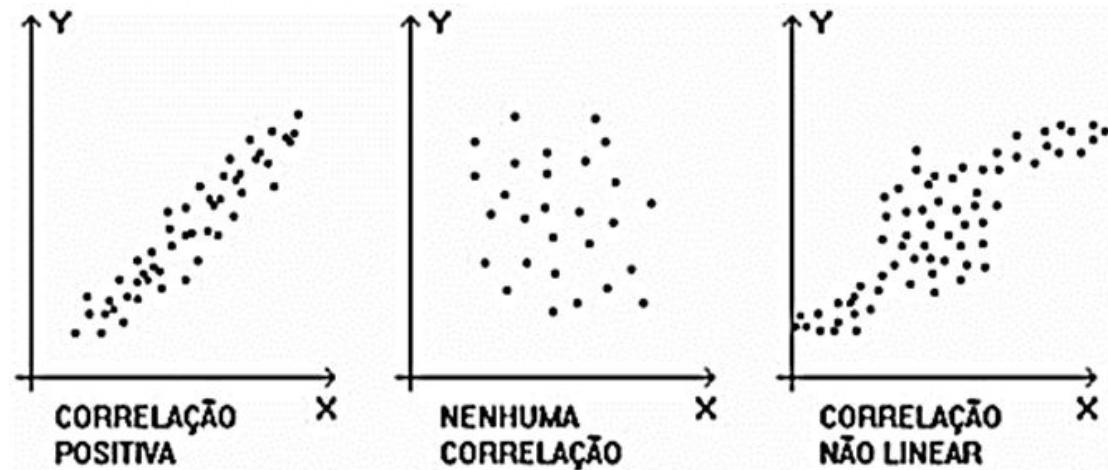
4 – Analisando Qualidade dos Dados

5 – Variáveis Relevantes



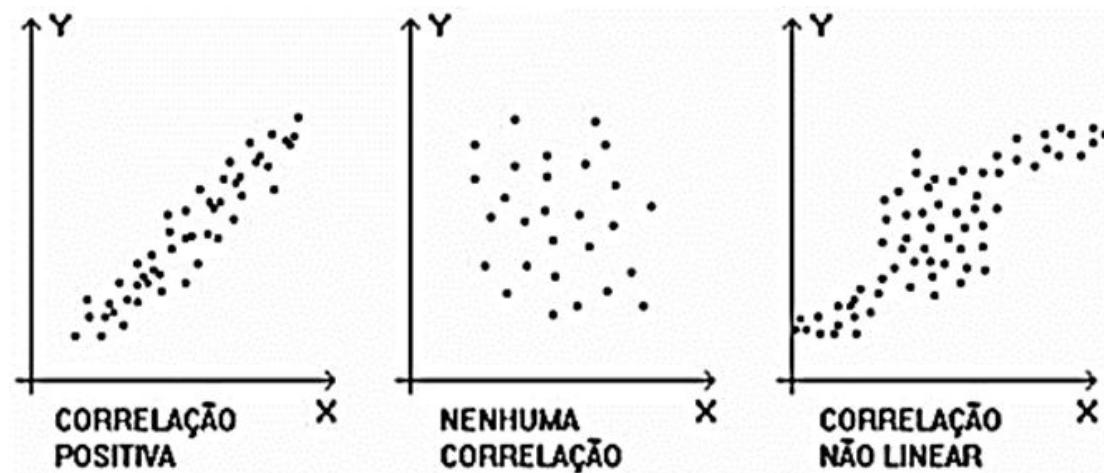
# Variáveis Relevantes

- Objetivo nesta etapa do estudo é verificar a como as variáveis se relacionam entre si
  - Foco maior aqui é entender a correlação entre as variáveis



# Variáveis Relevantes

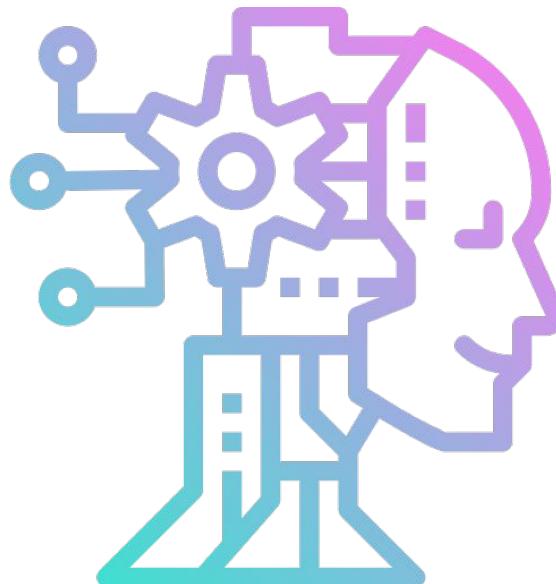
- O modelo ou a metodologia que será utilizada para responder às perguntas do estudo dependem dos achados desta etapa



# Artificial Intelligence & Machine Learning

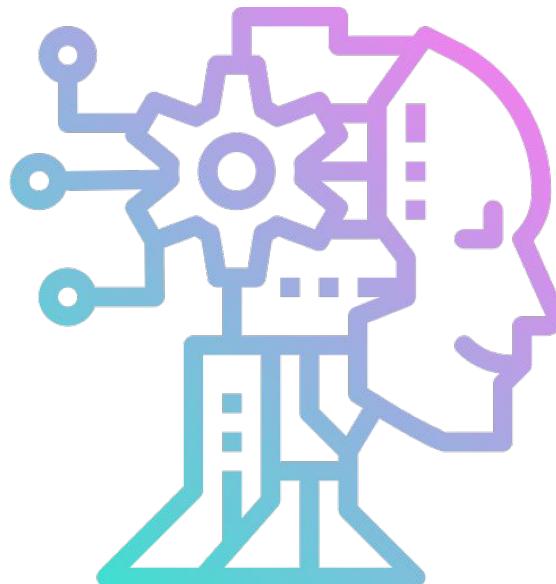
# Artificial Intelligence & Machine Learning

**Na atualidade são inúmeras as possibilidades de utilização  
de métodos de Inteligência Artificial e Aprendizado de  
Máquina**



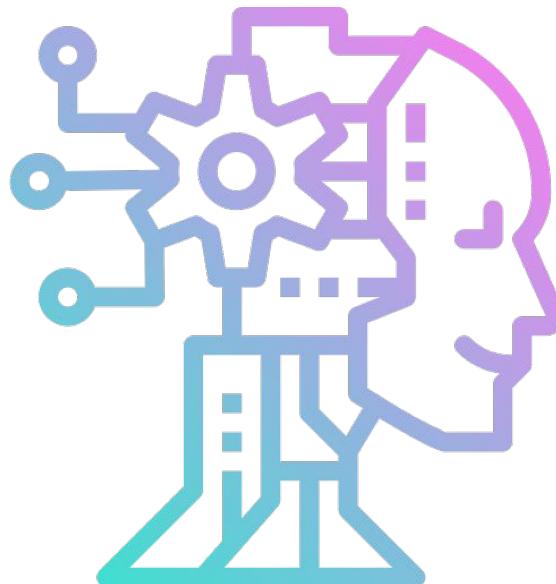
# Artificial Intelligence & Machine Learning

**À vocês, guerreiros e guerreiras que chegaram até aqui,  
vou mostrar-lhes quais são as principais tecnologias deste  
ramo da ciência e como utilizá-las**



# Artificial Intelligence & Machine Learning

**Temos mais umas teorias à desbravar até colocarmos a mão na massa! Vamos Nessa!**



# Machine Learning

**1 – Machine Learning**

**2 – Associação**

**3 – Case MM**

# Machine Learning

1 – Machine Learning

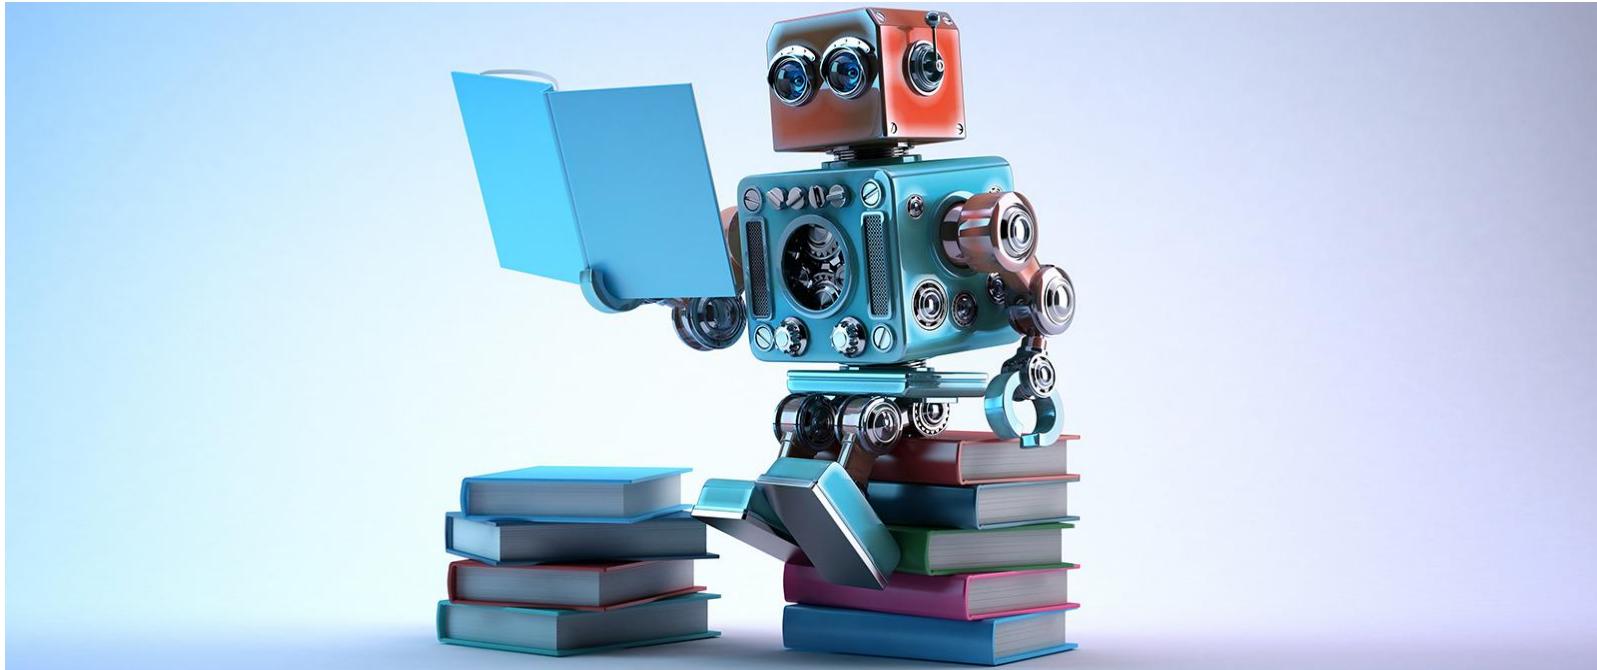
2 – Associação

3 – Case MM

# Machine Learning

## O que é Machine Learning?

---



## O que é Machine Learning?

**1959 - ML: "Field of study that gives computers the ability to learn without being explicitly programmed" - Arthur Samuel**

Ou seja, aprender com a experiência que existe intrínseca aos dados.

Como: Algoritmos de aprendizado de máquina analisam as correlações entre os atributos (variáveis) de um sistema (base de dados) a partir de dados amostrais (base de treinamento)



# Machine Learning

## O que é Machine Learning?

1959 - ML: "Field of study that gives computers the ability to learn without being explicitly programmed" - Arthur Samuel

**Ou seja, aprender com a experiência que existe intrínseca aos dados.**

**Como:** Algoritmos de aprendizado de máquina analisam as correlações entre os atributos (variáveis) de um sistema (base de dados) a partir de dados amostrais (base de treinamento)



# Machine Learning

## O que é Machine Learning?

1959 - ML: "Field of study that gives computers the ability to learn without being explicitly programmed" - Arthur Samuel

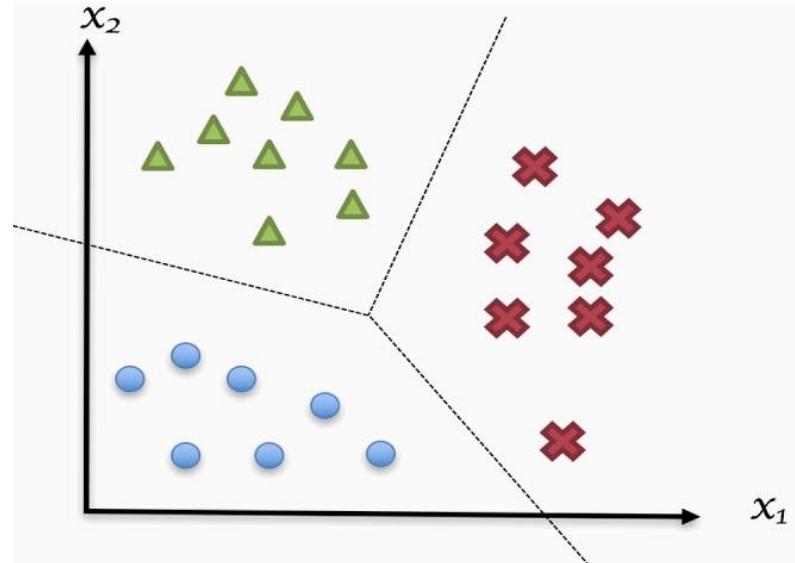
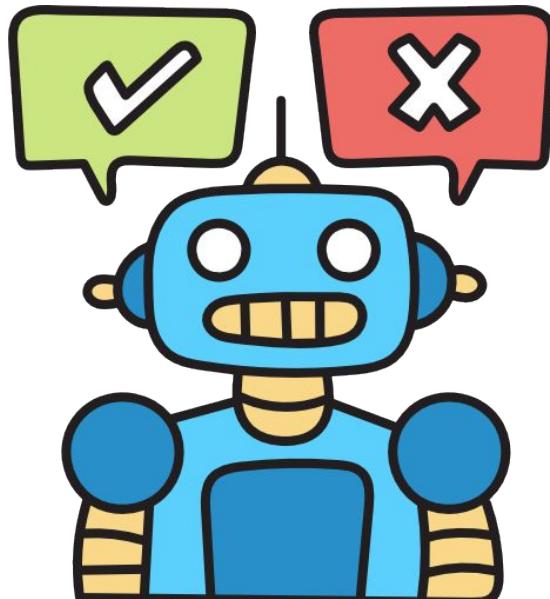
Ou seja, aprender com a experiência que existe intrínseca aos dados.

**Como:** Algoritmos de aprendizado de máquina analisam as correlações entre os atributos (variáveis) de um sistema (base de dados) a partir de dados amostrais (base de treinamento)



# Machine Learning

Ocorre quando um algoritmo ou um programa de computador é utilizado para melhorar as tarefas desempenhadas por humanos com base na experiência



# Machine Learning

## Tipos de Machine Learning

### Supervisionado

**Rotulado com saídas esperadas. Modelo gera ao entrar com conjunto de características uma saída rotulada (Classificação) ou um valor futuro (Predição)**

### Não Supervisionado

**Não existe rótulo prévio. Analisa a rede de relacionamento entre os dados para agrupá-los por características similares**

### Reforço

**Maximizar o resultado. Baseado em recompensa e/ou punição. Com isso algoritmo encontra a “política” que mapeia os dados**



# Machine Learning

## Tipos de Machine Learning

### Supervisionado

**Rotulado com saídas esperadas. Modelo gera ao entrar com conjunto de características uma saída rotulada (Classificação) ou um valor futuro (Predição)**

### Não Supervisionado

**Não existe rótulo prévio. Analisa a rede de relacionamento entre os dados para agrupá-los por características similares**

### Reforço

**Maximizar o resultado. Baseado em recompensa e/ou punição. Com isso algoritmo encontra a “política” que mapeia os dados**



# Machine Learning

## Tipos de Machine Learning

### Supervisionado

**Rotulado com saídas esperadas.** Modelo gera ao entrar com conjunto de características uma saída rotulada (Classificação) ou um valor futuro (Predição)

### Não Supervisionado

**Não existe rótulo prévio.** Analisa a rede de relacionamento entre os dados para agrupá-los por características similares

### Reforço

**Maximizar o resultado.** Baseado em recompensa e/ou punição. Com isso algoritmo encontra a “política” que mapeia os dados



# Machine Learning

## Tipos de Machine Learning

### Supervisionado

**Rotulado com saídas esperadas.** Modelo gera ao entrar com conjunto de características uma saída rotulada (Classificação) ou um valor futuro (Predição)

### Não Supervisionado

**Não existe rótulo prévio.** Analisa a rede de relacionamento entre os dados para agrupá-los por características similares

### Reforço

**Maximizar o resultado.** Baseado em recompensa e/ou punição. Com isso algoritmo encontra a “política” que mapeia os dados



# Machine Learning

## Aplicações

# Machine Learning

## Aplicações

Predição de  
Eventos

# Machine Learning

## Aplicações

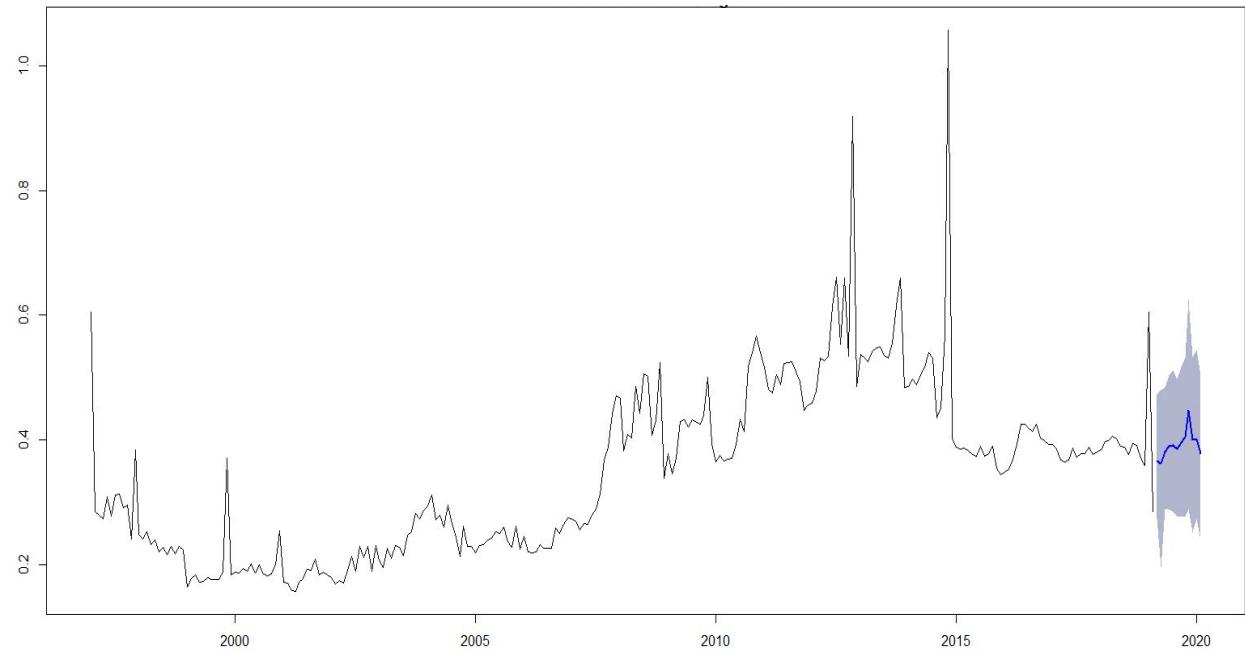
Predição de  
Eventos



# Machine Learning

## Aplicações

Predição de  
Eventos



# Machine Learning

## Aplicações

Predição de  
Eventos

Eventos

Temporais:

Vendas, Estoque,  
Visitas, Safras de  
Grãos, Clima,  
Ações Financeiras



# Machine Learning

## Aplicações

Predição de  
Eventos

Anomalias:  
Detecção de  
Falhas, Fraudes,  
Oportunidades,  
Invasões (Hackers)



# Machine Learning

## Aplicações

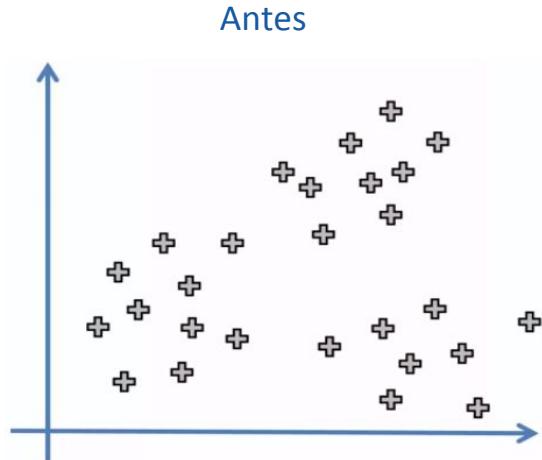
Predição de  
Eventos

Sobrevivência:  
**Duração de  
Equipamentos,  
Mortalidade,  
Reincidência, Cura**

# Machine Learning

## Aplicações

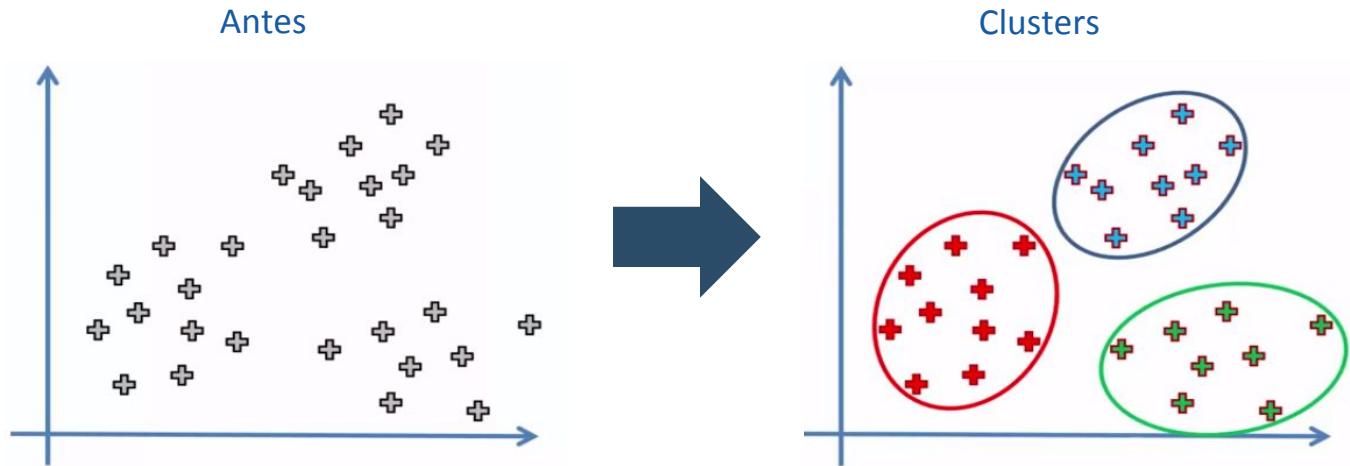
Classificação



# Machine Learning

## Aplicações

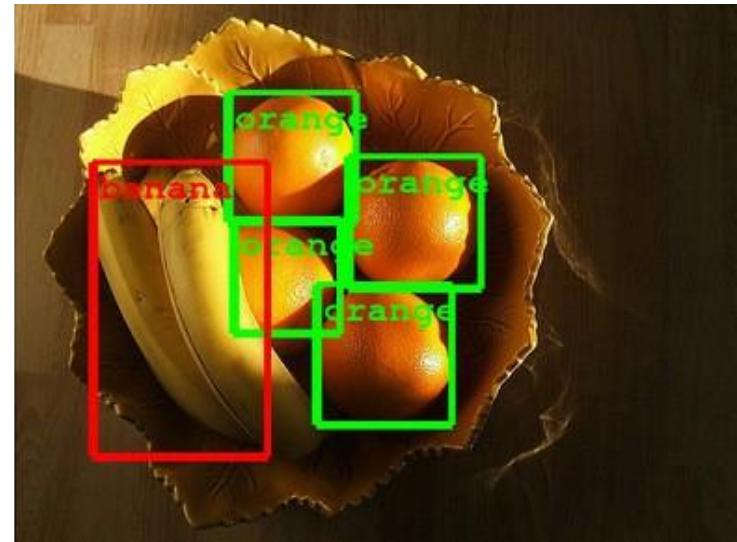
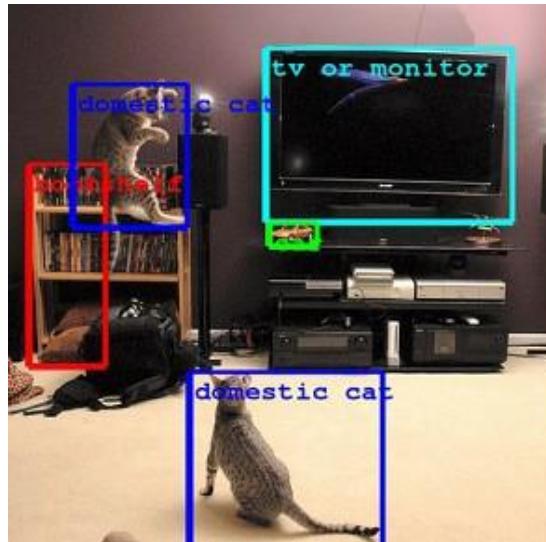
Classificação



# Machine Learning

## Aplicações

Classificação



# Machine Learning

## Aplicações

Associação



# Machine Learning

## Aplicações

Associação

Científica:

Bioinformática,  
Diagnóstico,  
Mineração de  
Dados, Dados  
Científicos

# Machine Learning

## Aplicações

Associação

Entidades:

Cartéis,

Concorrência,

Oportunidades,

Fornecedores,

Quadrilhas



# Machine Learning

## Aplicações

Associação

E-Commerce:  
Transações,  
Navegação, Wish  
List, Pesquisas,  
Clientes



# Associação

1 – Machine Learning

2 – Associação

3 – Case MM

# Associação

**Utilizado para descobrir relacionamentos interessantes em grandes conjuntos de dados**

- A metodologia Apriori é a utilizada pela MM  
- Motivo: simplicidade e resultados comprovados

Comumente implementado para análise de transações de compras (market basket analysis)

Os resultados são regras com:

- Suporte
- Confiança
- Lift

# Associação

**Utilizado para descobrir relacionamentos interessantes em grandes conjuntos de dados**

- A metodologia Apriori é a utilizada pela MM  
- Motivo: simplicidade e resultados comprovados

Comumente implementado para análise de transações de compras (market basket analysis)

Os resultados são regras com:

- Suporte
- Confiança
- Lift

# Associação

**Utilizado para descobrir relacionamentos interessantes em grandes conjuntos de dados**

- A metodologia Apriori é a utilizada pela MM
- Motivo: simplicidade e resultados comprovados

Comumente implementado para análise de transações de compras (market basket analysis)

Os resultados são regras com:

- Suporte
- Confiança
- Lift

# Associação

**Utilizado para descobrir relacionamentos interessantes em grandes conjuntos de dados**

- A metodologia Apriori é a utilizada pela MM  
- Motivo: simplicidade e resultados comprovados

Comumente implementado para análise de transações de compras (market basket analysis)

Os resultados são regras com:

- Suporte
- Confiança
- Lift

# Associação

## Análise de Transações de Compras => Apriori

ID_Transação	Itens_Comprados
1	biscoito, cerveja, chá, salaminho
2	cerveja, couve, lingüiça, pão, queijo
3	café, brócolis, couve , pão
4	brócolis, café, cerveja, couve, pão, salaminho
5	brócolis, café, couve, pão, refrigerante
6	couve, lingüiça

# Associação

## Funcionamento Apriori

ID_Transação	Itens_Comprados
1	biscoito, <u>cerveja</u> , chá, salaminho
2	<u>cerveja</u> , couve, lingüiça, pão, queijo
3	café, brócolis, couve , pão
4	brócolis, café, <u>cerveja</u> , couve, pão, <u>salaminho</u>
5	brócolis, café, couve, pão, refrigerante
6	couve, lingüiça



{ cerveja => salaminho }

### Suporte ou Frequência

$$Suporte = \frac{Freq\{Cerveja \Rightarrow Salaminho\}}{Quantidade\ Transacoes}$$

$$Suporte = \frac{2}{6}$$

$$Suporte = 0,334 \text{ ou } 33,4\%$$

# Associação

## Funcionamento Apriori

ID_Transação	Itens_Comprados
1	biscoito, <u>cerveja</u> , chá, salaminho
2	<u>cerveja</u> , couve, lingüiça, pão, queijo
3	café, brócolis, couve , pão
4	brócolis, café, <u>cerveja</u> , couve, pão, <u>salaminho</u>
5	brócolis, café, couve, pão, refrigerante
6	couve, lingüiça



{ cerveja => salaminho }

### Confiança ou Probabilidade

$$\text{Confiança} = \frac{\text{Freq } \{Cerveja \Rightarrow Salaminho\}}{\text{Qt Tr Cerveja ou Salaminho}}$$

$$\text{Confiança} = \frac{2}{3}$$

$$\text{Confiança} = 0,667 \text{ ou } 66,7\%$$

# Associação

## Funcionamento Apriori

ID_Transação	Itens_Comprados
1	biscoito, <u>cerveja</u> , chá, salaminho
2	<u>cerveja</u> , couve, lingüiça, pão, queijo
3	café, brócolis, couve , pão
4	brócolis, café, <u>cerveja</u> , couve, pão, <u>salaminho</u>
5	brócolis, café, couve, pão, refrigerante
6	couve, lingüiça



{ cerveja => salaminho }

### Lift ou Chances de Ocorrer

$$Lift = \frac{\text{Confiança}}{\text{Suporte}}$$

$$Lift = \frac{0,667}{0,334}$$

$$Lift = 2$$

# Associação

1 – Machine Learning

2 – Associação

3 – Case MM

# Case MadeiraMadeira

A compra de Painel de TV é precedida pela de Guarda Roupas, com:

- 6% de Suporte
- 45% de Confiança
- 7,5 de Lift



# Case MadeiraMadeira

A compra de Painel de TV é precedida pela de Guarda Roupa, com:

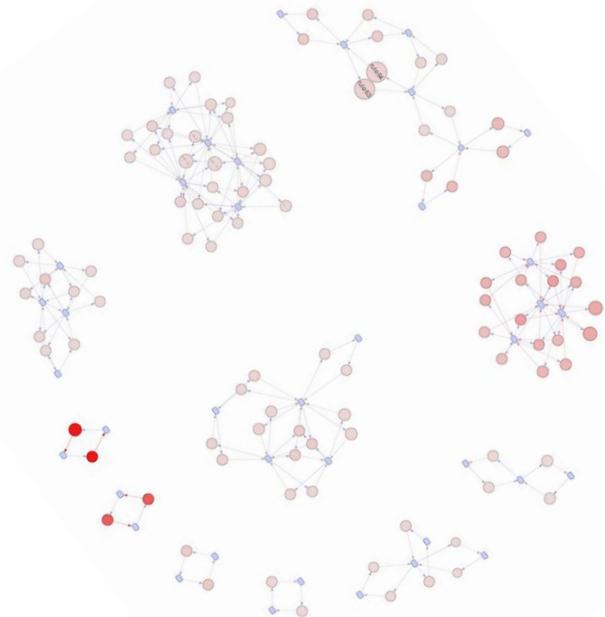
- 6% de Suporte
- 45% de Confiança
- 7,5 de Lift



- Os itens acima aparecem na compra de 6% dos clientes
- Destes, 45% das vezes estes são vendidos juntos
- Tem-se 7,5 vezes mais chances de vender Painel de TV para quem comprou Guarda Roupa

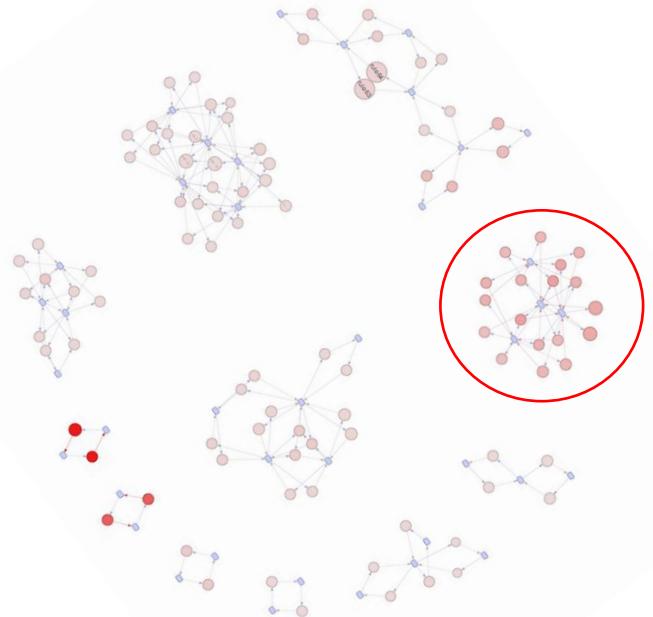
# Case MadeiraMadeira

Visualização de regras utilizando o pacote 'arulesViz' do software R



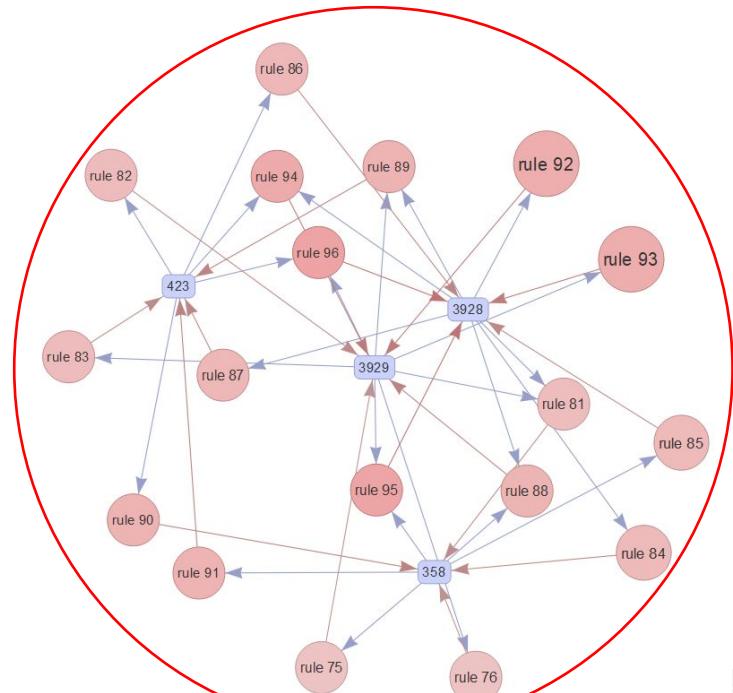
# Case MadeiraMadeira

Visualização de regras utilizando o pacote 'arulesViz' do software R



# Case MadeiraMadeira

Visualização de regras utilizando o pacote 'arulesViz' do software R



# Case MadeiraMadeira

## Utilização Prática

Prever a  
próxima melhor  
oferta (NBO)  
dado o último  
item que o  
cliente comprou

Olá, Rafael

Um produto que pode ser do seu interesse baixou de preço.  
Não perca esta chance!



Produto com desconto

Painel para TV até 47 Polegadas com Nicho Flash Artely

Os momentos de maior descontração em frente a tv ou em confraternizações com amigos em casa ocorrem na sala. O painel Flash surgiu para...

Comprar

Recomendamos para você



Painel para TV até 42 Polegadas com Nicho Flash Artely

Comprar



Painel para TV até 42 Polegadas 2 Nichos Navi Móveis...

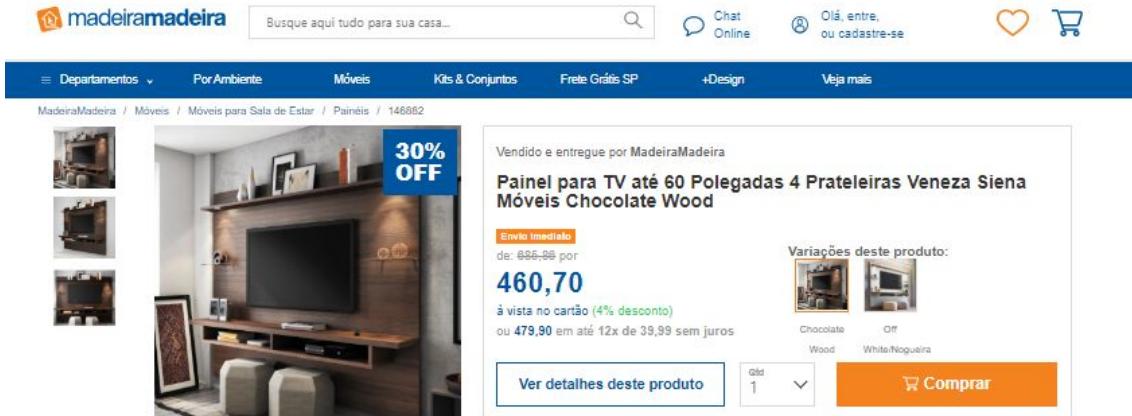
Comprar



# Case MadeiraMadeira

## Utilização Prática

Prever a  
próxima melhor  
oferta (NBO)  
dado o último  
item que o  
cliente comprou

madeiramadeira Busque aqui tudo para sua casa... Chat Online Olá, entre, ou cadastre-se

Departamentos Por Ambiente Móveis Kits & Conjuntos Frete Grátis SP +Design Veja mais

MadeiraMadeira / Móveis / Móveis para Sala de Estar / Painéis / 146882

Vendido e entregue por MadeiraMadeira

**Painel para TV até 60 Polegadas 4 Prateleiras Veneza Siena Móveis Chocolate Wood**

Envio imediato de: 086,98 por **460,70** à vista no cartão (4% desconto) ou 479,90 em até 12x de 39,99 sem juros

Variações deste produto: Chocolate Wood Off White/Nogueira

Ver detalhes deste produto Qtd 1 Comprar

Produtos visitados por quem procura este item

< >

Item	Preço	Detalhes
Painel para TV até 42 Polegadas Capri Siena Móveis	261,86	172,70 à vista 12x de 14,99 sem juros
Rack com Painel para TV até 55 Polegadas 1 Porta Miami Siena Móveis	545,86	316,70 à vista 12x de 27,49 sem juros
Painel para TV até 65 Polegadas Itaparica Siena Móveis	558,92	335,90 à vista 12x de 29,15 sem juros
Painel para TV até 80 Polegadas com LED 3 Gavetas 182cm Decore I...	1.007,86	691,10 à vista 12x de 58,99 sem juros
Sala de Estar com Painel, Rack e Mesa de Centro Requisite Siena M...	430,42	301,35 à vista 12x de 26,15 sem juros

MACHINE LEARNING PARA RECOMENDAÇÕES DE PRODUTOS Data Sciences



# Case MadeiraMadeira

## Utilização Prática

Juntar as categorias com regras com maiores lifts de vendas conjuntas



Busque aqui tudo para sua casa...



Quer ajuda?



Olá, entre ou cadastre-se



Item	Preço	Pagamento	Vencimento
Estante Home para TV	604,70	à vista no cartão	até 12x de 50,48 sem juros
Guarda Roupa Casal com Espelho	489,50	à vista no cartão	até 12x de 40,88 sem juros
Guarda Roupa Casal com Espelhos	777,50	à vista no cartão	até 12x de 67,48 sem juros
Painel para TV	691,10	à vista no cartão	até 12x de 58,98 sem juros
Armário Multiuso	364,70	à vista no cartão	até 12x de 31,86 sem juros

Produtos que baixaram de preço

Item	Preço	Pagamento	Vencimento
Guarda Roupa Casal	739,10	à vista no cartão	até 12x de 61,66 sem juros
Painel para TV	412,70	à vista no cartão	até 12x de 34,38 sem juros
Sala de Estar	301,35	à vista no cartão	até 12x de 25,16 sem juros
Painel para TV	259,10	à vista no cartão	até 12x de 22,48 sem juros
Painel para TV	326,30	à vista no cartão	até 12x de 27,22 sem juros



# Case MadeiraMadeira

## Utilização Prática

**Utilizar as  
regras com  
maiores lifts  
para montar  
conjuntos**



# Agenda

1 – ML Workflow

2 – Framework H2O.ai

3 – Framework TensorFlow

4 – Framework Scikit-Learn



# Artificial Intelligence & Machine Learning

1 – ML Workflow

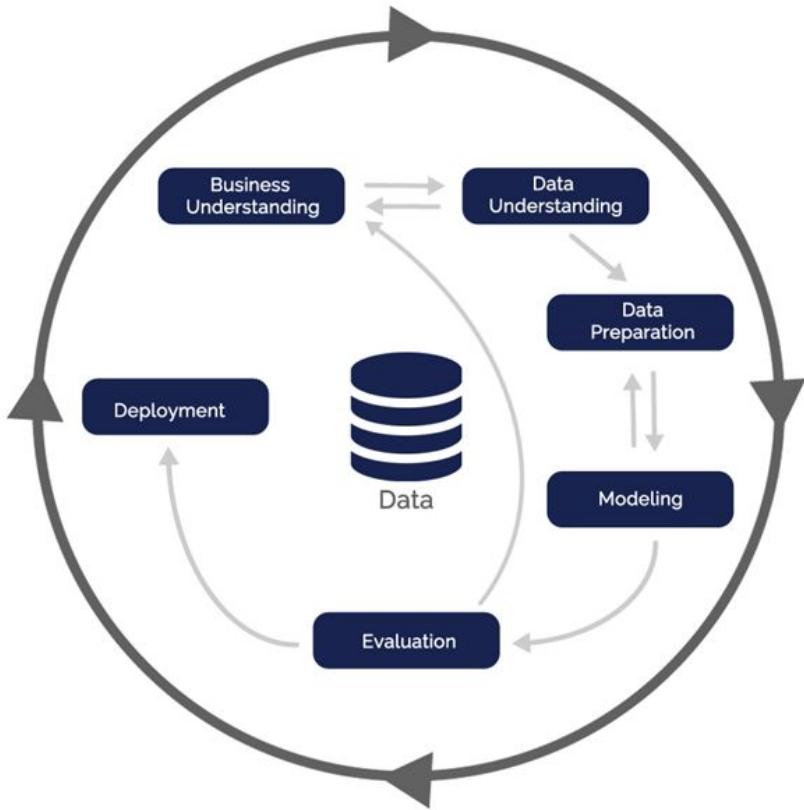
2 – Framework H2O.ai

3 – Framework TensorFlow

4 – Framework Scikit-Learn



# Machine Learning Workflow

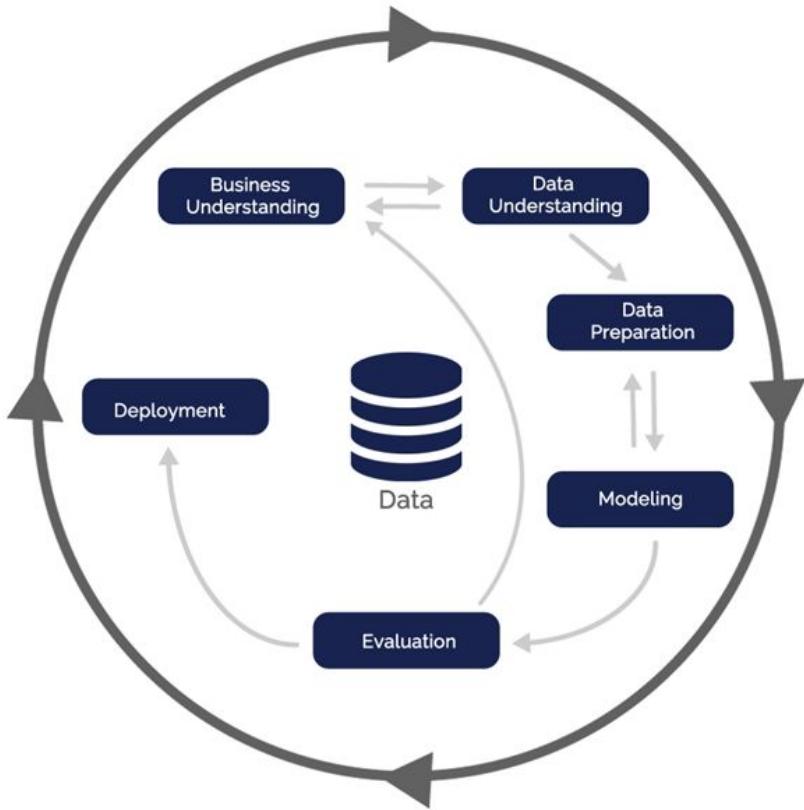


## CRISP-DM: Cross Industry Standard Process for Data Mining

É uma das técnicas mais utilizada em Mineração de Dados

Principal vantagem é que pode ser aplicada a qualquer tipo de negócio

# Machine Learning Workflow

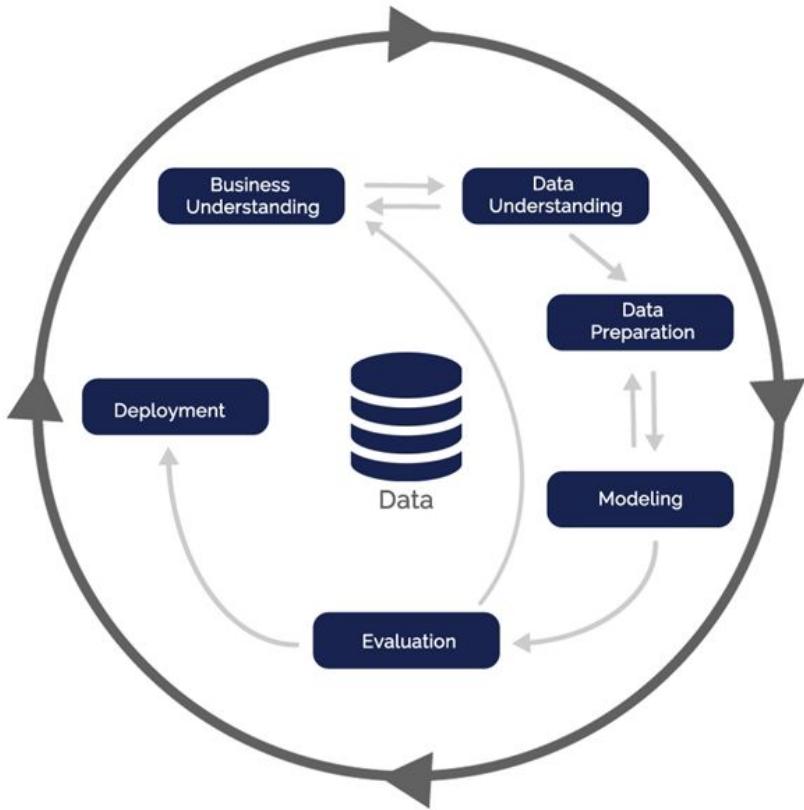


## CRISP-DM: Cross Industry Standard Process for Data Mining

É uma das técnicas mais utilizada em Mineração de Dados

Principal vantagem é que pode ser  
aplicada a qualquer tipo de  
negócio

# Machine Learning Workflow

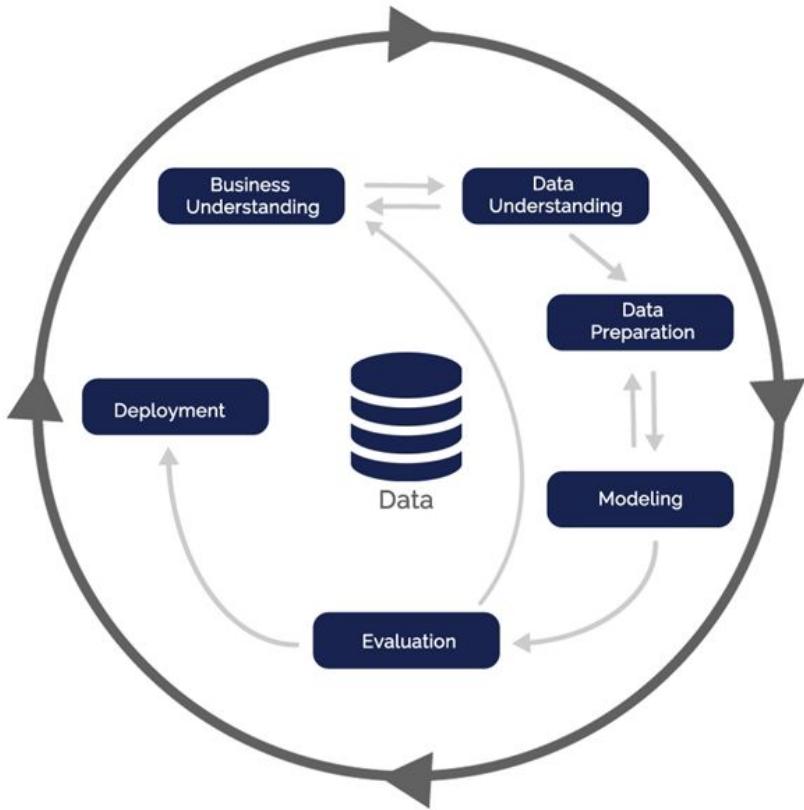


## CRISP-DM: Cross Industry Standard Process for Data Mining

É uma das técnicas mais utilizada em Mineração de Dados

Principal vantagem é que pode ser aplicada a qualquer tipo de negócio

# Machine Learning Workflow

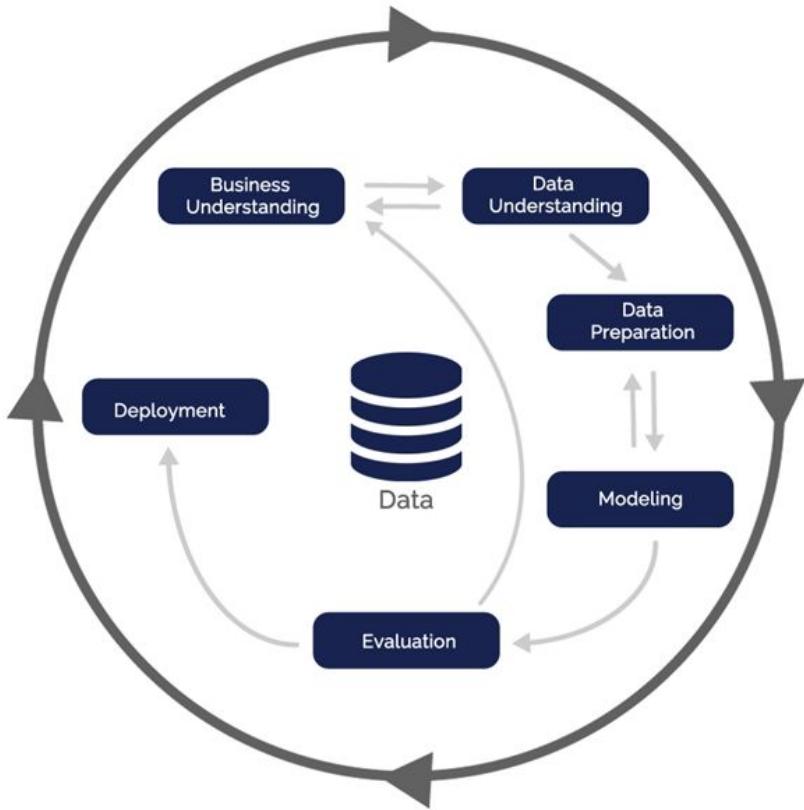


## CRISP-DM: Cross Industry Standard Process for Data Mining

Pode ser utilizada para Data Science pela sua simplicidade

Consegue-se utilizar esta técnica juntamente com Scrum: Método Ágil

# Machine Learning Workflow

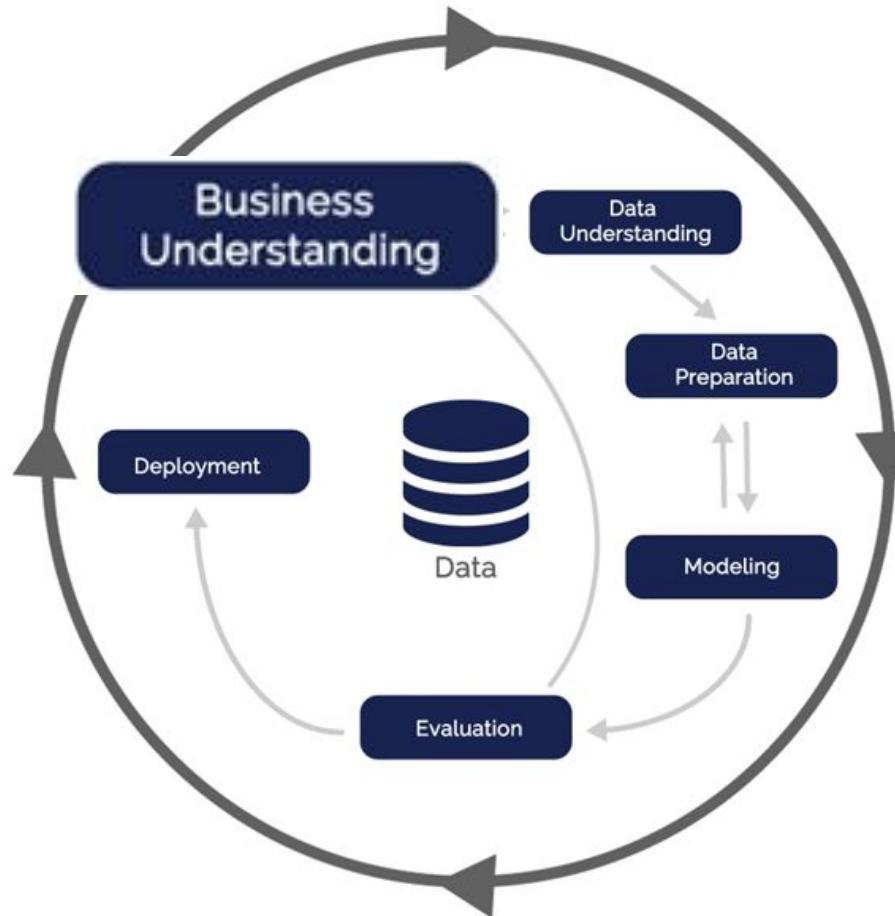


## CRISP-DM: Cross Industry Standard Process for Data Mining

Pode ser utilizada para Data Science pela sua simplicidade

Consegue-se utilizar esta técnica juntamente com Scrum: Método Ágil

# Machine Learning Workflow



# Machine Learning Workflow

## Business Understanding

Nesta fase será necessário identificar a questão a ser resolvida e/ou modelada, sendo necessário formalizar:

**Background:** Explicar a situação da empresa/entidade e como os produtos serão direcionados para entrega da modelagem

**Objetivo Modelagem:** Descrever com clareza quais serão as entregas

**Critério de sucesso:** Definir os KPIs que serão avaliados para comprovar eficácia do modelo, assim como acompanhamento da sua acurácia



# Machine Learning Workflow

## Business Understanding

Nesta fase será necessário identificar a questão a ser resolvida e/ou modelada, sendo necessário formalizar:

**Background:** Explicar a situação da empresa/entidade e como os produtos serão direcionados para entrega da modelagem

**Objetivo Modelagem:** Descrever com clareza quais serão as entregas

**Critério de sucesso:** Definir os KPIs que serão avaliados para comprovar eficácia do modelo, assim como acompanhamento da sua acurácia



# Machine Learning Workflow

## Business Understanding

Nesta fase será necessário identificar a questão a ser resolvida e/ou modelada, sendo necessário formalizar:

**Background:** Explicar a situação da empresa/entidade e como os produtos serão direcionados para entrega da modelagem

**Objetivo Modelagem:** Descrever com clareza quais serão as entregas

**Critério de sucesso:** Definir os KPIs que serão avaliados para comprovar eficácia do modelo, assim como acompanhamento da sua acurácia



# Machine Learning Workflow

## Business Understanding

Nesta fase será necessário identificar a questão a ser resolvida e/ou modelada, sendo necessário formalizar:

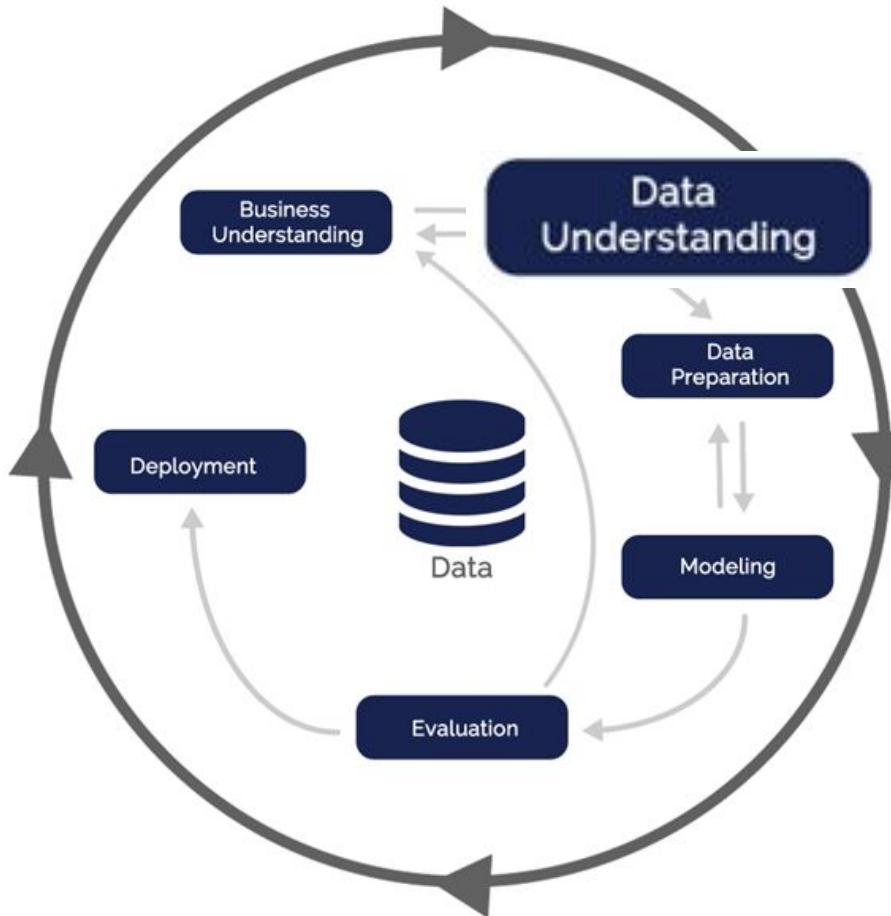
**Background:** Explicar a situação da empresa/entidade e como os produtos serão direcionados para entrega da modelagem

**Objetivo Modelagem:** Descrever com clareza quais serão as entregas

**Critério de sucesso:** Definir os KPIs que serão avaliados para comprovar eficácia do modelo, assim como acompanhamento da sua acurácia



# Machine Learning Workflow



# Machine Learning Workflow

## Data Understanding

É de conhecimento que coletar e tratar o dado é uma tarefa responsável por mais de **70% do tempo investido** por um Cientista de Dados

Exatamente sobre isso que essa fase e a próxima dizem respeito. Aqui, com uso de estatísticas, será necessário:  
**Coletar, Descrever, Explorar e Verificar a qualidade dos dados**

Aqui é o ponto onde se evita o famoso:

**Garbage In => Garbage Out**



# Machine Learning Workflow

## Data Understanding

É de conhecimento que coletar e tratar o dado é uma tarefa responsável por mais de **70% do tempo investido** por um Cientista de Dados

Exatamente sobre isso que essa fase e a próxima dizem respeito. Aqui, com uso de estatísticas, será necessário:  
**Coletar, Descrever, Explorar e Verificar a qualidade dos dados**

Aqui é o ponto onde se evita o famoso:

**Garbage In => Garbage Out**



# Machine Learning Workflow

## Data Understanding

É de conhecimento que coletar e tratar o dado é uma tarefa responsável por mais de **70% do tempo investido** por um Cientista de Dados

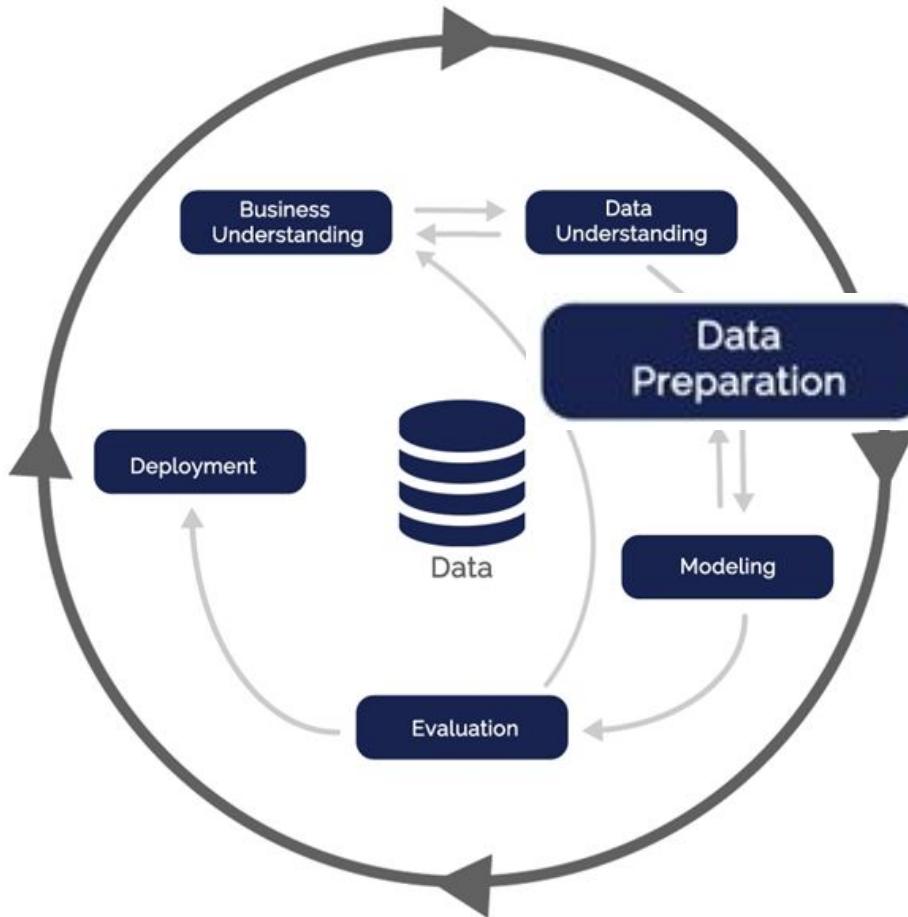
Exatamente sobre isso que essa fase e a próxima dizem respeito. Aqui, com uso de estatísticas, será necessário:  
**Coletar, Descrever, Explorar e Verificar a qualidade dos dados**

Aqui é o ponto onde se evita o famoso:

**Garbage In => Garbage Out**



# Machine Learning Workflow



# Machine Learning Workflow

## Data Preparation

Consiste na preparação dos dados para modelagem:

**Data Selection:** Selecionar os dados que serão usados no modelo. Importante documentar o motivo de tê-los escolhidos

**Data Cleaning:** Datas em formato incorreto e números inteiros sendo interpretados como string são alguns dos exemplos de questões a serem tratadas



# Machine Learning Workflow

## Data Preparation

Consiste na preparação dos dados para modelagem:

**Data Selection:** Selecionar os dados que serão usados no modelo. Importante documentar o motivo de tê-los escolhidos

Data Cleaning: Datas em formato incorreto e números inteiros sendo interpretados como string são alguns dos exemplos de questões a serem tratadas



# Machine Learning Workflow

## Data Preparation

Consiste na preparação dos dados para modelagem:

**Data Selection:** Selecionar os dados que serão usados no modelo. Importante documentar o motivo de tê-los escolhidos

**Data Cleaning:** Datas em formato incorreto e números inteiros sendo interpretados como string são alguns dos exemplos de questões a serem tratadas



# Machine Learning Workflow

## Data Preparation

Consiste na preparação dos dados para modelagem:

**Construct Data:** Algumas vezes é necessário criar novos dados para modelagem. Por exemplo, um novo campo ou coluna indicando que a data é feriado ou qual dia da semana representa

Integrating Data: Necessário para juntar fontes de dados diferentes



# Machine Learning Workflow

## Data Preparation

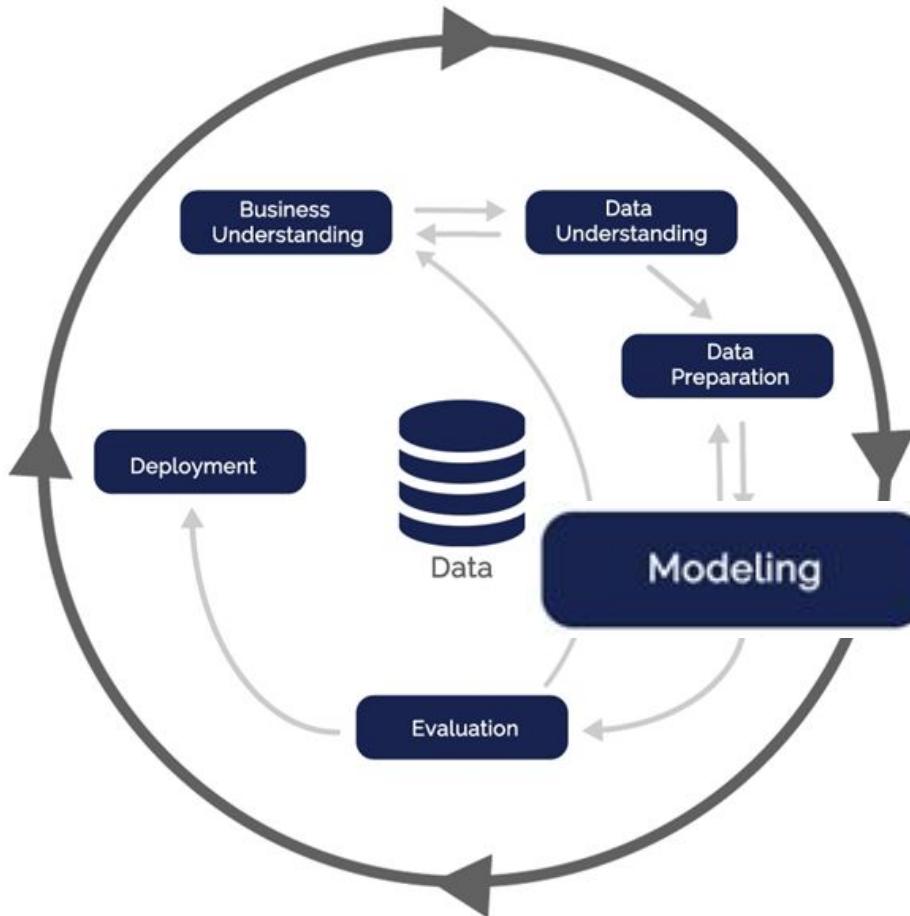
Consiste na preparação dos dados para modelagem:

**Construct Data:** Algumas vezes é necessário criar novos dados para modelagem. Por exemplo, um novo campo ou coluna indicando que a data é feriado ou qual dia da semana representa

**Integrating Data:** Necessário para juntar fontes de dados diferentes



# Machine Learning Workflow



# Machine Learning Workflow

## Modeling

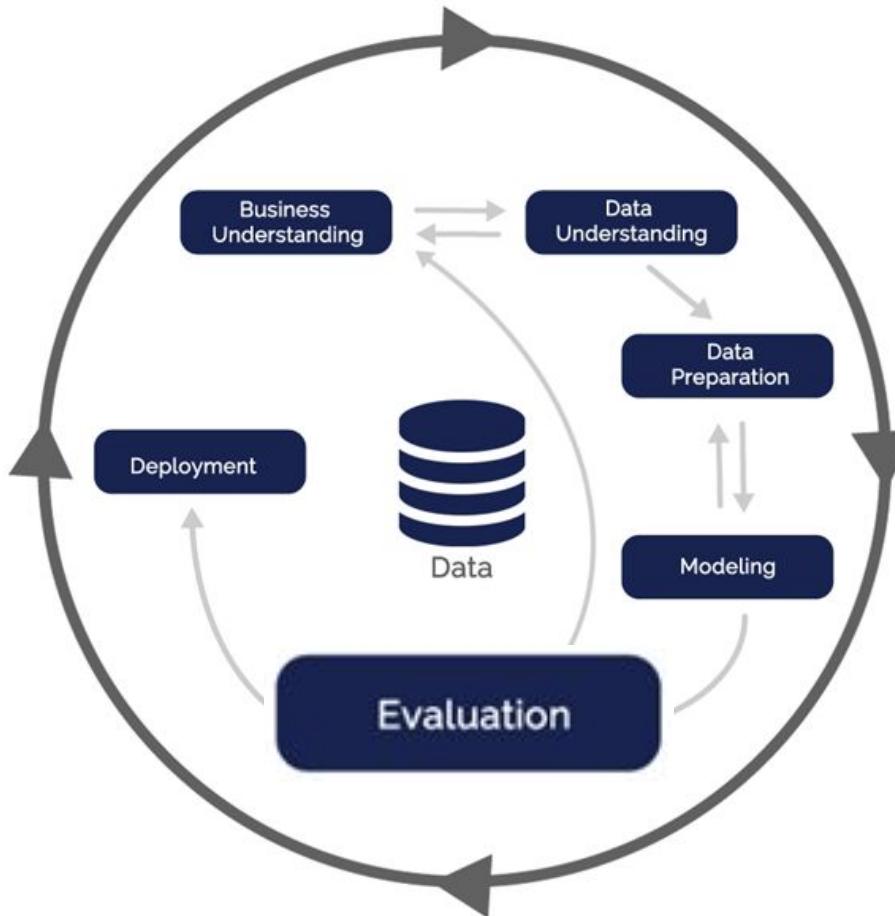


# Machine Learning Workflow

## Modeling



# Machine Learning Workflow



# Machine Learning Workflow

## Evaluation

Validação dos resultados da modelagem, utilizando os critérios de sucesso definidos na primeira fase

- No caso de não atingimento dos KPIs, será necessário voltar a primeira fase para entendimento da falha de planejamento
- No caso de atingimento adequado das metas, pode-se prosseguir para fase de implementação da modelagem



# Machine Learning Workflow

## Evaluation

Validação dos resultados da modelagem, utilizando os critérios de sucesso definidos na primeira fase

- **No caso de não atingimento dos KPIs, será necessário voltar a primeira fase para entendimento da falha de planejamento**
- No caso de atingimento adequado das metas, pode-se prosseguir para fase de implementação da modelagem



# Machine Learning Workflow

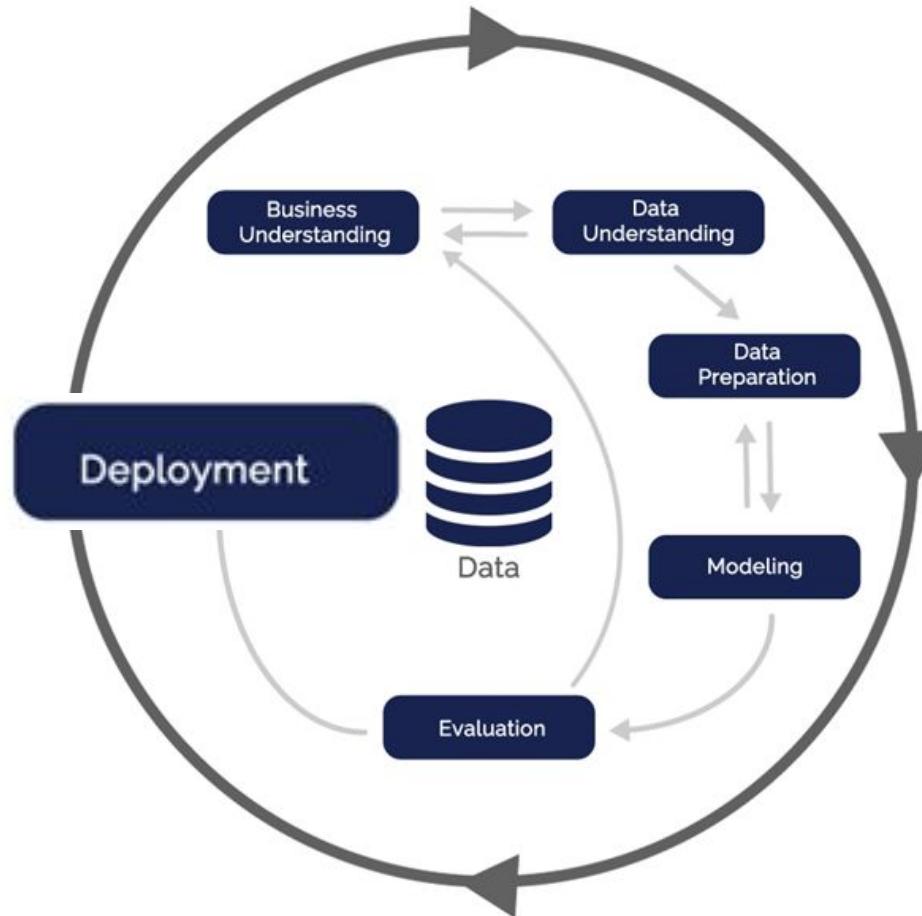
## Evaluation

Validação dos resultados da modelagem, utilizando os critérios de sucesso definidos na primeira fase

- No caso de não atingimento dos KPIs, será necessário voltar a primeira fase para entendimento da falha de planejamento
- **No caso de atingimento adequado das metas, pode-se prosseguir para fase de implementação da modelagem**



# Machine Learning Workflow



# Machine Learning Workflow

## Deployment

Nesta fase será hora de colocar o **modelo em produção**, para que **possa ser usado**

O deployment demarca a entrega do produto final

Após, será necessário acompanhar e monitorar os resultados

Sempre que necessário a modelagem deverá ser readaptada para manter a sua acurácia



# Machine Learning Workflow

## Deployment

Nesta fase será hora de colocar o **modelo em produção**, para que **possa ser usado**

O deployment demarca a **entrega do produto final**

Após, será necessário acompanhar e monitorar os resultados

Sempre que necessário a modelagem deverá ser readaptada para manter a sua acurácia



# Machine Learning Workflow

## Deployment

Nesta fase será hora de colocar o **modelo em produção**, para que **possa ser usado**

O deployment demarca a **entrega do produto final**

Após, será necessário acompanhar e monitorar os resultados

Sempre que necessário a modelagem deverá ser readaptada para manter a sua acurácia



# Machine Learning Workflow

## Deployment

Nesta fase será hora de colocar o **modelo em produção**, para que **possa ser usado**

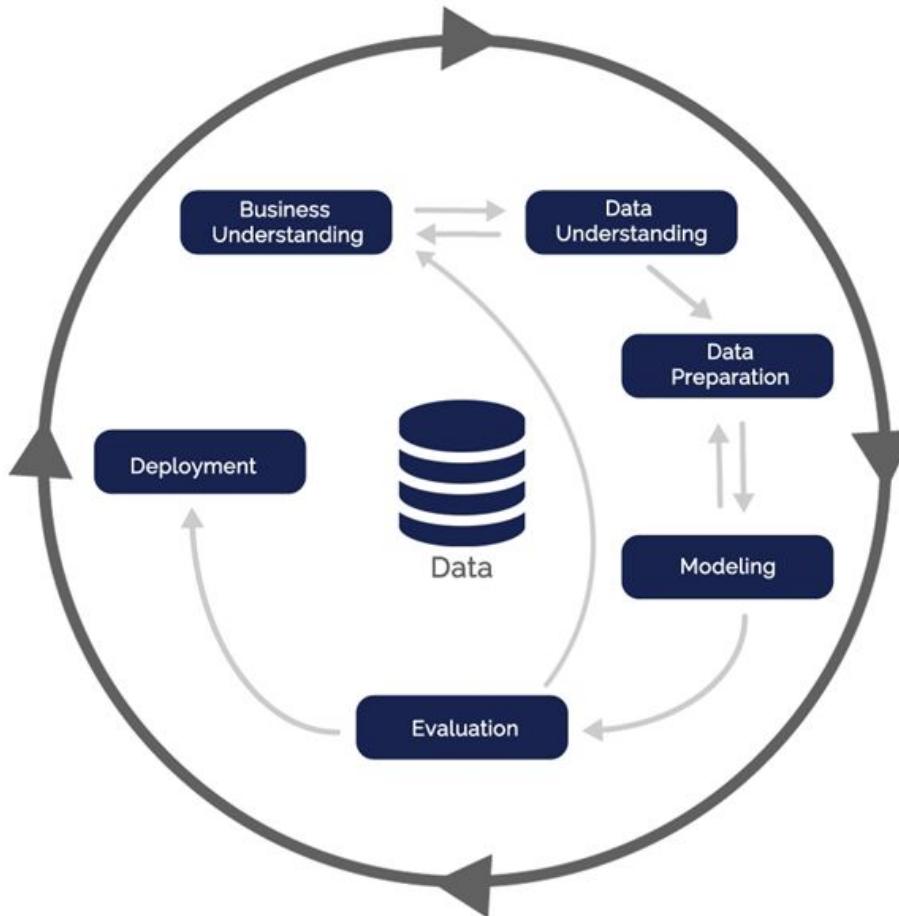
O deployment demarca a **entrega do produto final**

Após, será necessário acompanhar e monitorar os resultados

Sempre que necessário a **modelagem deverá ser readaptada para manter a sua acurácia**



# Machine Learning Workflow



# Artificial Intelligence & Machine Learning

1 – ML Workflow

2 – Framework H2O.ai

3 – Framework TensorFlow

4 – Framework Scikit-Learn





# Artificial Intelligence & Machine Learning

1 – ML Workflow

2 – Framework H2O.ai

3 – Framework TensorFlow

4 – Framework Scikit-Learn





# Artificial Intelligence & Machine Learning

1 – ML Workflow

2 – Framework H2O.ai

3 – Framework TensorFlow

4 – Framework Scikit-Learn



# Scikit-Learn



# Agenda - Modelos Preditivos

1 – Introdução

2 – Construção

3 – Overfitting

4 – Resampling

5 – Algoritmos

6 – Aplicações



# Modelos Preditivos

1 – Introdução

2 – Construção

3 – Overfitting

4 – Resampling

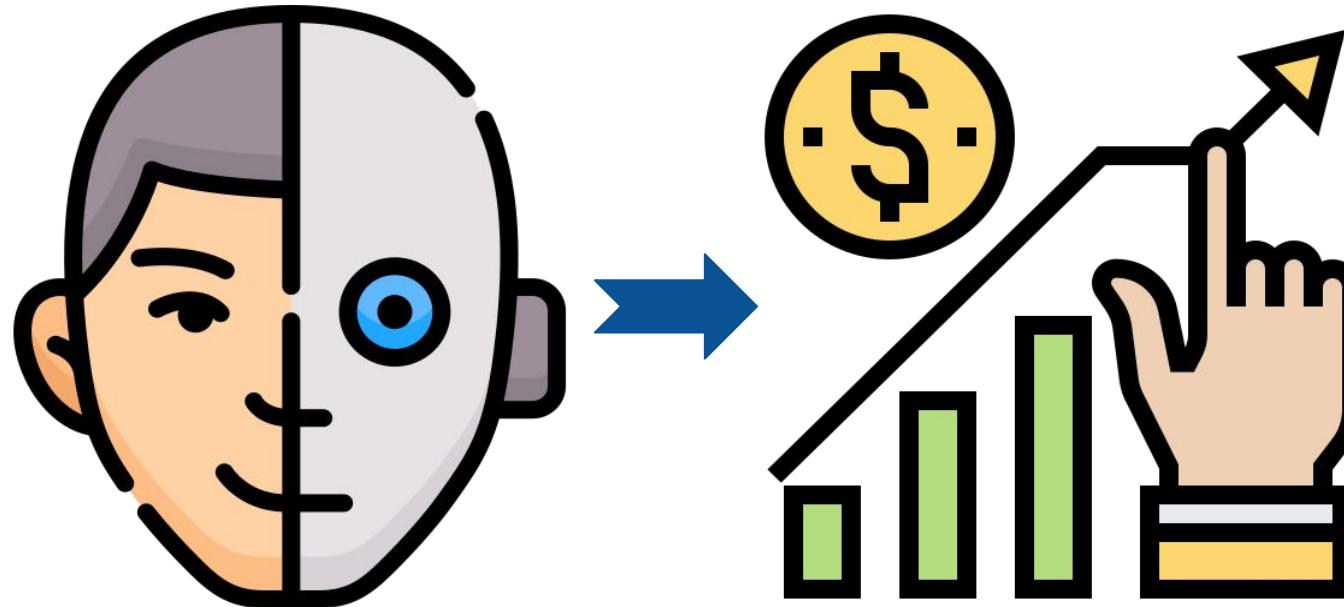
5 – Algoritmos

6 – Aplicações



# Modelos Preditivos - Introdução

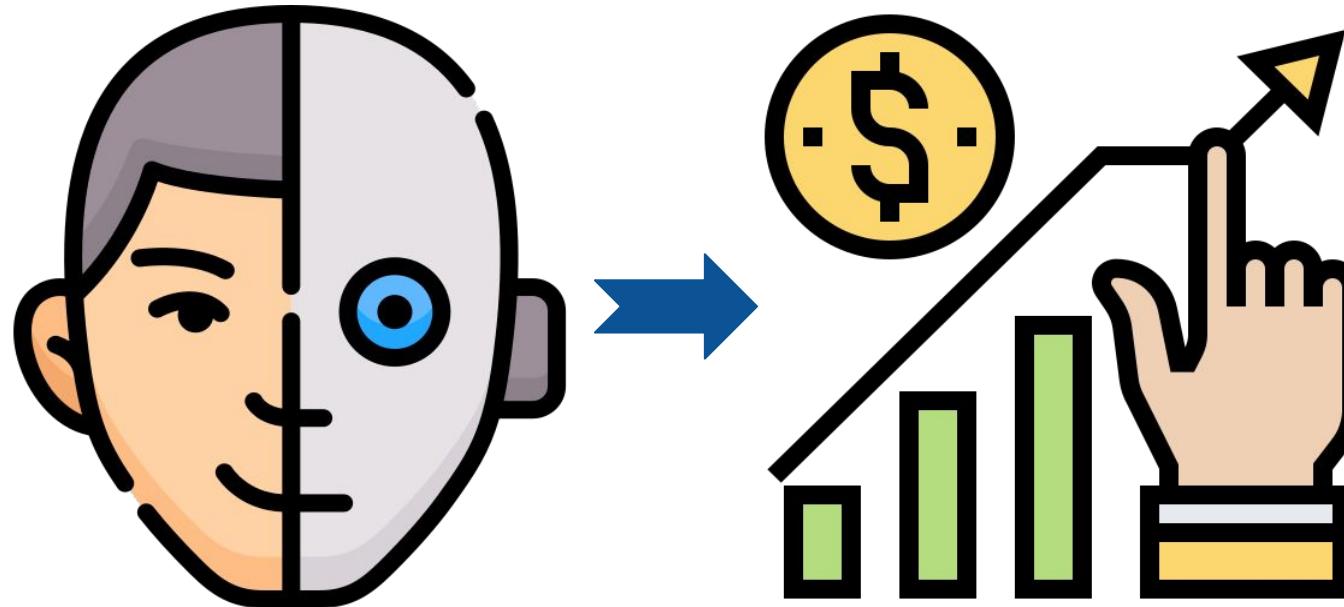
É o processo de desenvolver uma ferramenta matemática ou modelo que seja capaz de gerar uma previsão acurada



# Modelos Preditivos - Introdução

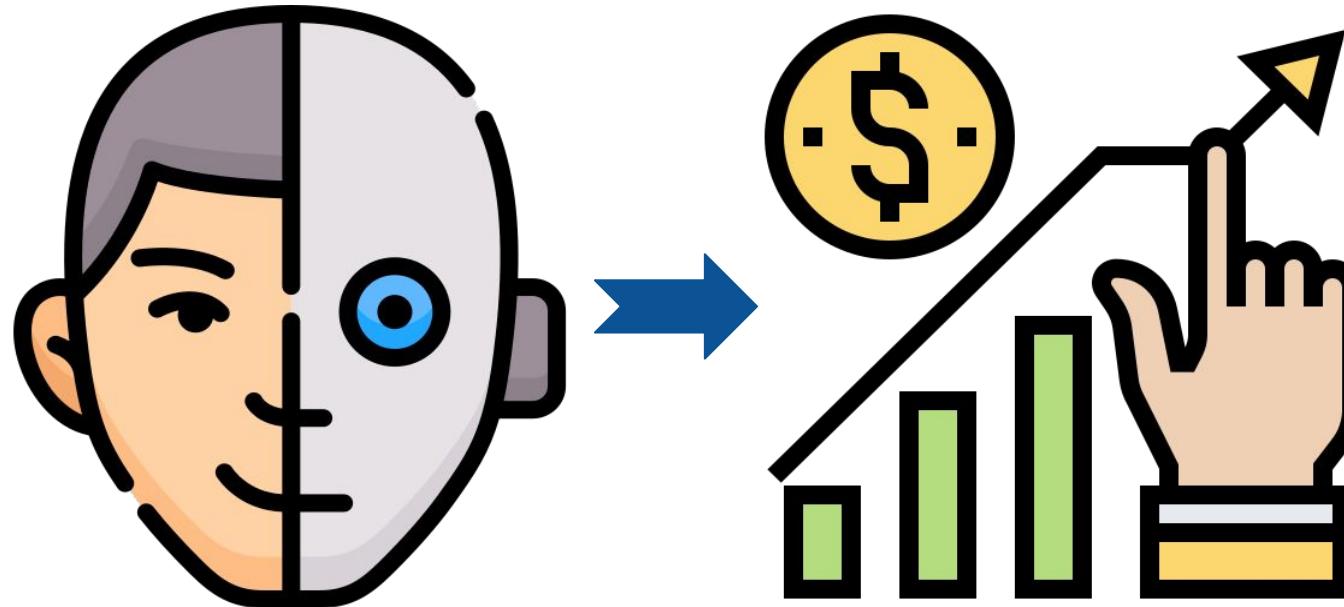
**Os métodos supervisionados são os mais comumente utilizados**

**Ou seja, exigirá conhecimento prévio sobre o fenômeno**



# Modelos Preditivos - Introdução

Estes modelos estão presentes à muito tempo em nossas vidas: Recomendação de produtos da Amazon, análise de crédito pelos bancos, sugestões de filmes na Netflix, etc



# Modelos Preditivos - Introdução

## Predição <=> Interpretação

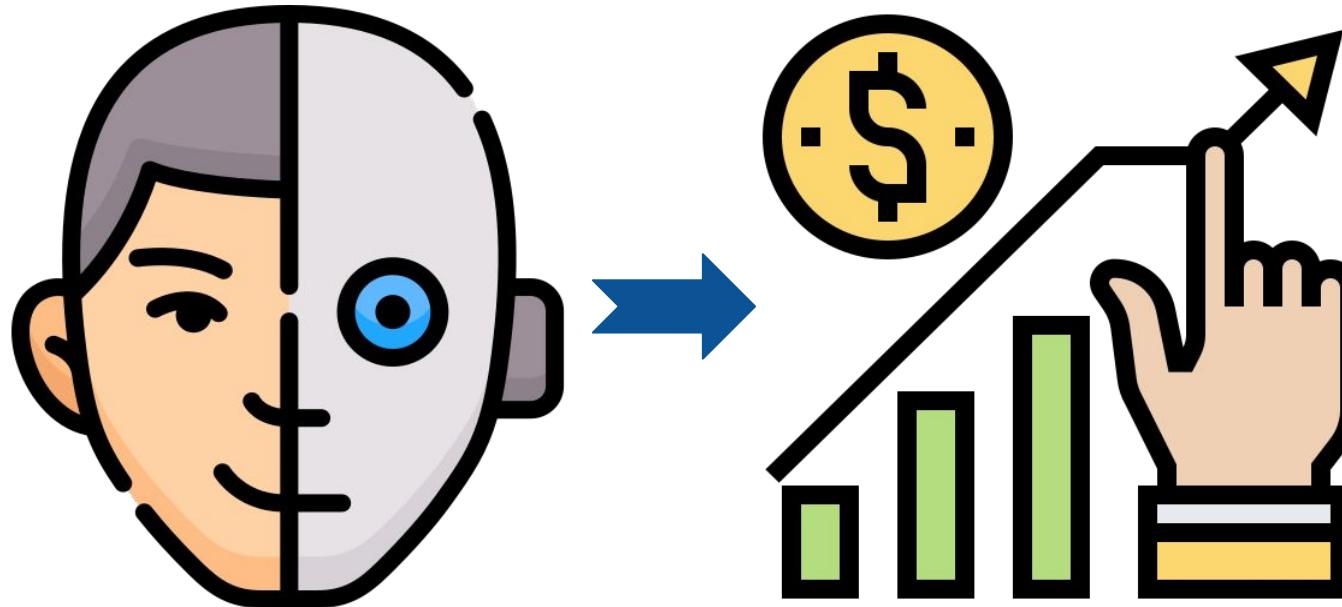
A predição deverá ser acurada, por outro lado o modelo construído também deverá ser interpretável

Isto porque quanto mais complexo é o modelo mais difícil será a sua interpretação



# Modelos Preditivos - Introdução

“No final, os modelos preditivos não substituem a intuição humana, e sim a complementam” Ayres(2007)



# Modelos Preditivos

1 – Introdução

2 – Construção

3 – Overfitting

4 – Resampling

5 – Algoritmos

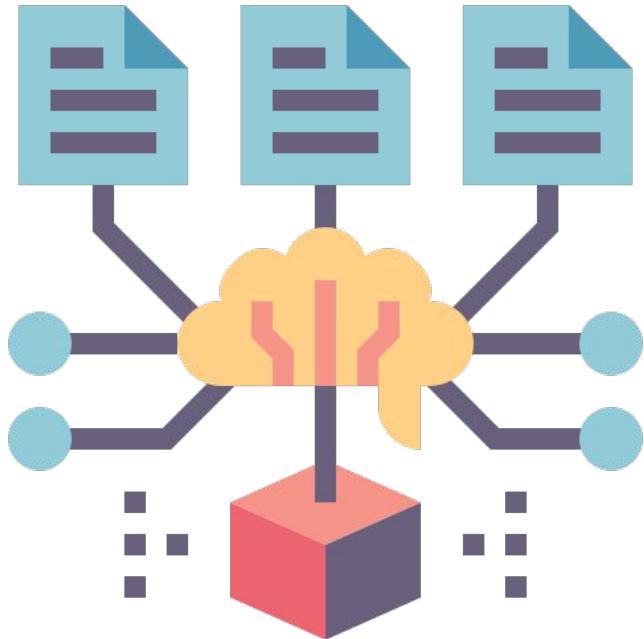
6 – Aplicações



# Modelos Preditivos - Construção

## Erros mais graves:

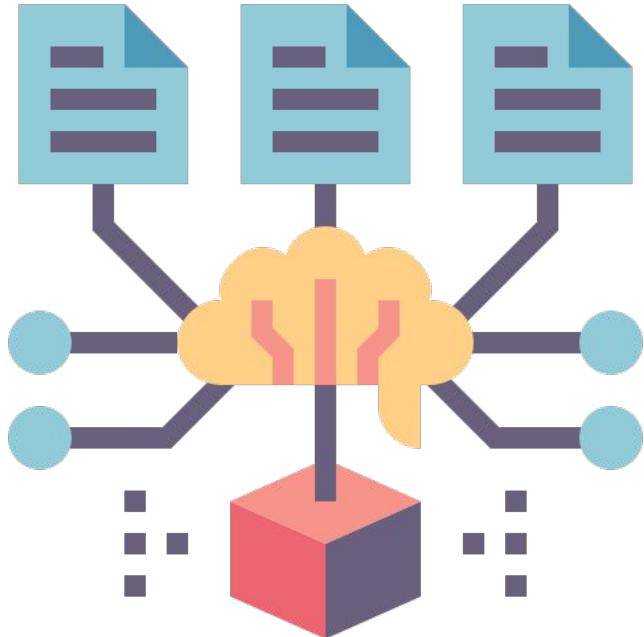
- 1) Pré-processamento inadequado dos dados**
- 2) Validação inadequada dos modelos**
- 3) Extrapolação injustificada (espaço, dimensão, tempo)**
- 4) Overfitting**



# Modelos Preditivos - Construção

## Erros mais graves:

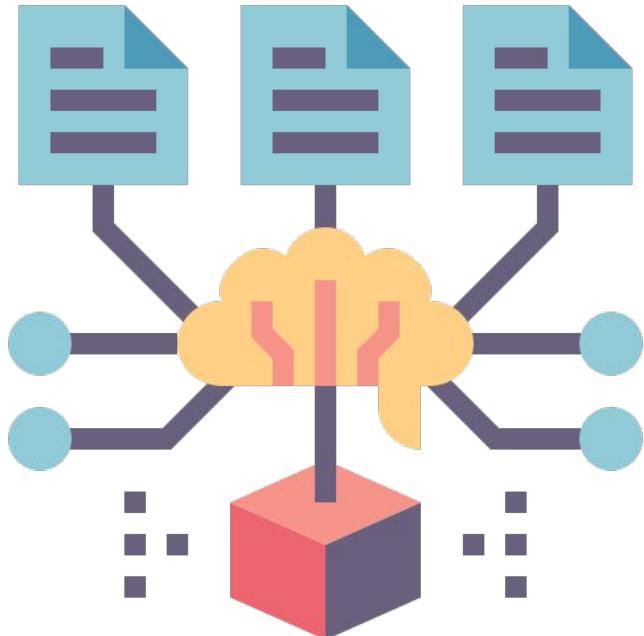
- 1) Pré-processamento inadequado dos dados
- 2) **Validação inadequada dos modelos**
- 3) Extrapolação injustificada (espaço, dimensão, tempo)
- 4) Overfitting



# Modelos Preditivos - Construção

## Erros mais graves:

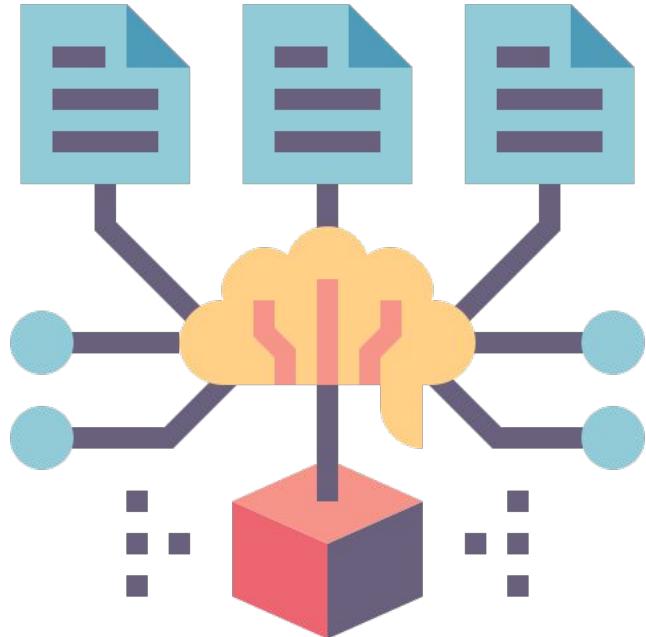
- 1) Pré-processamento inadequado dos dados
- 2) Validação inadequada dos modelos
- 3) **Extrapolação injustificada (espaço, dimensão, tempo)**
- 4) Overfitting



# Modelos Preditivos - Construção

## Erros mais graves:

- 1) Pré-processamento inadequado dos dados
- 2) Validação inadequada dos modelos
- 3) Extrapolação injustificada (espaço, dimensão, tempo)
- 4) Overfitting



# Modelos Preditivos - Construção

## 1 - Data Splitting

- Para os modelos preditivos em geral será necessário construí-lo com **dados diferentes** aos que serão utilizados para validar sua acurácia
  - Ou seja, com populações **distintas** ou **separadas**
- A construção será feita com dados para **Treino** e posteriormente validado pelos dados de **Teste**

# Modelos Preditivos - Construção

## 1 - Data Splitting

- Para os modelos preditivos em geral será necessário construí-lo com **dados diferentes** aos que serão utilizados para validar sua acurácia
  - Ou seja, com populações **distintas ou separadas**
- A construção será feita com dados para **Treino** e posteriormente validado pelos dados de **Teste**

# Modelos Preditivos - Construção

## 1 - Data Splitting

- Portanto é necessário dividir os dados **rotulados** (data splitting) em treino e teste
- A tamanho para cada população depende de alguns fatores:
  - Para conjunto de dados acima de 100k observações, indicado dividir ao menos em aproximadamente 70% para treino e 30% para teste



# Modelos Preditivos - Construção

## 1 - Data Splitting

- Portanto é necessário dividir os dados **rotulados** (data splitting) em treino e teste
- A tamanho para cada população depende de alguns fatores:
  - Para conjunto de dados acima de 100k observações, indicado dividir ao menos em aproximadamente **70% para treino e 30% para teste**



# Modelos Preditivos - Construção

## 1 - Data Splitting

- Para quantidades inferiores recomenda-se trabalhar com aproximadamente 90% treino e 10% teste
- Nestes casos, para aumentar a qualidade do teste necessário aplicar **reamostragem**:
  - Técnica que consiste em reamostrar  $n$  vezes o conjunto de teste melhorar a capacidade de validação do modelo

# Modelos Preditivos - Construção

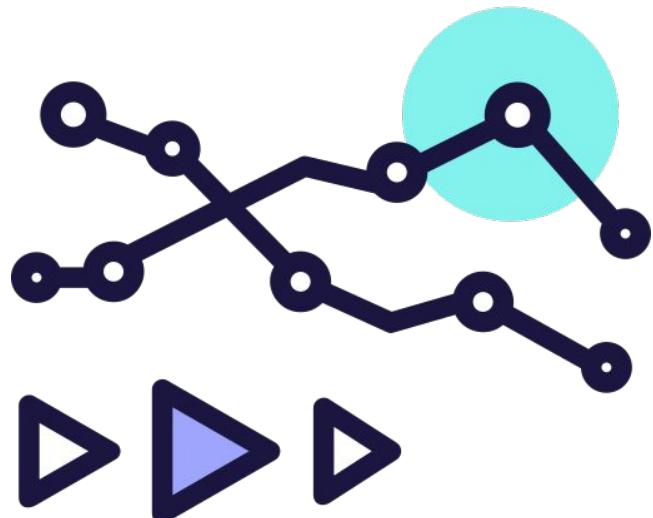
## 1 - Data Splitting

- Para quantidades inferiores recomenda-se trabalhar com aproximadamente 90% treino e 10% teste
- Nestes casos, para aumentar a qualidade do teste necessário aplicar **reamostragem**:
  - Técnica que consiste em reamostrar  $n$  vezes o conjunto de teste para melhorar a capacidade de validação do modelo

# Modelos Preditivos - Construção

## 2 - Dados Preditivos

O primeiro passo aqui é entender como será **utilizado** o modelo após construído e validar quais serão as **Variáveis Explicativas**



# Modelos Preditivos - Construção

## 2 - Dados Preditivos

- Principais considerações:
  - Procurar e validar as variáveis com maior potencial de predição (correlação)
  - Mapear a complexidade de obtenção destas informações
  - Preferência para as variáveis com baixa volatilidade

# Modelos Preditivos - Construção

## 2 - Dados Preditivos

- Principais considerações:
  - Procurar e validar as variáveis com maior potencial de predição (correlação)
  - Mapear a complexidade de obtenção destas informações
  - Preferência para as variáveis com baixa volatilidade

## 2 - Dados Preditivos

- Principais considerações:
  - Procurar e validar as variáveis com maior potencial de predição (correlação)
  - Mapear a complexidade de obtenção destas informações
  - Preferência para as variáveis com baixa volatilidade

# Modelos Preditivos - Construção

## 2 - Dados Preditivos

- Principais considerações:
  - Procurar e validar as variáveis com maior potencial de predição (correlação)
  - Mapear a complexidade de obtenção destas informações
  - Preferência para as variáveis com baixa volatilidade

# Modelos Preditivos - Construção

## 2 - Dados Preditivos

- Principais considerações:
  - Não trabalhar com muitas variáveis explicativas para evitar o problema de grande dimensionalidade
  - Caso três variáveis sejam suficientes para explicar o fenômeno será excelente para simplificar a explicação do modelo

# Modelos Preditivos - Construção

## 2 - Dados Preditivos

- Principais considerações:
  - Não trabalhar com muitas variáveis explicativas para evitar o problema de grande dimensionalidade
  - Caso três variáveis sejam suficientes para explicar o fenômeno será excelente para **simplificar a explicação do modelo**

# Modelos Preditivos - Construção

## 3 - Estimando Performance do Modelo

O indicador de performance mais usual é o **RMSE**, ou Root Mean Squared Error ou ainda **Raiz Quadrada do Erro Médio**, por ser eficaz para gerar uma função objetivo para otimizar o modelo escolhido

$$RMSE = \sqrt{\sum_{i=1}^n \frac{(\hat{y}_i - y_i)^2}{n}}$$



# Modelos Preditivos - Construção

## 4 - Validando Vários Modelos

Aqui está uma das principais armadilhas: querer usar apenas o modelo que se tem maior domínio, sem testar outros potenciais candidatos

Cada conjunto de dados possui uma **característica específica** que precisará ser testado com vários modelos até encontrar o com melhor ajuste



# Modelos Preditivos - Construção

## 4 - Validando Vários Modelos

Aqui está uma das principais armadilhas: querer usar apenas o modelo que se tem maior domínio, sem testar outros potenciais candidatos

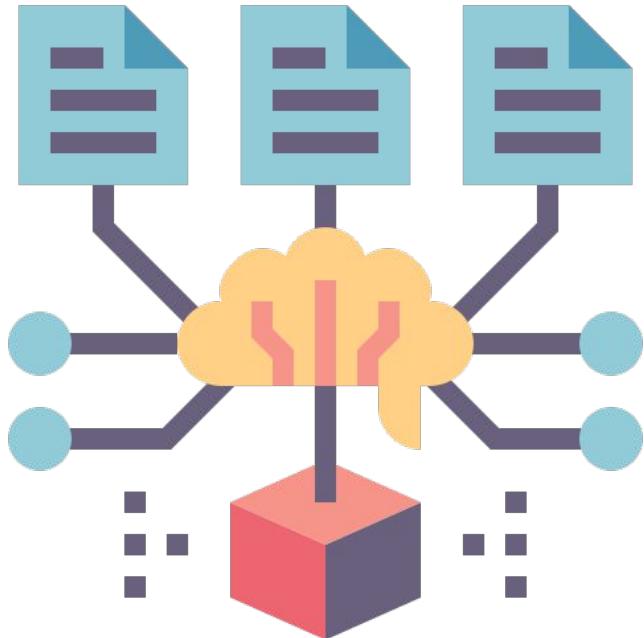
Cada conjunto de dados possui uma **característica específica** que precisará ser testado com vários modelos até encontrar o com melhor ajuste



# Modelos Preditivos - Construção

## 5 - Seleção do Modelo

Após a validação dos modelos será necessário escolher o que possui melhor ajuste aos dados e também que seja **mais fácil de explicar e de implantar**



# Modelos Preditivos

1 – Introdução

2 – Construção

3 – Overfitting

4 – Resampling

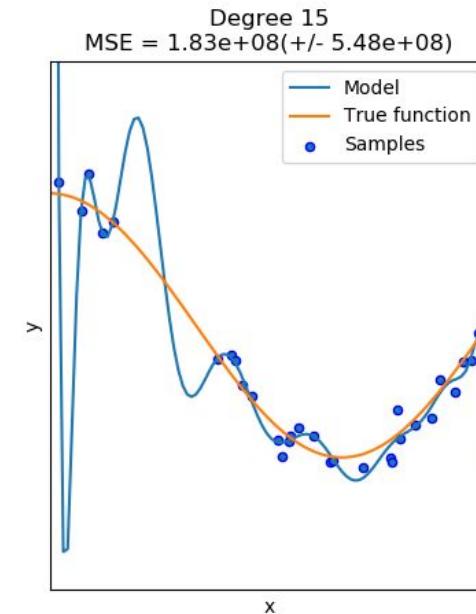
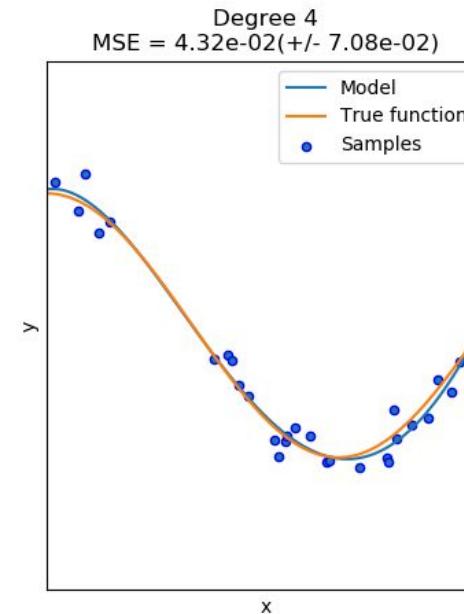
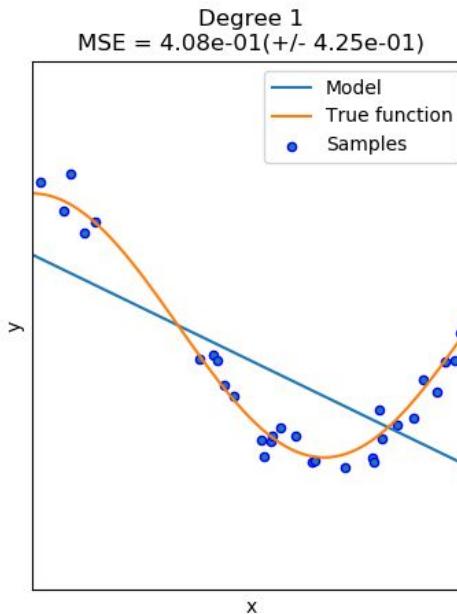
5 – Algoritmos

6 – Aplicações



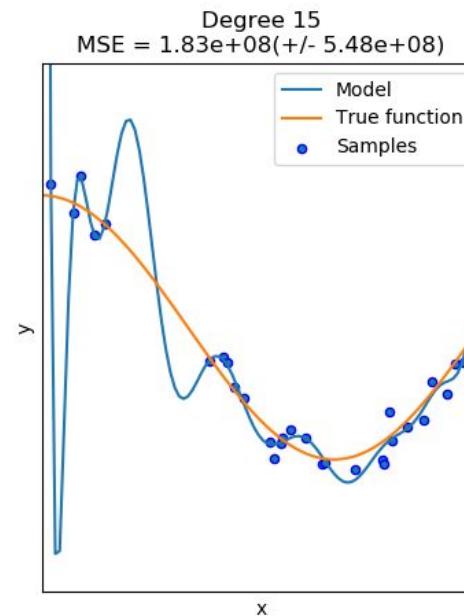
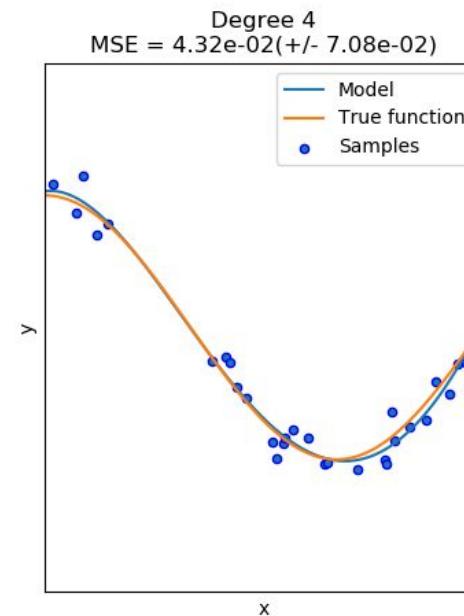
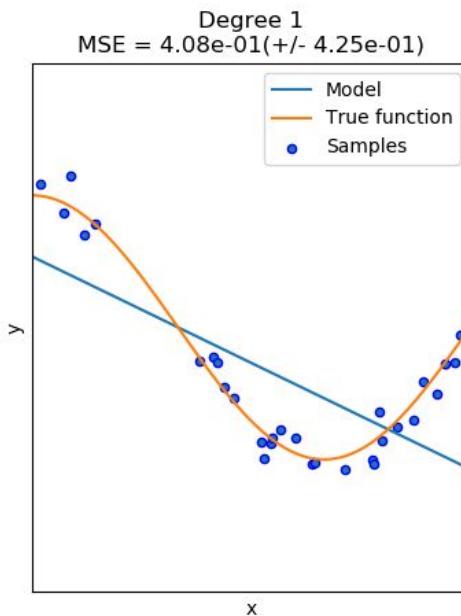
# Overfitting

É o fenômeno causado quando um modelo se adapta demais ao conjunto de dados de treino



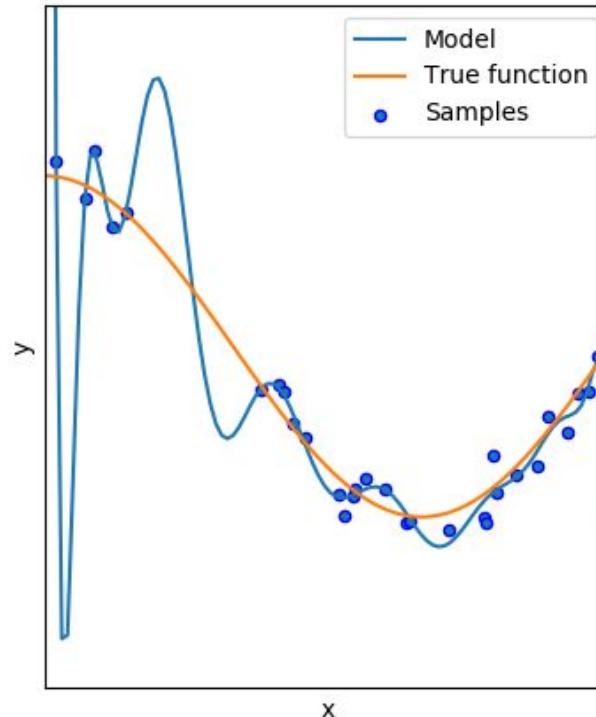
# Overfitting

## Qual destes tem overfitting?



# Overfitting

É o fenômeno causado quando um modelo se adapta demais ao conjunto de dados de treino



# Overfitting

Geralmente é identificado pelo **elevado índice de ajuste**, indicando uma excelente performance quando comparado aos demais modelos avaliados

Percebe-se que é essencial a validação de vários tipos de modelos para conseguir identificar mais claramente o Overfitting

# Overfitting

Geralmente é identificado pelo elevado índice de ajuste, indicando uma excelente performance quando comparado aos demais modelos avaliados

Percebe-se que é essencial a validação de vários tipos de modelos para conseguir identificar mais claramente o Overfitting



# Overfitting

O problema do modelo super ajustado aos conjuntos de dados é que ele produzirá **previsões pouco ou nada acurados**

É mais indicado dar preferência aos modelos que suavizam sua adaptação aos dados e consequentemente produzirão **previsões mais acuradas e igualmente confiáveis**

# Overfitting

O problema do modelo super ajustado aos conjuntos de dados é que ele produzirá **previsões pouco ou nada acurados**

É mais indicado dar preferência aos modelos que suavizam sua adaptação aos dados e consequentemente produzirão **previsões mais acuradas e igualmente confiáveis**

# Modelos Preditivos

1 – Introdução

2 – Construção

3 – Overfitting

4 – Resampling

5 – Algoritmos

6 – Aplicações



# Resampling

Conforme abordado anteriormente, a **reamostragem é uma excelente ferramenta** quando necessário ter mais dados para validação dos modelos

Pode ser utilizado para balancear dados de conjuntos **estratificados por segmentos**, quando alguns possuem poucos dados perante aos demais

Ou simplesmente para realizar uma validação de cada modelo com maior precisão



# Resampling

Conforme abordado anteriormente, a **reamostragem** é uma **excelente ferramenta** quando é necessário ter mais dados para validação dos modelos

Pode ser utilizado para balancear dados de conjuntos **estratificados por segmentos**, quando alguns possuem poucos dados perante aos demais

Ou simplesmente para realizar uma validação de cada modelo com maior precisão



# Resampling

Conforme abordado anteriormente, a **reamostragem** é uma **excelente ferramenta** quando é necessário ter mais dados para validação dos modelos

Pode ser utilizado para balancear dados de conjuntos **estratificados por segmentos**, quando alguns possuem poucos dados perante aos demais

Ou simplesmente para realizar uma validação de cada modelo com maior precisão



# Resampling

## K-fold Cross-Validation

É uma das técnicas de resampling mais utilizadas para  
**validação de modelos em geral**

Simplificando é a metodologia onde separa-se o conjunto de dados K vezes entre treino e teste

# Resampling

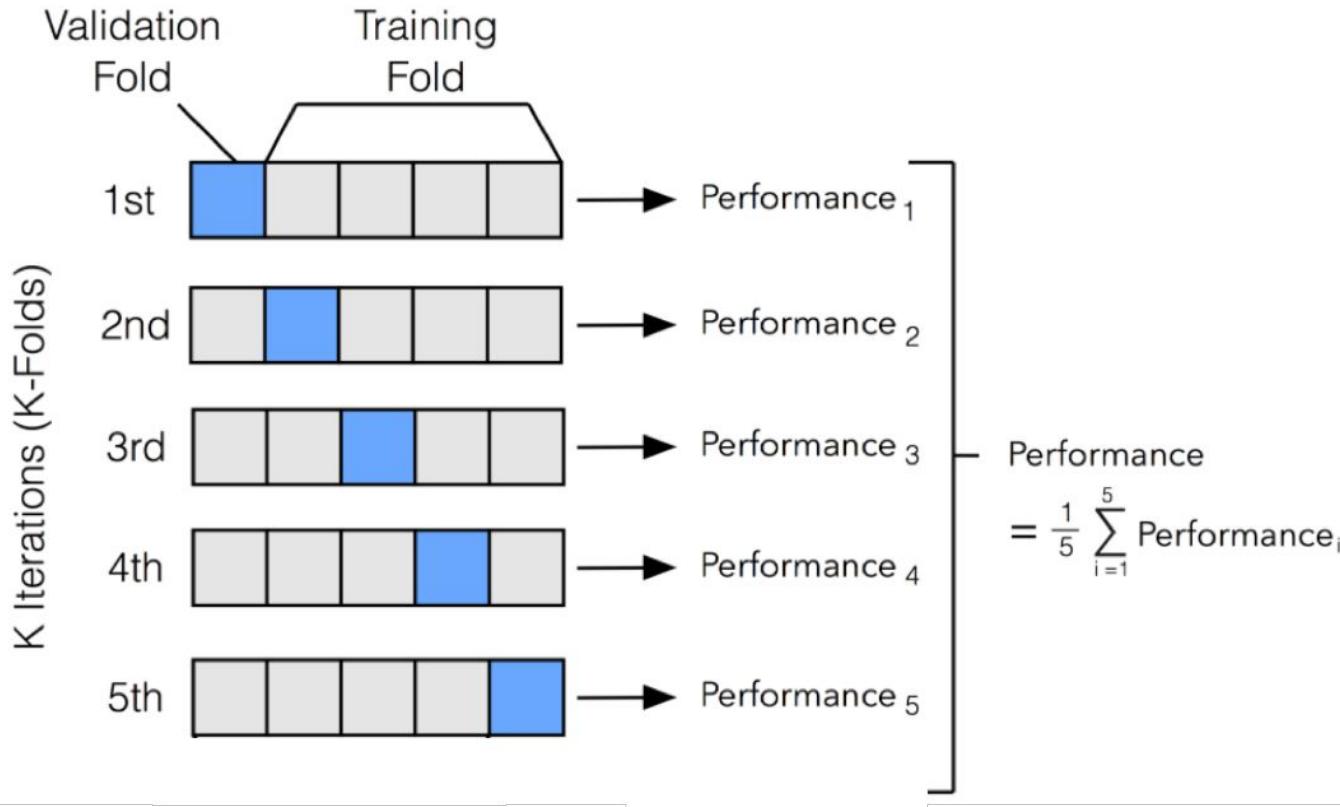
## K-fold Cross-Validation

É uma das técnicas de resampling mais utilizadas para validação de modelos em geral

Simplificando é a metodologia onde separa-se o conjunto de dados K vezes entre treino e teste

# Resampling

## K-fold Cross-Validation



# Resampling

## K-fold Cross-Validation

Para escolha do tamanho de K precisará ser levado em consideração:

- Quanto maior o K, maior o **custo computacional**
- Quanto menor o K, maior **será o viés da validação** podendo comprometer a escolha do modelo

Portanto, levando isto em consideração, indicado utilizar K=5 ou K=10



# Resampling

## K-fold Cross-Validation

Para escolha do tamanho de K precisará ser levado em consideração:

- Quanto maior o K, maior o **custo computacional**
- Quanto menor o K, maior **será o viés da validação, o que pode comprometer** a escolha do modelo

Portanto, levando isto em consideração, indicado utilizar K=5 ou K=10



# Resampling

## K-fold Cross-Validation

Para escolha do tamanho de K precisará ser levado em consideração:

- Quanto maior o K, maior o **custo computacional**
- Quanto menor o K, maior **será o viés da validação** podendo comprometer a escolha do modelo

Portanto, levando isto em consideração, indicado utilizar  
**K=5 ou K=10**



# Modelos Preditivos

1 – Introdução

2 – Construção

3 – Overfitting

4 – Resampling

5 – Algoritmos

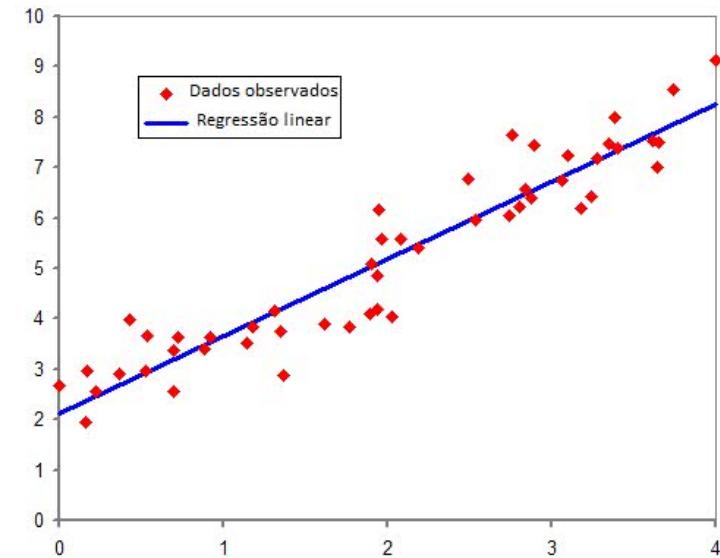
6 – Aplicações



# Regressão Linear

Análise de Regressão Linear é de longe a técnica de dependência mais amplamente usada e versátil, aplicável em cada faceta da tomada de decisões em negócios!

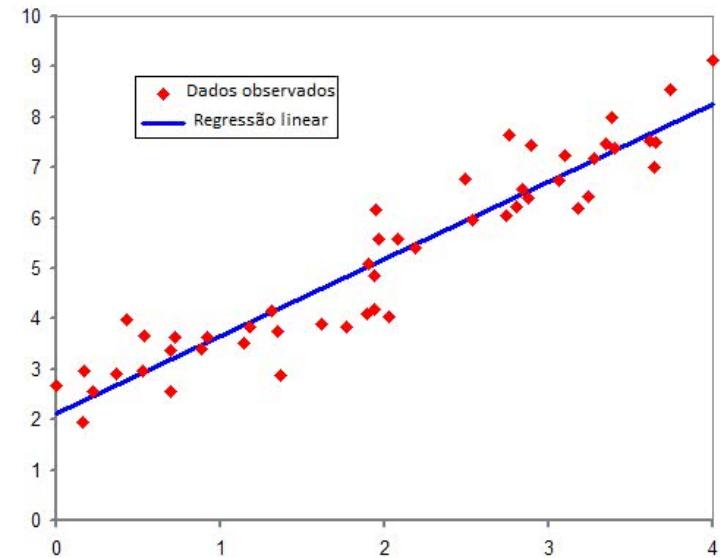
Seus usos variam desde os problemas mais gerais até os mais específicos. Por exemplo, é utilizado em empresas para previsão de vendas ou modelos para desempenho dos investimentos em Marketing.



# Regressão Linear

Análise de Regressão Linear é de longe a técnica de dependência mais amplamente usada e versátil, aplicável em cada faceta da tomada de decisões em negócios!

Seus usos variam desde os problemas mais gerais até os mais específicos. Por exemplo, é utilizado em empresas para **previsão de vendas** ou **modelos para desempenho** dos investimentos em Marketing.



# Regressão Linear

Existem basicamente dois tipos de **Regressão Linear**:

- 1) **Regressão Simples**: Modelo de regressão com uma única variável independente, também conhecida como bivariada
- 2) **Regressão Múltipla**: Modelo de regressão com duas ou mais variáveis independentes ou explicativas.

# Regressão Linear

Existem basicamente dois tipos de **Regressão Linear**:

- 1) **Regressão Simples**: Modelo de regressão com uma única variável independente, também conhecida como bivariada
- 2) **Regressão Múltipla**: Modelo de regressão com duas ou mais variáveis independentes ou explicativas.

# Regressão Linear

Existem basicamente dois tipos de **Regressão Linear**:

- 1) **Regressão Simples**: Modelo de regressão com uma única variável independente, também conhecida como bivariada
- 2) **Regressão Múltipla**: Modelo de regressão com duas ou mais variáveis independentes ou explicativas.

# Regressão Linear

Após a seleção, será o momento de construirmos a equação de regressão linear. Esta é a representação da Regressão Linear Simples:

$$Y = b_0 + b_1 X_1 + e$$

**Y** = Variável Resposta

**$b_0$**  = Constante

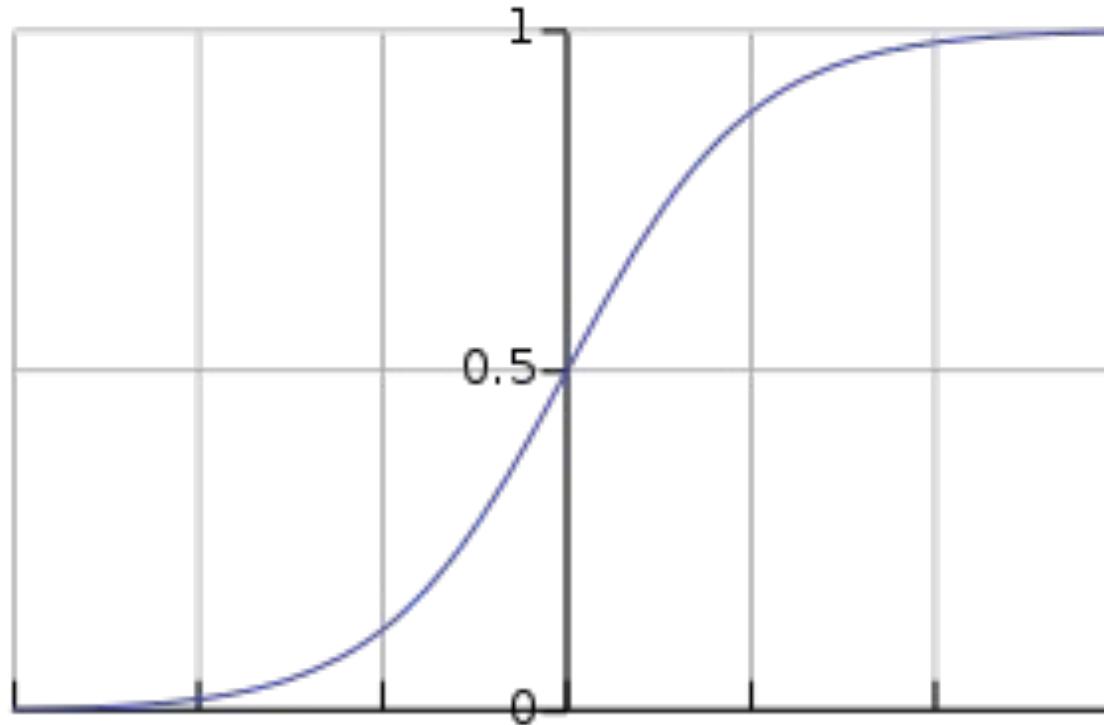
**$b_1$**  = Peso variável explicativa  **$X_1$**  = Variável Explicativa

**e** = Erro de previsão ou Resíduo



# Regressão Logística

A Regressão Logística é implementada de maneira semelhante à Regressão Linear Múltipla



# Regressão Logística

Este método representa os dois grupos de interesse como uma **variável binária com valores 0 e 1**. Não importa qual grupo é designado com o valor de 1 versus 0, mas tal designação deve ser observada para interpretação dos **coeficientes**:

- Se os grupos representam características como sexo, então um grupo pode ser designado com valor 1 (fem) e o outro com 0 (masc). Então os coeficientes refletiriam o impacto das variáveis explicativas sobre a probabilidade da pessoa ser do sexo feminino



# Regressão Logística

Este método representa os dois grupos de interesse como uma variável binária com valores 0 e 1. Não importa qual grupo é designado com o valor de 1 versus 0, mas tal designação deve ser observada para interpretação dos coeficientes:

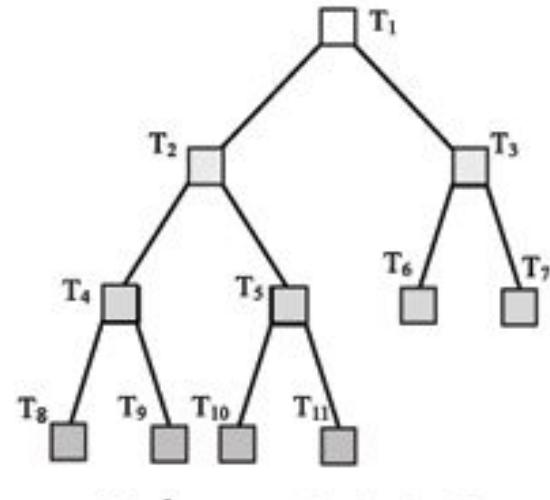
- Se os grupos representam resultados ou eventos (sucesso ou fracasso, compra ou não compra), a designação dos códigos de grupos causará impacto na interpretação dos resultados

# Árvore de Decisão ou Regressão

**Uma das técnicas mais utilizadas para tomada de decisões**

É capaz de lidar com a não linearidade, fácil de codificar, com poucas premissas e com resultado fácil de interpretar

A árvore de decisões é comumente adotada para concessões de crédito, diagnósticos médicos, análises de efeitos de drogas, análises de investimentos, etc

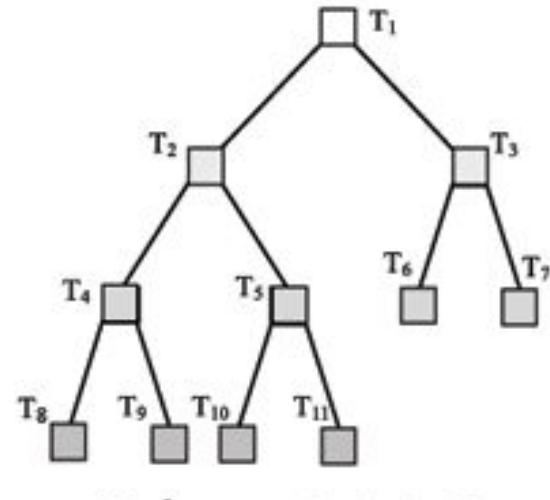


# Árvore de Decisão ou Regressão

Uma das técnicas mais utilizadas para tomada de decisões

É capaz de lidar com a não linearidade,  
fácil de codificar, com poucas premissas e  
com resultado fácil de interpretar

A árvore de decisões é comumente adotada para concessões de crédito, diagnósticos médicos, análises de efeitos de drogas, análises de investimentos, etc

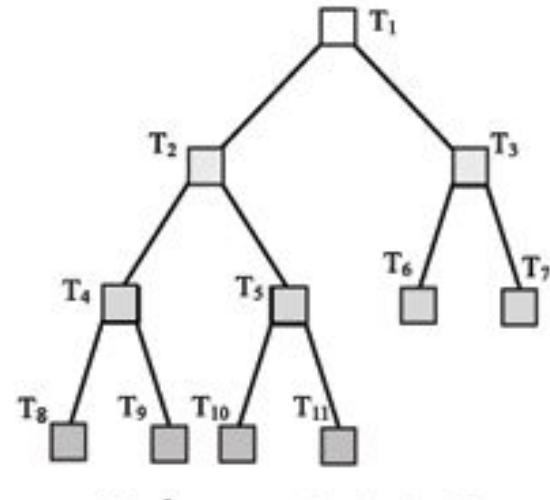


# Árvore de Decisão ou Regressão

Uma das técnicas mais utilizadas para tomada de decisões

É capaz de lidar com a não linearidade, fácil de codificar, com poucas premissas e com resultado fácil de interpretar

A árvore de decisões é comumente adotada para concessões de crédito, diagnósticos médicos, análises de efeitos de drogas, análises de investimentos, etc



# Árvore de Decisão ou Regressão

**Exemplo:** Para decidir se vai ou não emprestar a uma pessoa, o banco XYZ monta um formulário com três perguntas:

- Você possui empréstimo em outros bancos?
- Você é casado?
- Você possui casa própria?

# Árvore de Decisão ou Regressão

**Exemplo:** Para decidir se vai ou não emprestar a uma pessoa, o banco XYZ monta um formulário com três perguntas:

- Você possui empréstimo em outros bancos?
- Você é casado?
- Você possui casa própria?

# Árvore de Decisão ou Regressão

**Exemplo:** Para decidir se vai ou não emprestar a uma pessoa, o banco XYZ monta um formulário com três perguntas:

- Você possui empréstimo em outros bancos?
- Você é casado?
- Você possui casa própria?

# Árvore de Decisão ou Regressão

Com base nas suas respostas, o banco deve decidir ou não dar um empréstimo

Na árvore de decisões a seguir, construída com base nas respostas dos clientes, sabe-se a probabilidade do cliente pagar ou não o empréstimo.

E passa a fornecer crédito, para os clientes com probabilidade acima de 50%, que são os que ele considera bons pagadores:

# Árvore de Decisão ou Regressão

Com base nas suas respostas, o banco deve decidir ou não dar um empréstimo

Na árvore de decisões a seguir, construída com base nas respostas dos clientes, **sabe-se a probabilidade do cliente pagar ou não o empréstimo.**

E passa a fornecer crédito, para os clientes com probabilidade acima de 50%, que são os que ele considera bons pagadores:

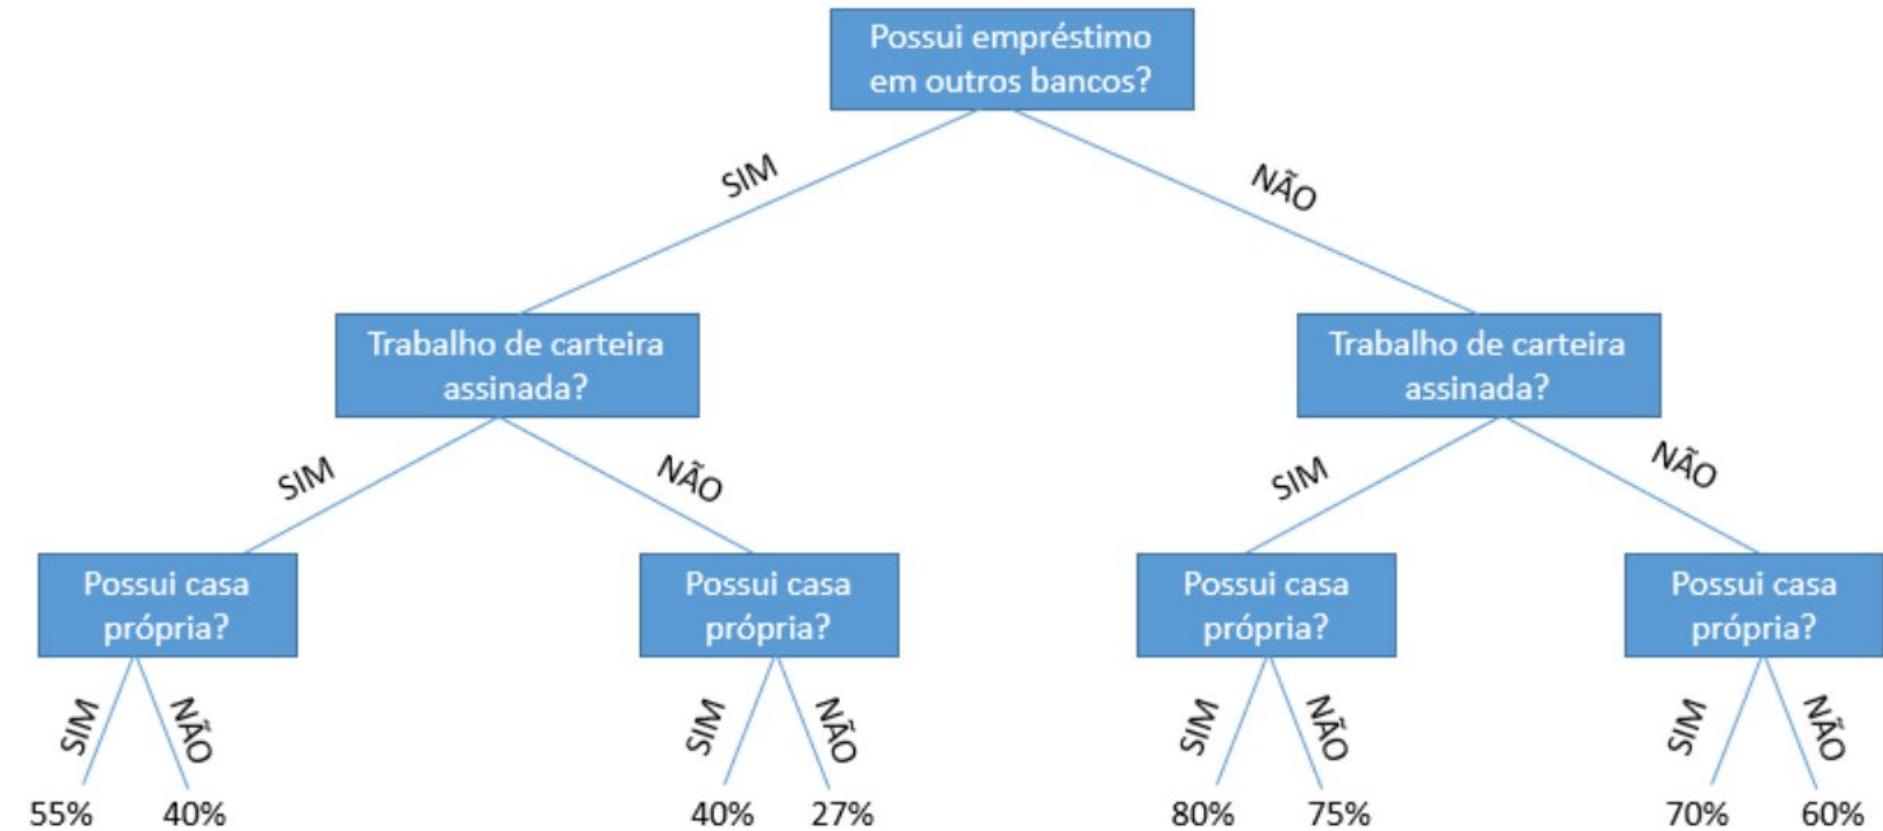
# Árvore de Decisão ou Regressão

Com base nas suas respostas, o banco deve decidir ou não dar um empréstimo

Na árvore de decisões a seguir, construída com base nas respostas dos clientes, sabe-se a probabilidade do cliente pagar ou não o empréstimo.

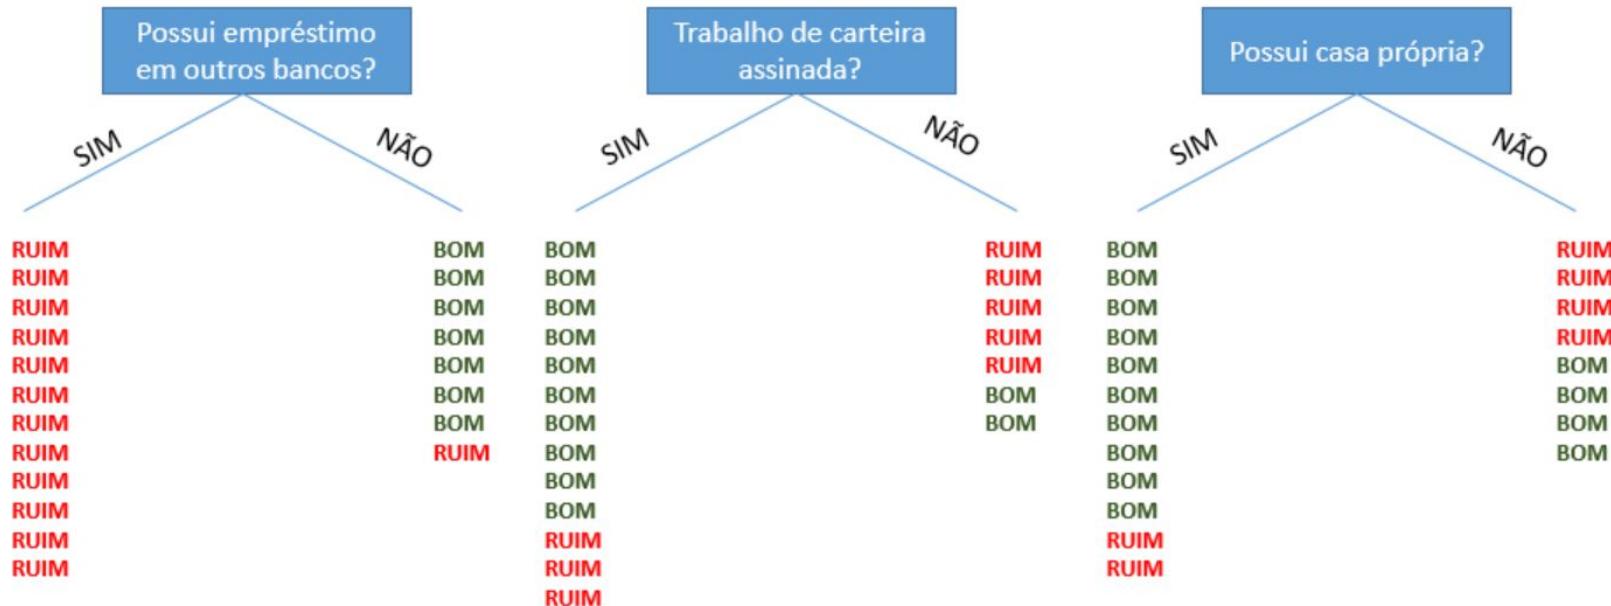
E passa a fornecer crédito, para os clientes com probabilidade acima de 50%, que são os que ele considera bons pagadores:

# Árvore de Decisão ou Regressão



# Árvore de Decisão ou Regressão

Supondo que o banco XYZ tenha 20 clientes que tomaram empréstimo no passado, sendo que bom é o cliente que pagou a dívida e ruim o que não pagou:



# Árvore de Decisão ou Regressão

Dentre os que tomaram empréstimo em outros bancos, nenhum pagou a dívida. E dentre os que não tomaram, apenas um não pagou a dívida com o banco XYZ

Com base na incerteza, podemos dizer que possuir empréstimo em outro banco é a melhor

Veja que essa variável tem zero de incerteza, com base no histórico, todos os clientes que possuem empréstimo em outros bancos são maus pagadores

# Árvore de Decisão ou Regressão

Dentre os que tomaram empréstimo em outros bancos, nenhum pagou a dívida. E dentre os que não tomaram, apenas um não pagou a dívida com o banco XYZ

Com base na incerteza, podemos dizer que possuir empréstimo em outro banco é a melhor variável

Veja que essa variável tem zero de incerteza, com base no histórico, todos os clientes que possuem empréstimo em outros bancos são maus pagadores

# Árvore de Decisão ou Regressão

Dentre os que tomaram empréstimo em outros bancos, nenhum pagou a dívida. E dentre os que não tomaram, apenas um não pagou a dívida com o banco XYZ

Com base na incerteza, podemos dizer que possuir empréstimo em outro banco é a melhor

Veja que essa variável tem zero de incerteza, com base no histórico, todos os clientes que possuem empréstimo em outros bancos são maus pagadores

# Árvore de Decisão ou Regressão

E qual a pior variável?

Seguindo a mesma lógica, é a variável possui ou não casa própria

Percebe-se que caso a pessoa não possua casa própria, a não é possível decidir se é mais provável que ela seja boa ou má pagadora

É equivalente a jogar uma moeda e decidir na sorte

# Árvore de Decisão ou Regressão

E qual a pior variável?

Seguindo a mesma lógica, é a variável possui ou não casa própria

Percebe-se que caso a pessoa não possua casa própria, a não é possível decidir se é mais provável que ela seja boa ou má pagadora

É equivalente a jogar uma moeda e decidir na sorte

# Árvore de Decisão ou Regressão

E qual a pior variável?

Seguindo a mesma lógica, é a variável possui ou não casa própria

Percebe-se que caso a pessoa não possua casa própria, não é possível decidir se é mais provável que ela seja boa ou má pagadora

É equivalente a jogar uma moeda e decidir na sorte

# Árvore de Decisão ou Regressão

E qual a pior variável?

Seguindo a mesma lógica, é a variável possui ou não casa própria

Percebe-se que caso a pessoa não possua casa própria, a não é possível decidir se é mais provável que ela seja boa ou má pagadora

**É equivalente a jogar uma moeda e decidir na sorte**

# Modelos Preditivos

1 – Introdução

2 – Construção

3 – Overfitting

4 – Resampling

5 – Algoritmos

6 – Aplicações

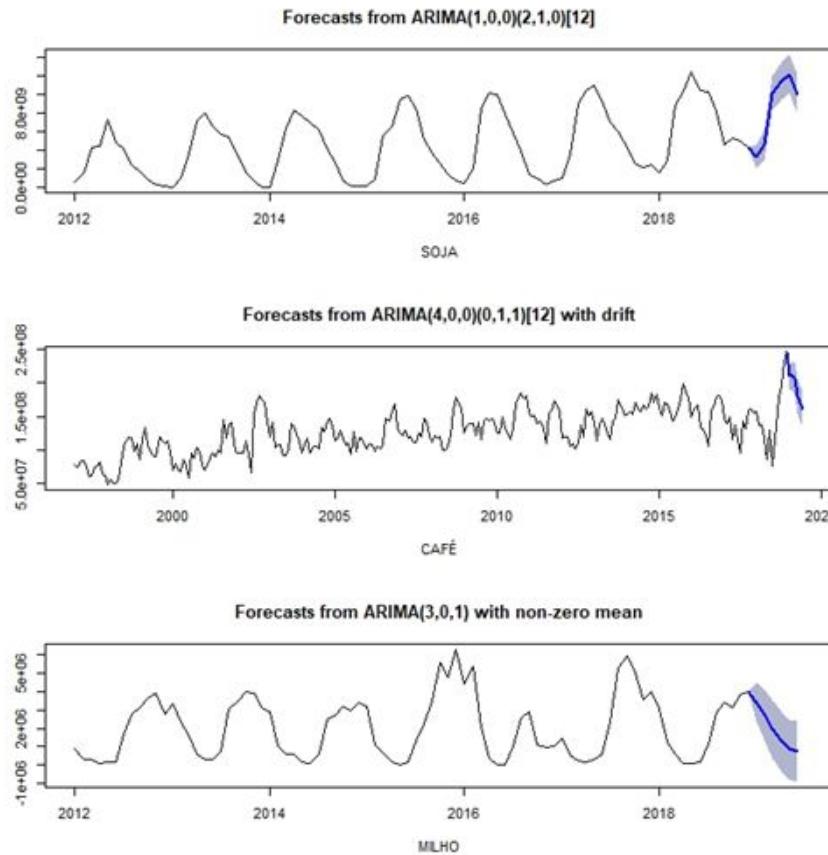


# Aplicações

HEY  
HO  
LET'S  
GO



# Agro XP Brazil - Solução



- **Proposta: Verificar qual é a previsão para os próximos 4 meses para cada um dos grãos**
- **E decidir em qual commodities iremos investir no 1º semestre/2019**
- **Utilizaremos técnicas de Séries Temporais**



# Agenda - Modelos Classificadores

1 – Introdução

2 – Preliminares

3 – Modelagem Descritiva

4 – Técnicas de Validação

5 – Algoritmos

6 – Aplicações



# Modelos Classificadores

1 – Introdução

2 – Preliminares

3 – Modelagem Descritiva

4 – Técnicas de Validação

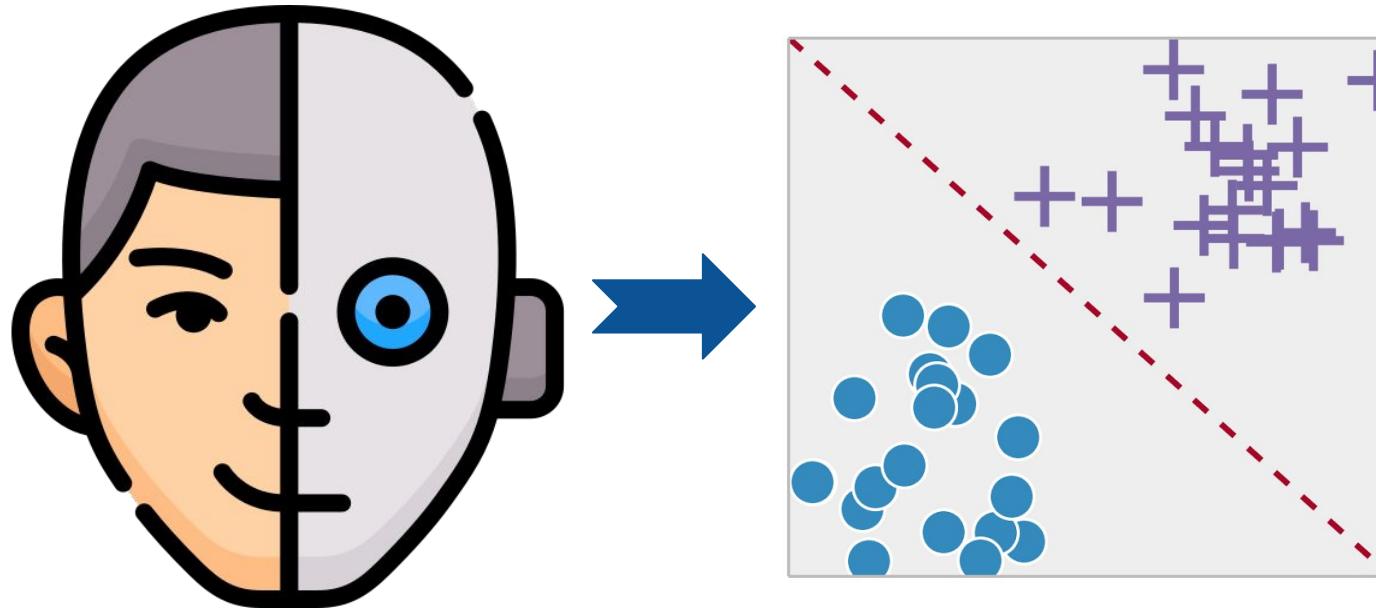
5 – Algoritmos

6 – Aplicações



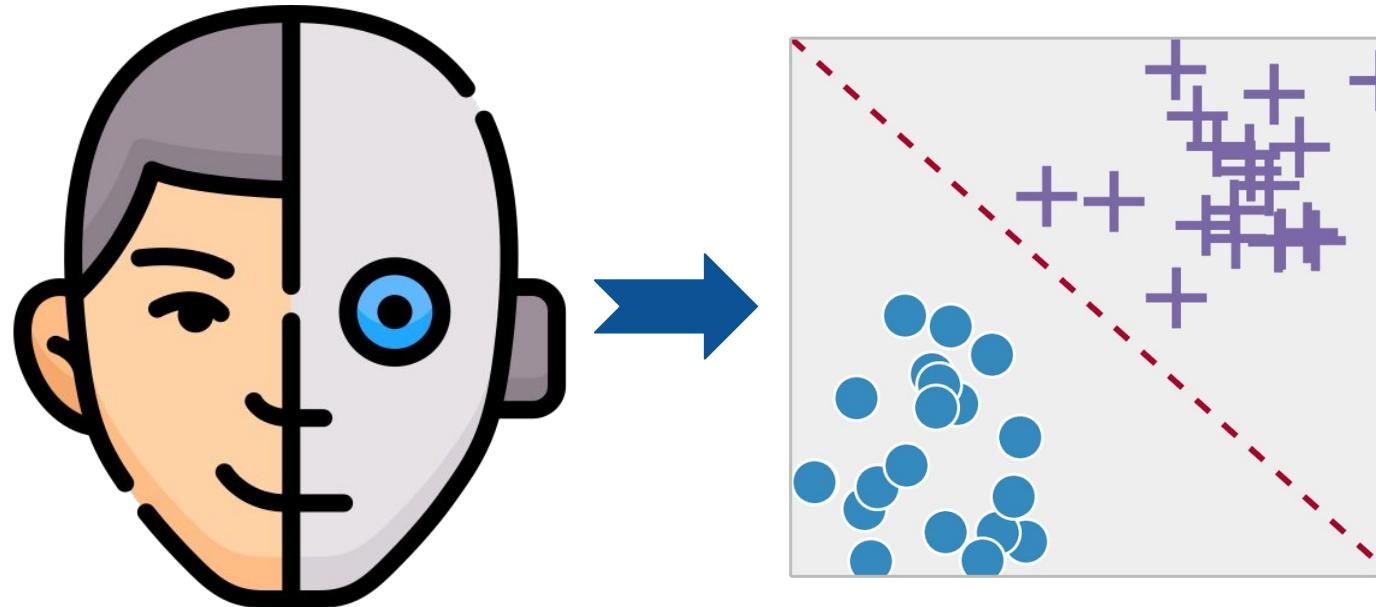
# Modelos Classificadores - Introdução

Os modelos de Classificação podem ser chamados também de Algoritmos de Reconhecimento de Padrões



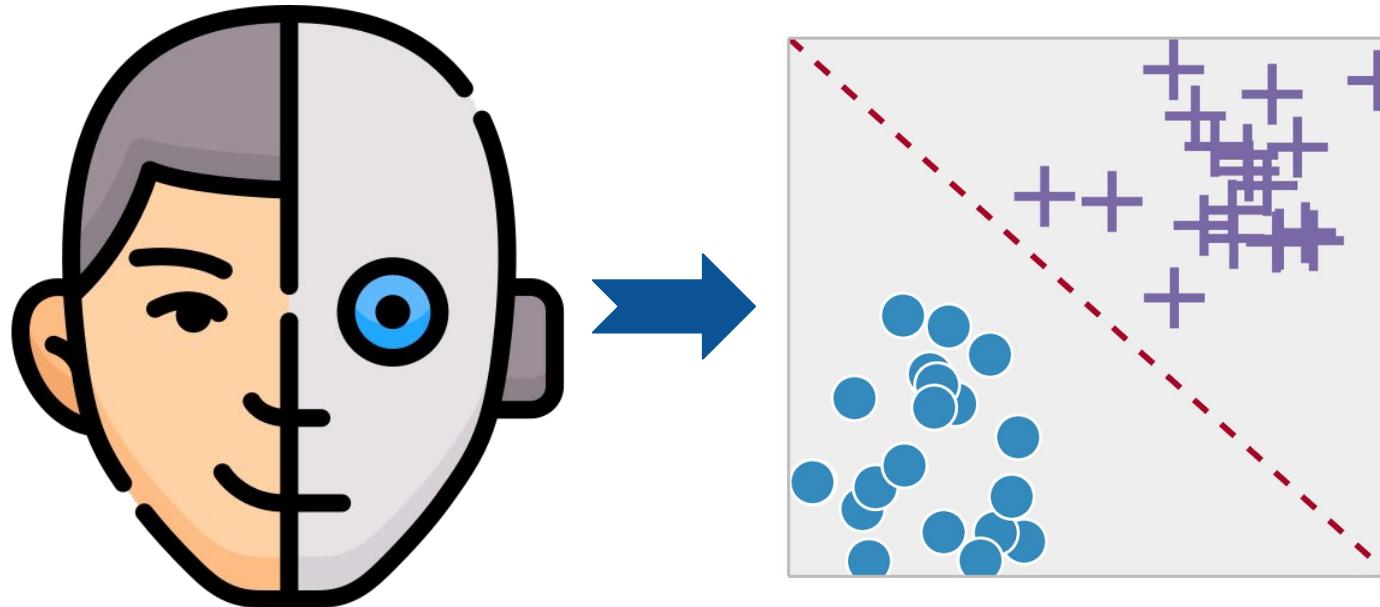
# Modelos Classificadores - Introdução

Classificação é a tarefa de organizar objetos em uma entre diversas categorias pré-definidas, é um problema universal que engloba muitas aplicações diferentes



# Modelos Classificadores - Introdução

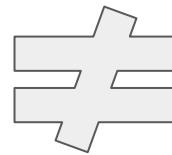
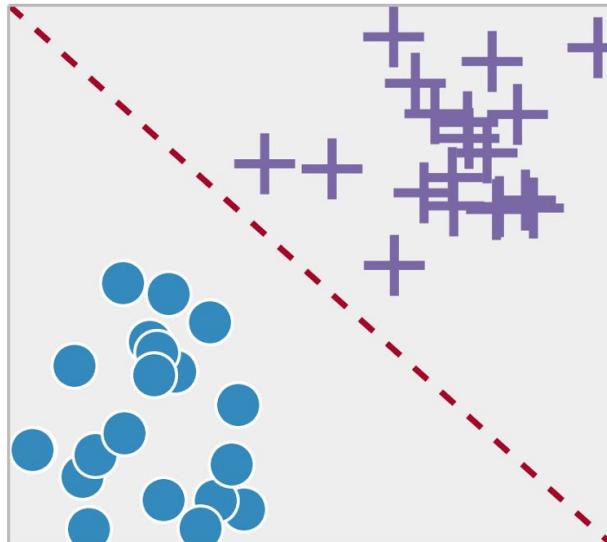
Exemplos de **classificação** incluem a **detecção** de mensagens de spam, **reconhecimento** de células como malignas ou benignas, **identificação** de objetos por veículo autônomo, etc



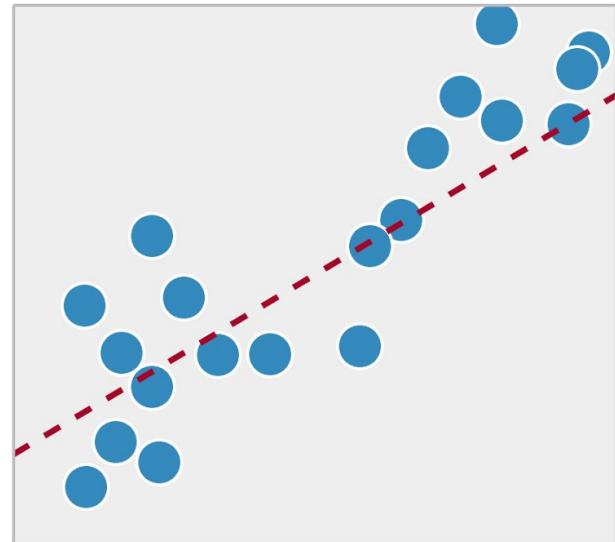
# Modelos Classificadores - Introdução

Diferença entre Modelos Classificadores e Preditivos:

Classificadores



Preditivos



# Modelos Classificadores - Introdução

**Modelos Classificadores são comumente:**

**Supervisionados?**

**Não Supervisionados?**



# Modelos Classificadores - Introdução

## Supervisionados!!!



# Modelos Classificadores

1 – Introdução

2 – Preliminares

3 – Modelagem Descritiva

4 – Técnicas de Validação

5 – Algoritmos

6 – Aplicações



# Modelos Classificadores - Preliminares

Os dados de entrada da tarefa de classificação são um conjunto de **registros**.

Cada registro também é conhecido como uma **instância** ou **exemplo**.

E são caracterizados por uma dupla **(x,y)**, onde **x** é o conjunto de **atributos** e **y** é o atributo **especial**, designado como rótulo da classe, também chamado de atributo **alvo** ou de **categorização**

# Modelos Classificadores - Preliminares

Os dados de entrada da tarefa de classificação são um conjunto de **registros**.

Cada registro também é conhecido como uma **instância** ou **exemplo**.

E são caracterizados por uma dupla  $(x,y)$ , onde **x** é o conjunto de **atributos** e **y** é o atributo **especial**, designado como rótulo da classe, também chamado de atributo **alvo** ou de **categorização**



# Modelos Classificadores - Preliminares

Os dados de entrada da tarefa de classificação são um conjunto de **registros**.

Cada registro também é conhecido como uma **instância** ou **exemplo**.

E são caracterizados por uma dupla **(x,y)**, onde **x** é o conjunto de **atributos** e **y** é o atributo **especial**, designado como **rótulo da classe**, também chamado de atributo **alvo** ou de **categorização**

# Modelos Classificadores - Preliminares

O rótulo de classe deve ser um atributo **discreto**, ou seja,  
**inteiro**

Esta é a característica chave que distingue a **classificação** da  
**regressão**, que é uma tarefa de modelagem preditiva na qual  
**y** é um atributo **contínuo**

Na aula anterior foi explicado sobre **modelos preditivos**

# Modelos Classificadores - Preliminares

O rótulo de classe deve ser um atributo **discreto**, ou seja,  
inteiro

Esta é a característica chave que distingue a **classificação** da  
**regressão**, que é uma tarefa de modelagem **preditiva** na qual  
**y** é um atributo **contínuo**

Na aula anterior foi explicado sobre **modelos preditivos**

# Modelos Classificadores - Preliminares

O rótulo de classe deve ser um atributo **discreto**, ou seja,  
**inteiro**

Esta é a característica chave que distingue a **classificação** da  
**regressão**, que é uma tarefa de modelagem **preditiva** na qual  
**y** é um atributo **contínuo**

Na aula anterior foi explicado sobre **modelos preditivos**



# Modelos Classificadores

1 – Introdução

2 – Preliminares

3 – Modelagem Descritiva

4 – Técnicas de Validação

5 – Algoritmos

6 – Aplicações



# Modelagem Descritiva

Um **modelo de classificação** que pode servir como ferramenta explicativa para se distinguir entre objetos e classes diferentes

Abordagem geral para resolução de um problema de classificação:

Uma técnica de classificação (ou classificadora) é uma abordagem sistemática para construção de modelos de classificação à partir de um conjunto de dados de entrada

# Modelagem Descritiva

Um modelo de classificação que pode servir como ferramenta explicativa para se distinguir entre objetos e classes diferentes

**Abordagem geral para resolução de um problema de classificação:**

Uma técnica de classificação (ou classificadora) é uma abordagem sistemática para construção de modelos de classificação à partir de um conjunto de dados de entrada

# Modelagem Descritiva

Um modelo de classificação que pode servir como ferramenta explicativa para se distinguir entre objetos e classes diferentes

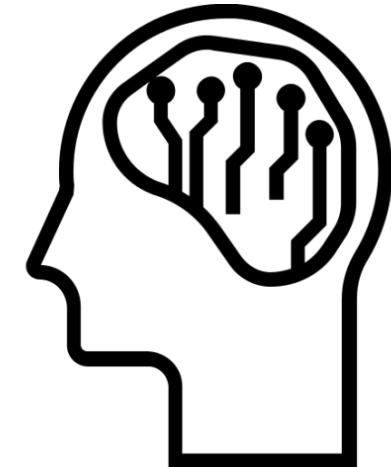
Abordagem geral para resolução de um problema de classificação:

Uma técnica de classificação (ou classificadora) é uma **abordagem sistemática** para construção de **modelos de classificação** à partir de um conjunto de dados de entrada

# Modelagem Descritiva

Exemplos incluem:

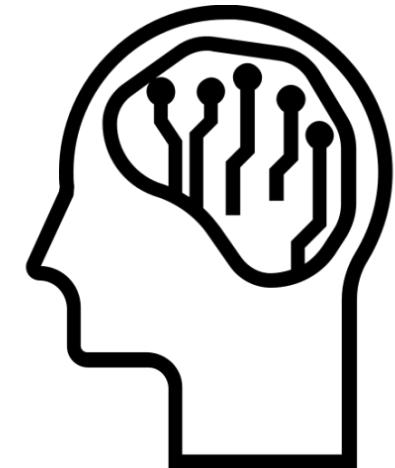
- **Classificadores de Árvore de Decisão**
- Classificadores baseados em regras:
  - Redes Neurais
  - Máquinas de Vetor de Suporte (SVM)
  - K-NN
- Classificadores baseados em Bayes



# Modelagem Descritiva

Exemplos incluem:

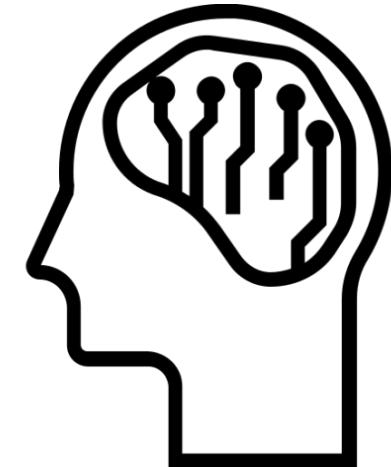
- Classificadores de Árvore de Decisão
- **Classificadores baseados em regras:**
  - Redes Neurais
  - Máquinas de Vetor de Suporte (SVM)
  - K-NN
- Classificadores baseados em Bayes



# Modelagem Descritiva

Exemplos incluem:

- Classificadores de Árvore de Decisão
- Classificadores baseados em regras:
  - Redes Neurais
  - Máquinas de Vetor de Suporte (SVM)
  - K-NN
- **Classificadores baseados em Bayes**



# Modelagem Descritiva

Cada técnica emprega um **algoritmo de aprendizagem** para identificar um modelo que seja mais apropriado para o relacionamento entre o **conjunto de atributos** e o **rótulo de entrada**

O modelo gerado pelo algoritmo de aprendizagem deve se adaptar bem aos dados de entrada e prever corretamente os rótulos de classes de registros que ainda não foram apresentados ao modelo

# Modelagem Descritiva

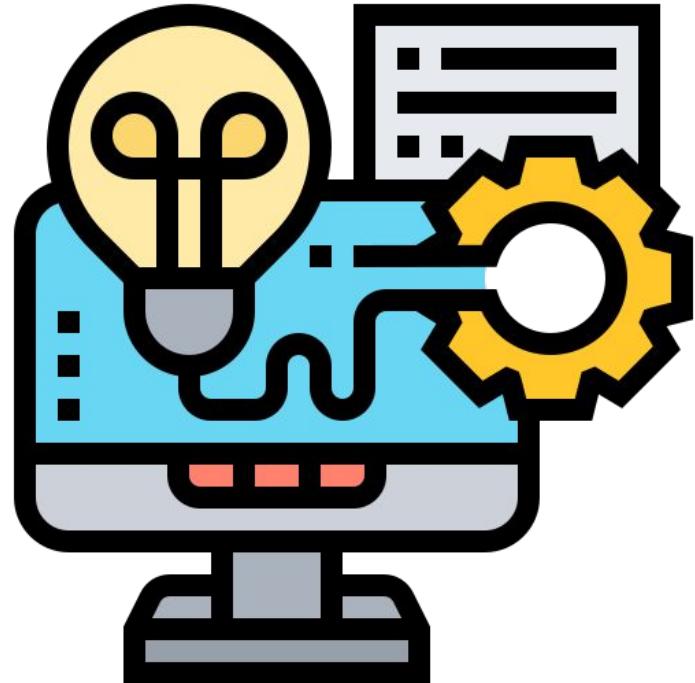
Cada técnica emprega um **algoritmo de aprendizagem** para identificar um modelo que seja mais apropriado para o relacionamento entre o **conjunto de atributos** e o **rótulo de entrada**

O **modelo** gerado pelo algoritmo de aprendizagem deve se adaptar bem aos dados de entrada e prever corretamente os rótulos de classes de registros que ainda não foram apresentados ao modelo

# Modelagem Descritiva

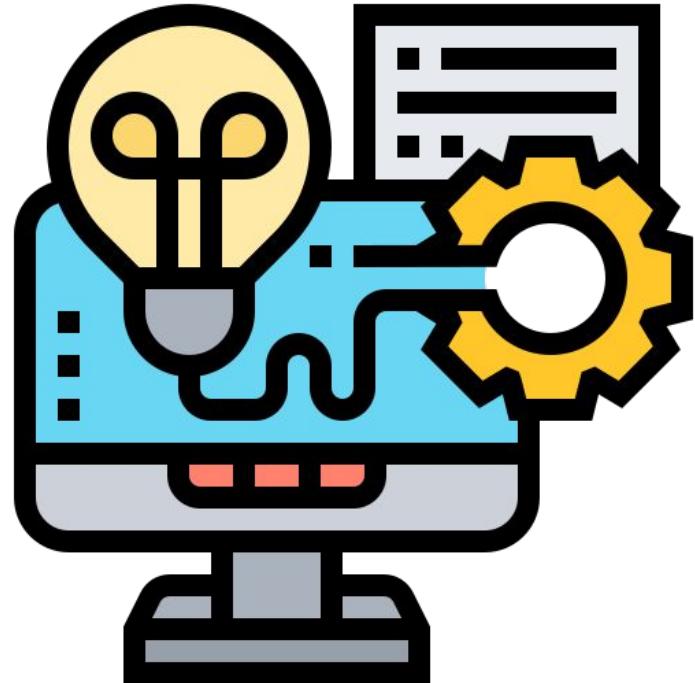
Ou seja, um bom modelo é  
aquele capaz de **generalizar**:

Que preveja com precisão os  
rótulos de classes de registros  
não conhecidos previamente



# Modelagem Descritiva

Ou seja, um bom modelo é aquele capaz de **generalizar**:  
Que preveja com precisão os rótulos de classes de registros não conhecidos previamente



# Modelos Classificadores

1 – Introdução

2 – Preliminares

3 – Modelagem Descritiva

4 – Técnicas de Validação

5 – Algoritmos

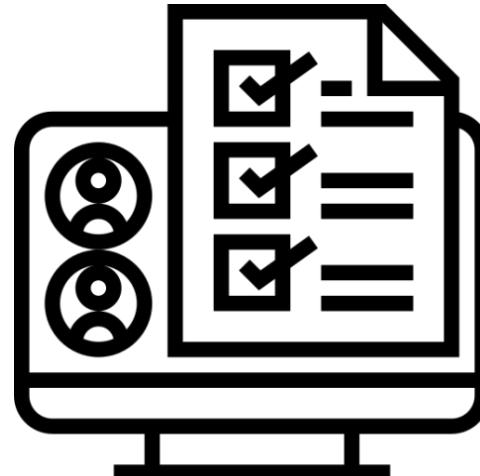
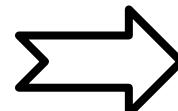
6 – Aplicações



# Modelagem Descritiva

## Teste & Treino

Conforme vimos anteriormente, após separar o conjunto como **treino e teste**, é importante validar os indicadores de acerto através da...



# Modelagem Descritiva

da...



# Modelagem Descritiva

da...

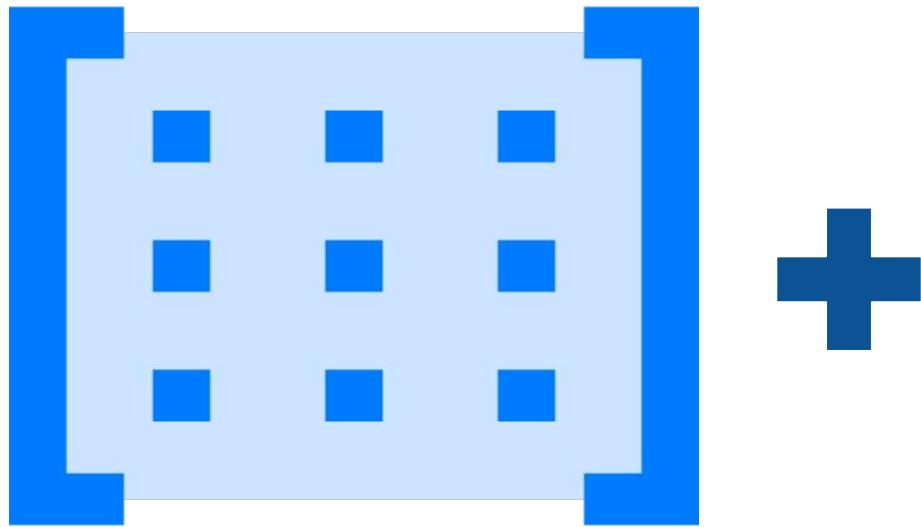


# Modelagem Descritiva



# Modelagem Descritiva

## Matriz de Confusão



## Matriz de Confusão

Após treinar o algoritmo e fazer a validação com o conjunto de teste, a avaliação de desempenho será baseada nas contagens de registros de **testes previstos correta e incorrectamente pelo modelo**

Estas contagens são tabeladas em uma tabela conhecida por  
**Matriz de Confusão**

# Modelagem Descritiva

## Matriz de Confusão

Após treinar o algoritmo e fazer a validação com o conjunto de teste, a avaliação de desempenho será baseada nas contagens de registros de testes previstos correta e incorrectamente pelo modelo

Estas contagens são tabeladas em uma tabela conhecida por  
**Matriz de Confusão**

# Modelagem Descritiva

## Exemplo Matriz de Confusão Binária

		Classe Prevista	
		Classe = 1	Classe = 0
Classe Real	Classe = 1	$f_{11}$	$f_{10}$
	Classe = 0	$f_{01}$	$f_{00}$

Cada entrada  $f_{ij}$  denota o número de registros da Classe 0 previstos incorretamente como da Classe 1

Baseado nas entradas da matriz de confusão, o número de total de previsões corretas feitas pelo modelo é ( $f_{11} + f_{00}$ ) e o número total de erros é ( $f_{01} + f_{01}$ )



# Modelagem Descritiva

## Exemplo Matriz de Confusão Binária

		Classe Prevista	
		Classe = 1	Classe = 0
Classe Real	Classe = 1	$f_{11}$	$f_{10}$
	Classe = 0	$f_{01}$	$f_{00}$

Cada entrada  $f_{ij}$  denota o número de registros da Classe 0 previstos incorretamente como da Classe 1

Baseado nas entradas da matriz de confusão, o número de total de previsões corretas feitas pelo modelo é ( $f_{11} + f_{00}$ ) e o número total de erros é ( $f_{01} + f_{01}$ )



# Modelagem Descritiva

## Exemplo Matriz de Confusão Binária

		Classe Prevista	
		Classe = 1	Classe = 0
Classe Real	Classe = 1	$f_{11}$	$f_{10}$
	Classe = 0	$f_{01}$	$f_{00}$

Cada entrada  $f_{ij}$  denota o número de registros da Classe 0 previstos incorretamente como da Classe 1

Baseado nas entradas da matriz de confusão, o número de total de **previsões corretas** feitas pelo modelo é ( $f_{11} + f_{00}$ ) e o **número total de erros** é ( $f_{01} + f_{10}$ )



# Modelagem Descritiva

Com base nesta Matriz com estas informações consegue-se calcular as seguintes métricas de desempenho:

## Precisão:

$$\text{Precisão} = \frac{\text{Número de Previsões Corretas}}{\text{Número Total de Previsões}} = \frac{f_{11} + f_{00}}{f_{11} + f_{00} + f_{10} + f_{01}}$$

# Modelagem Descritiva

Com base nesta Matriz com estas informações consegue-se calcular as seguintes métricas de desempenho:

## Taxa de Erro:

$$\text{Taxa de Erro} = \frac{\text{Número de Previsões Erradas}}{\text{Número Total de Previsões}} = \frac{f_{10} + f_{01}}{f_{11} + f_{00} + f_{10} + f_{01}}$$

# Modelos Classificadores

1 – Introdução

2 – Preliminares

3 – Modelagem Descritiva

4 – Técnicas de Validação

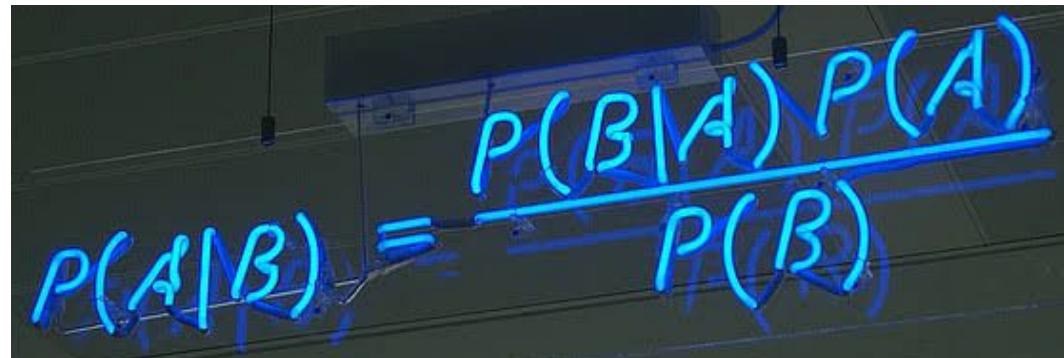
5 – Algoritmos

6 – Aplicações



# Algoritmos - Classificador Naive Bayes

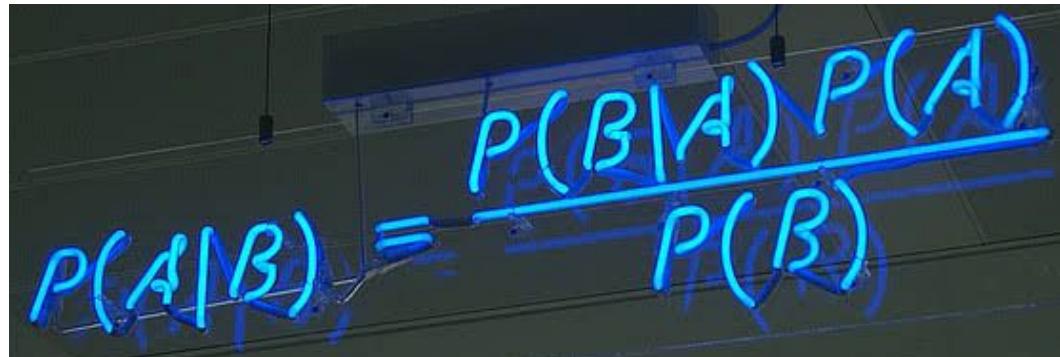
É uma técnica de classificação baseado no teorema de **Bayes** com uma suposição de independência entre os preditores


$$P(A|B) = \frac{P(B|A)P(A)}{P(B)}$$

Em termos simples, um **classificador Naive Bayes** assume que a presença de uma característica particular em uma classe não está relacionada com a presença de qualquer outro recurso

# Algoritmos - Classificador Naive Bayes

É uma técnica de classificação baseado no teorema de Bayes com uma suposição de independência entre os preditores


$$P(A|B) = \frac{P(B|A)P(A)}{P(B)}$$

Em termos simples, um **classificador Naive Bayes** assume que a presença de uma característica particular em uma classe não está relacionada com a presença de qualquer outro recurso

# Algoritmos - Classificador Naive Bayes

Por exemplo, um fruto pode ser considerado como uma **maçã** se é **vermelho, redondo**, e tiver cerca de **3 polegadas de diâmetro**

Mesmo que esses recursos dependam uns dos outros ou da existência de outras características, todas estas propriedades contribuem de forma independente para a probabilidade de que este fruto é uma maçã e é por isso que é conhecido como ‘Naive’ (ingênuo)

# Algoritmos - Classificador Naive Bayes

Por exemplo, um fruto pode ser considerado como uma maçã se é vermelho, redondo, e tiver cerca de 3 polegadas de diâmetro

Mesmo que esses recursos dependam uns dos outros ou da existência de outras características, todas estas propriedades contribuem de forma independente para a probabilidade de que este **fruto é uma maçã** e é por isso que é conhecido como '**Naive**' (ingênuo)

# Algoritmos - Classificador Naive Bayes

O modelo Naive Bayes é **fácil** de construir e particularmente útil para grandes volumes de dados

Além de simples, Naive Bayes é conhecido por ganhar de métodos de classificação altamente sofisticados

Teorema de Bayes fornece uma forma de calcular a probabilidade posterior  $P(c|x)$  a partir de  $P(c)$ ,  $P(x)$  e  $P(x|c)$

# Algoritmos - Classificador Naive Bayes

O modelo Naive Bayes é fácil de construir e particularmente útil para grandes volumes de dados

Além de simples, Naive Bayes é conhecido por ganhar de métodos de **classificação altamente sofisticados**

Teorema de Bayes fornece uma forma de calcular a probabilidade posterior  $P(c|x)$  a partir de  $P(c)$ ,  $P(x)$  e  $P(x|c)$



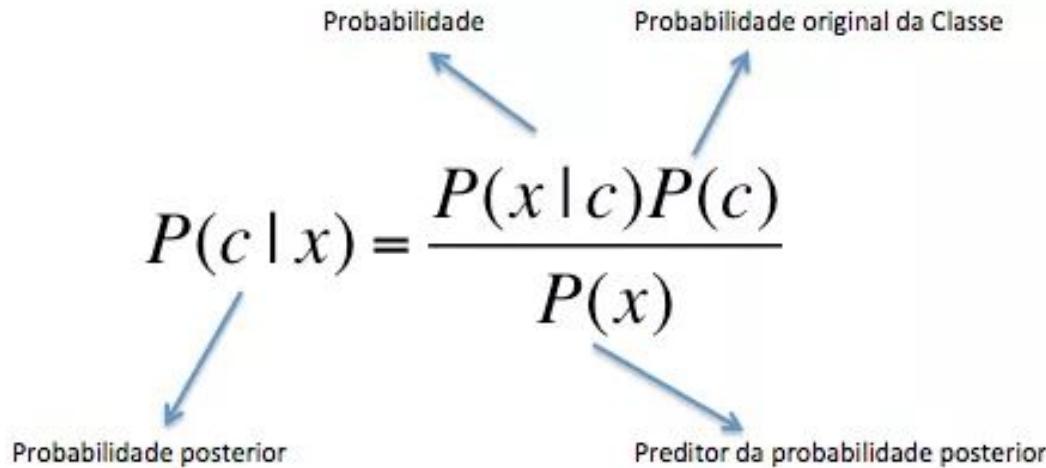
# Algoritmos - Classificador Naive Bayes

O modelo Naive Bayes é fácil de construir e particularmente útil para grandes volumes de dados

Além de simples, Naive Bayes é conhecido por ganhar de métodos de classificação altamente sofisticados

Teorema de Bayes fornece uma forma de calcular a probabilidade posterior  $P(c|x)$  a partir de  $P(c)$ ,  $P(x)$  e  $P(x|c)$

# Algoritmos - Classificador Naive Bayes

$$P(c|x) = \frac{P(x|c)P(c)}{P(x)}$$


The diagram shows the formula for the posterior probability  $P(c|x)$ . It consists of two main parts: the numerator  $P(x|c)P(c)$  and the denominator  $P(x)$ . The numerator is labeled with 'Probabilidade' above it and 'Probabilidade original da Classe' to its right. The denominator is labeled with 'Probabilidade posterior' below it and 'Preditor da probabilidade posterior' to its right. Blue arrows indicate the flow of information from these labels into the respective terms of the formula.

- **$P(c|x)$  é a probabilidade posterior da classe (c, alvo) dada predictor (x, atributos)**
- $P(c)$  é a probabilidade original da classe
- $P(x|c)$  é a probabilidade que representa a probabilidade de predictor dada a classe
- $P(x)$  é a probabilidade original do predictor

# Algoritmos - Classificador Naive Bayes

$$P(c|x) = \frac{P(x|c)P(c)}{P(x)}$$

Probabilidade  
Probabilidade original da Classe  
Probabilidade posterior  
Preditor da probabilidade posterior

- **P (c | x)** é a **probabilidade posterior da classe (c, alvo) dada preditor (x, atributos)**
- **P (c)** é a **probabilidade original da classe**
- **P (x | c)** é a **probabilidade que representa a probabilidade de preditor dada a classe**
- **P (x)** é a **probabilidade original do preditor**

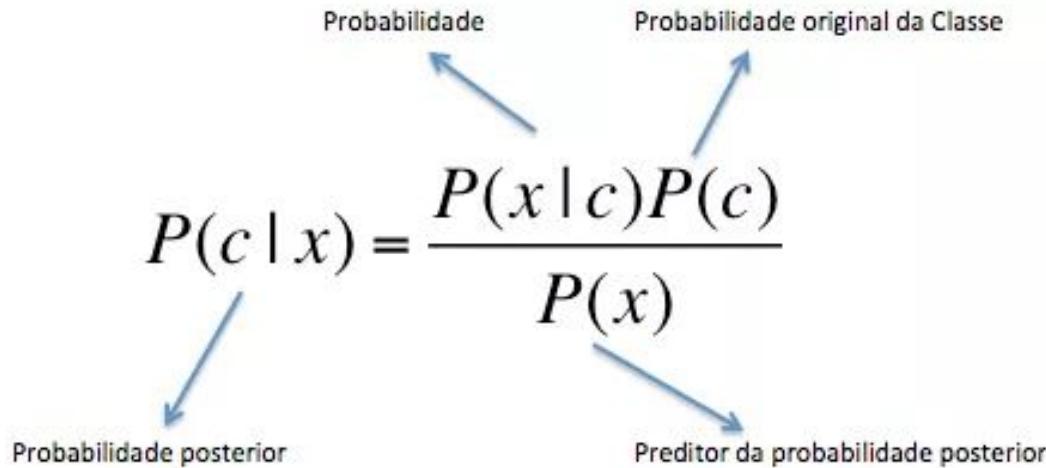
# Algoritmos - Classificador Naive Bayes

$$P(c|x) = \frac{P(x|c)P(c)}{P(x)}$$

Probabilidade  
Probabilidade original da Classe  
Probabilidade posterior  
Preditor da probabilidade posterior

- $P(c|x)$  é a **probabilidade posterior da classe (c, alvo) dada predictor (x, atributos)**
- $P(c)$  é a **probabilidade original da classe**
- $P(x|c)$  é a **probabilidade que representa a probabilidade de predictor dada a classe**
- $P(x)$  é a **probabilidade original do predictor**

# Algoritmos - Classificador Naive Bayes

$$P(c|x) = \frac{P(x|c)P(c)}{P(x)}$$


The diagram shows the formula  $P(c|x) = \frac{P(x|c)P(c)}{P(x)}$ . Four arrows originate from text labels above and below the formula and point to specific terms: 'Probabilidade' points to  $P(x|c)$ , 'Probabilidade original da Classe' points to  $P(c)$ , 'Probabilidade posterior' points to the entire numerator  $P(x|c)P(c)$ , and 'Preditor da probabilidade posterior' points to the denominator  $P(x)$ .

- $P(c|x)$  é a probabilidade posterior da classe (c, alvo) dada predictor (x, atributos)
- $P(c)$  é a probabilidade original da classe
- $P(x|c)$  é a probabilidade que representa a probabilidade de predictor dada a classe
- $P(x)$  é a probabilidade original do predictor

# Algoritmos - Classificador Naive Bayes

À seguir um conjunto de dados de treinamento de clima e da correspondente variável-alvo “Jogo” (sugerindo possibilidades de jogar)

Agora, precisa-se classificar se os jogadores **vão jogar ou não** com base na **condição meteorológica**

Bastam fazer os passos abaixo para realizar a operação

# Algoritmos - Classificador Naive Bayes

À seguir um conjunto de dados de treinamento de clima e da correspondente variável-alvo “Jogo” (sugerindo possibilidades de jogar)

Agora, precisa-se classificar se os jogadores **vão jogar ou não** com base na **condição meteorológica**

Bastam fazer os passos abaixo para realizar a operação

# Algoritmos - Classificador Naive Bayes

À seguir um conjunto de dados de treinamento de clima e da correspondente variável-alvo “Jogo” (sugerindo possibilidades de jogar)

Agora, precisa-se classificar se os jogadores **vão jogar ou não** com base na **condição meteorológica**

Bastam fazer os passos abaixo para realizar a operação

# Algoritmos - Classificador Naive Bayes

Tabela com as  
informações rotuladas  
sobre Tempo e Jogo

TEMPO	JOGO
Sol	Não
Nublado	Sim
Chuva	Sim
Sol	Sim
Sol	Sim
Nublado	Sim
Chuva	Não
Chuva	Não
Sol	Sim
Chuva	Sim
Sol	Não
Nublado	Sim
Nublado	Sim
Chuva	Não

# Algoritmos - Classificador Naive Bayes

**Passo 1:** Converter o conjunto de dados em uma tabela de frequência

**Passo 2:** Criar tabela de Probabilidade ao encontrar as probabilidades de tempo Nublado = 0,29 e probabilidade de jogar = 0,64

Tabela de Probabilidade		
Clima	Não	Sim
<b>Nublado</b>	0	4
<b>Sol</b>	2	3
<b>Chuva</b>	3	2
<b>Total</b>	5	9

# Algoritmos - Classificador Naive Bayes

Passo 1: Converter o conjunto de dados em uma tabela de frequência

Passo 2: Criar tabela de Probabilidade ao encontrar as probabilidades de tempo  
Nublado = 0,29 e probabilidade de Jogo = 0,64

Tabela de Probabilidade

Clima	Não	Sim		
Nublado	0	4	=4/14	0,286
Sol	2	3	=5/14	0,357
Chuva	3	2	=5/14	0,357
Total	5	9		
	=5/14	=9/14		
	0,357	0,643		

# Algoritmos - Classificador Naive Bayes

**Passo 1:** Converter o conjunto de dados em uma tabela de frequência

**Passo 2:** Criar tabela de Probabilidade ao encontrar as probabilidades de tempo Nublado = 0,29 e probabilidade de Jogo = 0,64

**Passo 3:** Utilizar a equação Bayesiana Naive para calcular a probabilidade posterior para cada classe

# Algoritmos - Classificador Naive Bayes

**Problema:** Os jogadores irão jogar se o tempo estiver ensolarado.  
Esta afirmação está correta?

$$P(\text{Sim} | \text{Ensolarado}) = P(\text{Ensolarado} | \text{Sim}) * P(\text{Sim}) / P(\text{Ensolarado})$$

1.  $P(\text{Ensolarado} | \text{Sim}) = 3/9 = 0,33$ , => À priori
2.  $P(\text{Ensolarado}) = 5/14 = 0,36$ ,
3.  $P(\text{Sim}) = 9/14 = 0,64$

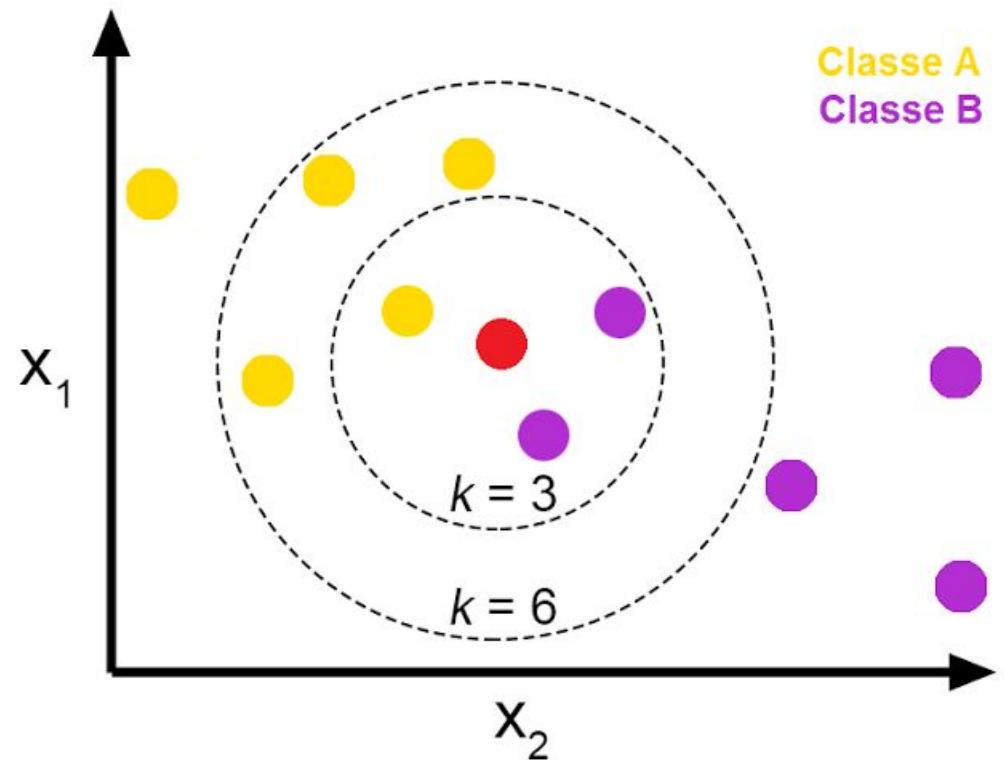
$$P(\text{Sim} | \text{Ensolarado}) = 0,33 * 0,64 / 0,36 = 0,60, \text{ que tem maior probabilidade.}$$



# K-Nearest Neighbor ou K-Vizinhos mais Próximos

O algoritmo K-NN segue o seguinte ditado à risca:

*“Se caminhar como um pato, se grasnar como um pato e se parecer como um pato, então provavelmente é um pato”*



# K-Nearest Neighbor ou K-Vizinhos mais Próximos

Um classificador de **vizinho mais próximo** representa cada exemplo como um ponto de dado num espaço  $d$ -dimensional, onde  $d$  é o número de atributos

Dado um exemplo de teste, calcula-se sua proximidade com o resto dos pontos de dados no conjunto de treinamento, usando uma das medidas de proximidade

A proximidade entre dois objetos é uma função da proximidade entre os atributos correspondentes entre dois objetos, que podem ser **semelhantes ou diferentes**



# K-Nearest Neighbor ou K-Vizinhos mais Próximos

Um classificador de vizinho mais próximo representa cada exemplo como um ponto de dado num espaço  $d$ -dimensional, onde  $d$  é o número de atributos

Dado um exemplo de teste, calcula-se sua proximidade com o resto dos pontos de dados no conjunto de treinamento, usando uma das medidas de proximidade

A proximidade entre dois objetos é uma função da proximidade entre os atributos correspondentes entre dois objetos, que podem ser semelhantes ou diferentes



# K-Nearest Neighbor ou K-Vizinhos mais Próximos

Um classificador de vizinho mais próximo representa cada exemplo como um ponto de dado num espaço  $d$ -dimensional, onde  $d$  é o número de atributos

Dado um exemplo de teste, calcula-se sua proximidade com o resto dos pontos de dados no conjunto de treinamento, usando uma das medidas de proximidade

**A proximidade entre dois objetos** é uma função da proximidade entre os atributos correspondentes entre dois objetos, que podem ser **semelhantes ou diferentes**



# K-Nearest Neighbor ou K-Vizinhos mais Próximos

Os vizinhos mais próximos  $k$  de um determinado exemplo  $z$  se referem aos  $k$  pontos que sejam mais próximos de  $z$

O ponto de dados é classificado com base nos rótulos de classe dos seus vizinhos

No caso onde os vizinhos têm mais de um rótulo, o ponto dado é atribuído à classe majoritária dos seus vizinhos mais próximos



# K-Nearest Neighbor ou K-Vizinhos mais Próximos

Os vizinhos mais próximos  $k$  de um determinado exemplo  $z$  se referem aos  $k$  pontos que sejam mais próximos de  $z$

O ponto de dados é classificado com base nos rótulos de classe dos seus vizinhos

No caso onde os vizinhos têm mais de um rótulo, o ponto dado é atribuído à classe majoritária dos seus vizinhos mais próximos

# K-Nearest Neighbor ou K-Vizinhos mais Próximos

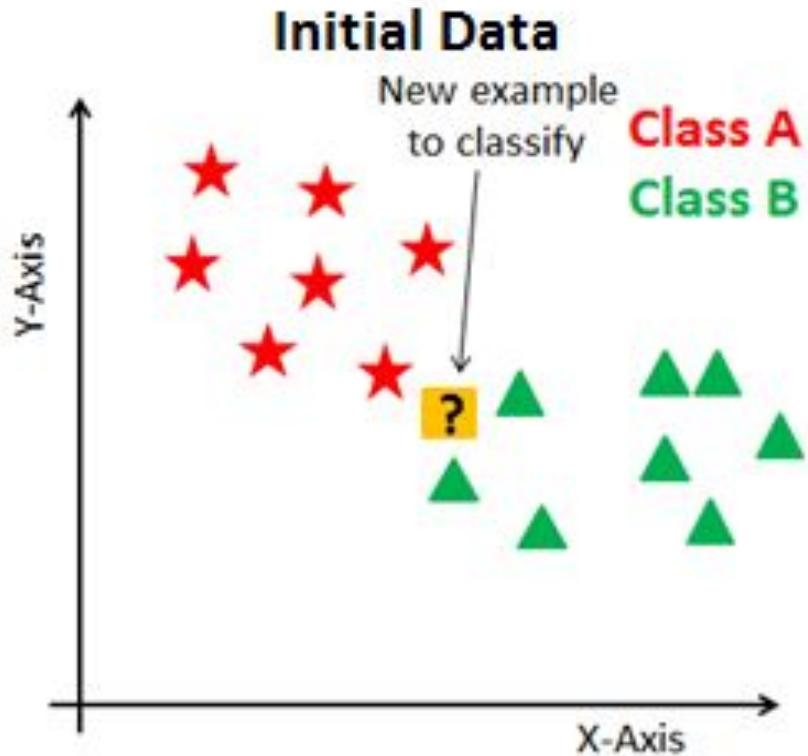
Os vizinhos mais próximos  $k$  de um determinado exemplo  $z$  se referem aos  $k$  pontos que sejam mais próximos de  $z$

O ponto de dados é classificado com base nos rótulos de classe dos seus vizinhos

No caso onde os vizinhos têm mais de um rótulo, o ponto dado é atribuído à classe majoritária dos seus vizinhos mais próximos

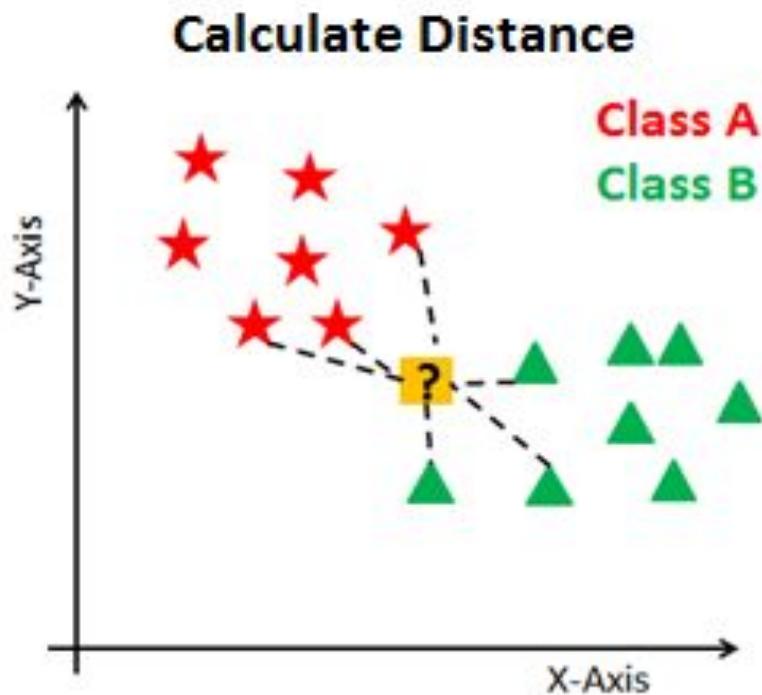
# K-Nearest Neighbor ou K-Vizinhos mais Próximos

Exemplo Gráfico:



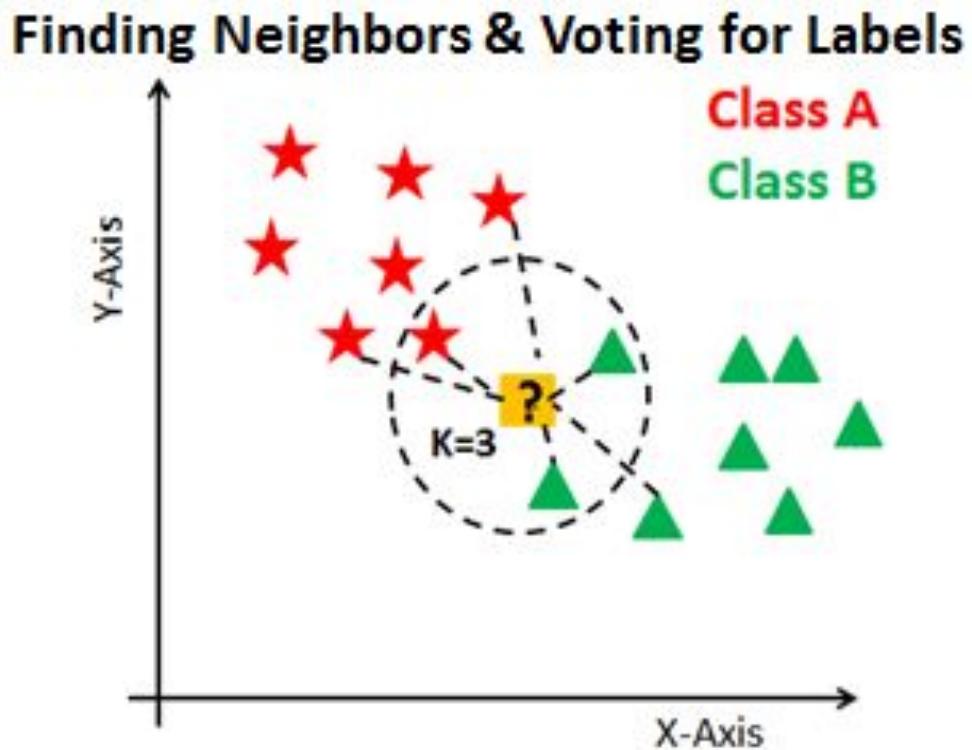
# K-Nearest Neighbor ou K-Vizinhos mais Próximos

Exemplo Gráfico:



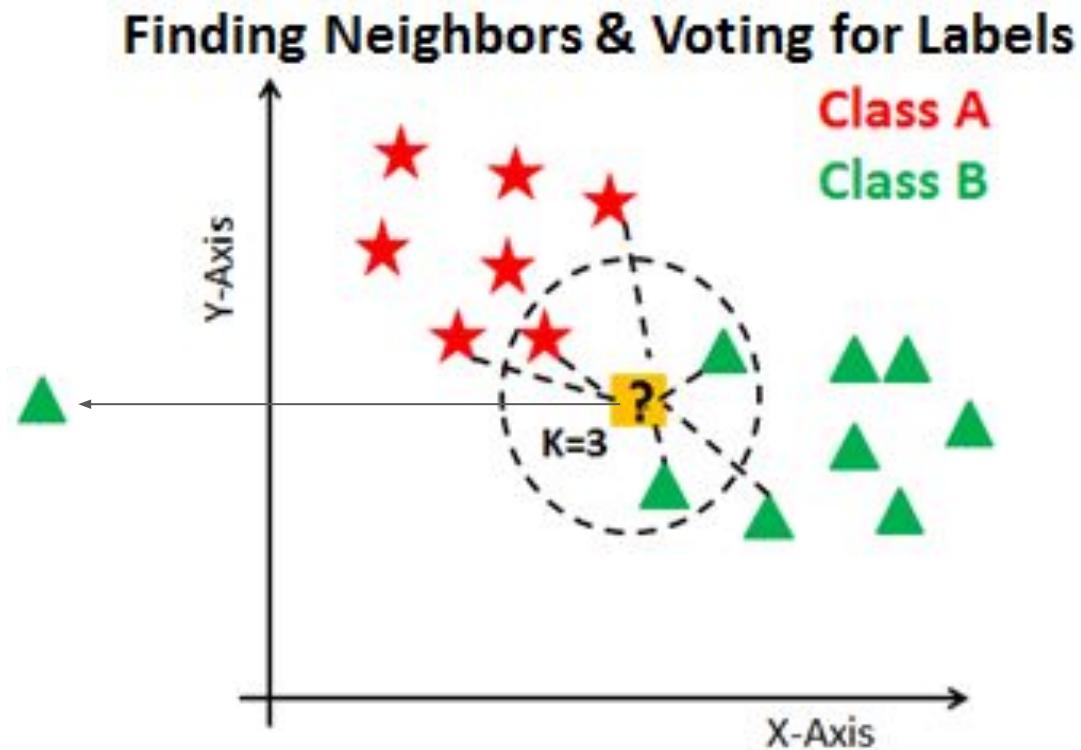
# K-Nearest Neighbor ou K-Vizinhos mais Próximos

Exemplo Gráfico:



# K-Nearest Neighbor ou K-Vizinhos mais Próximos

Exemplo Gráfico:



# SVM - Support Vector Machine

**Máquinas de Vetores de Suporte ou SVM é uma técnica de classificação que possui seus fundamentos na teoria de aprendizagem estatística**

É capaz de mostrar resultados empíricos promissores em muitas aplicações práticas

Este algoritmo funciona muito bem também para com dados de **alta dimensionalidade**, evitando assim o problema da dimensionalidade

Podem ser utilizados para separações **Lineares e Não Lineares**



# SVM - Support Vector Machine

Máquinas de Vetores de Suporte ou SVM é uma técnica de classificação que possui seus fundamentos na teoria de aprendizagem estatística

É capaz de mostrar resultados **empíricos** promissores em muitas aplicações práticas

Este algoritmo funciona muito bem também para com dados de **alta dimensionalidade**, evitando assim o problema da dimensionalidade

Podem ser utilizados para separações **Lineares e Não Lineares**



# SVM - Support Vector Machine

Máquinas de Vetores de Suporte ou SVM é uma técnica de classificação que possui seus fundamentos na teoria de aprendizagem estatística

É capaz de mostrar resultados **empíricos** promissores em muitas aplicações práticas

Este algoritmo funciona muito bem também para com dados de **alta dimensionalidade**, evitando assim o problema da dimensionalidade

Podem ser utilizados para separações Lineares e Não Lineares



# SVM - Support Vector Machine

Máquinas de Vetores de Suporte ou SVM é uma técnica de classificação que possui seus fundamentos na teoria de aprendizagem estatística

É capaz de mostrar resultados **empíricos** promissores em muitas aplicações práticas

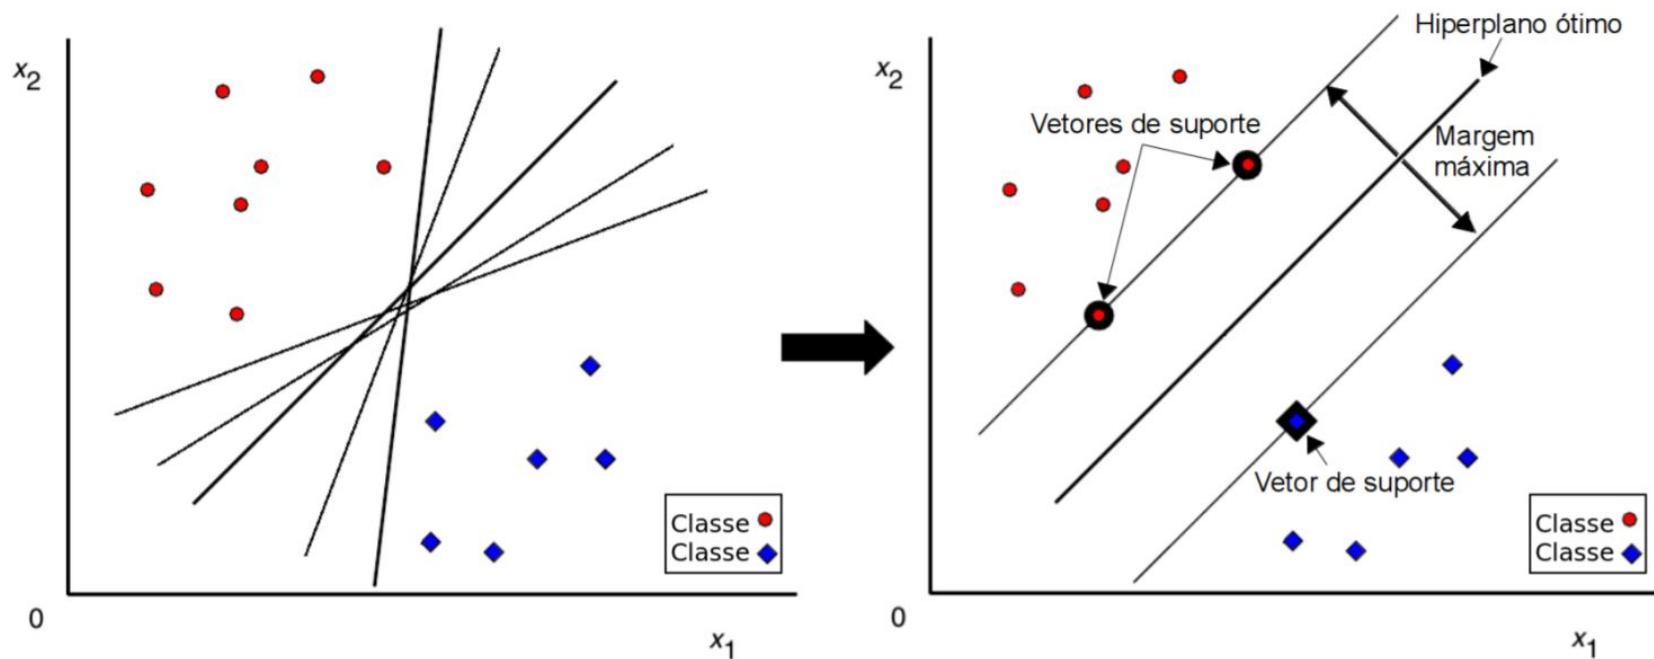
Este algoritmo funciona muito bem também para com dados de **alta dimensionalidade**, evitando assim o problema da dimensionalidade

Podem ser utilizados para separações **Lineares e Não Lineares**



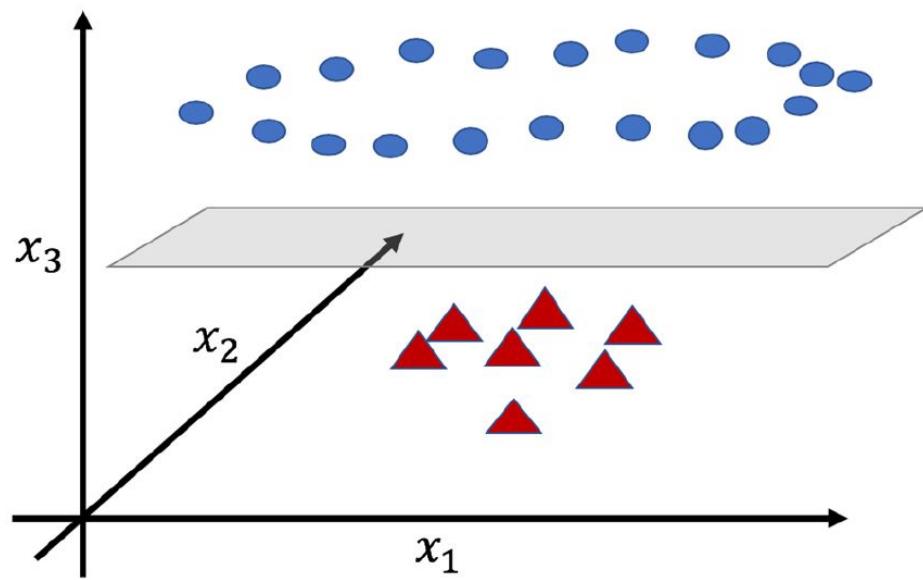
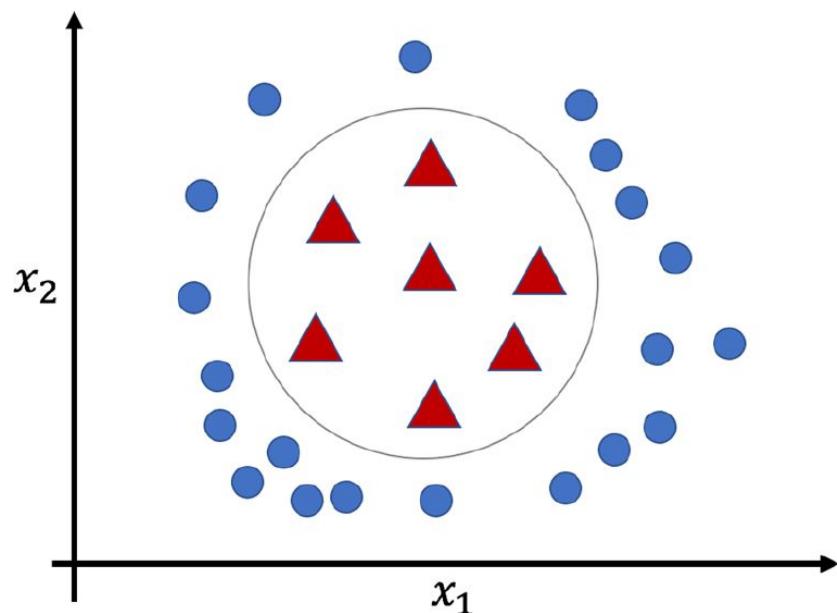
# SVM - Support Vector Machine

## Como Funciona:



# SVM - Support Vector Machine

E quando necessário o SVM coloca os dados em **outra dimensão** para que eles se tornem separáveis:

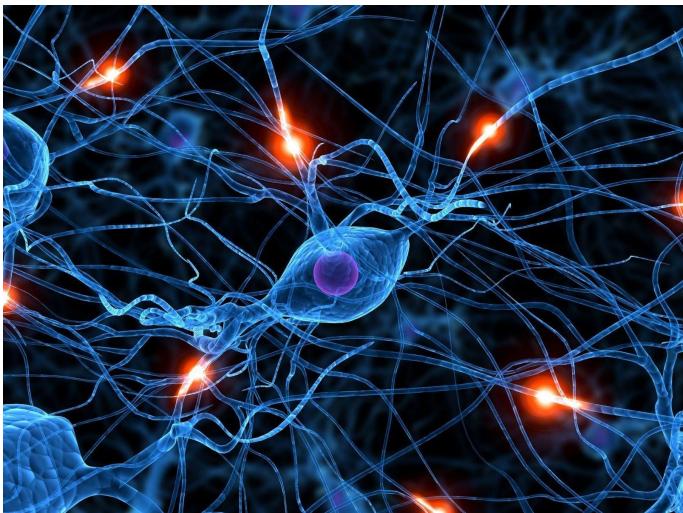


# Rede Neural Artificial

O estudo de Redes Neurais Artificiais foi inspirado em tentativas de simular sistemas neurais biológicos

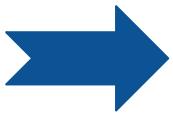
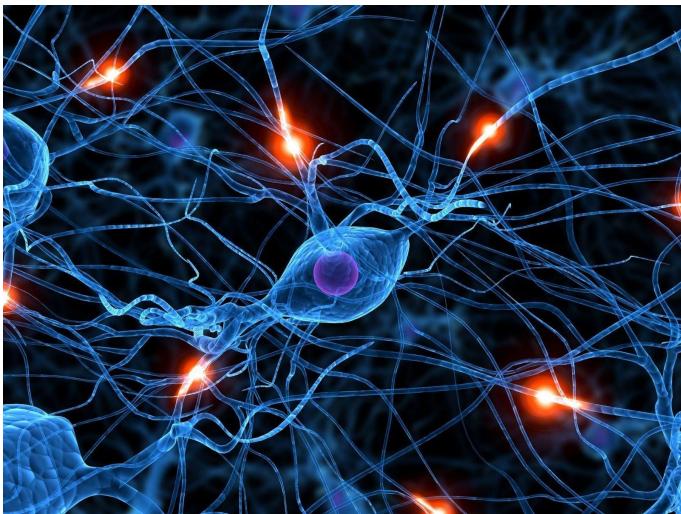
# Rede Neural Artificial

O estudo de Redes Neurais Artificiais foi inspirado em tentativas de simular sistemas neurais biológicos



# Rede Neural Artificial

O estudo de Redes Neurais Artificiais foi inspirado em tentativas de simular sistemas neurais biológicos



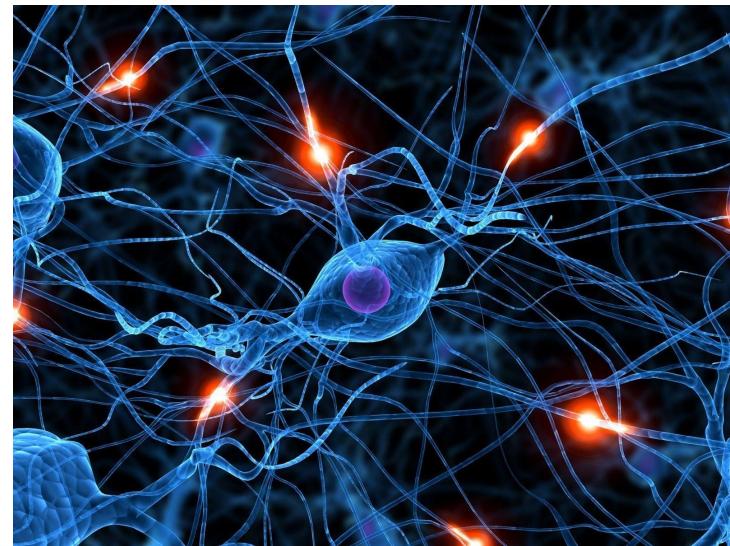
# Rede Neural Artificial

O estudo de Redes Neurais Artificiais foi inspirado em tentativas de simular sistemas neurais biológicos



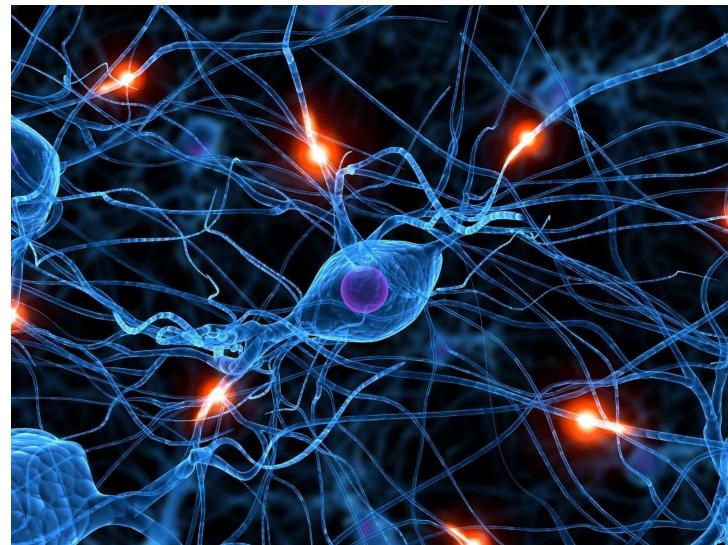
# Rede Neural Artificial

- O cérebro humano consiste principalmente de células nervosas chamadas **neurônios**
- São ligados entre si através de fios de fibra chamados **axônios**
- Estes transmitem os impulsos nervosos quando o neurônio é estimulado
- Os **dendritos** conectam os neurônios
- A **sinapse** é o ponto de contato entre dendrito e um axônio



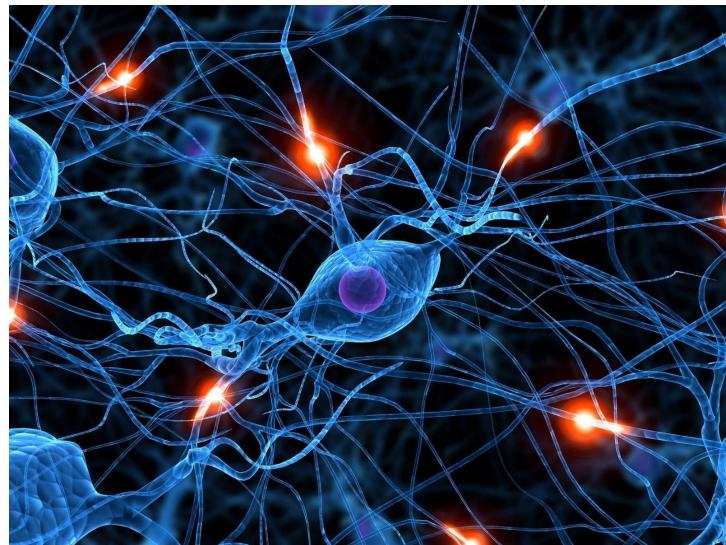
# Rede Neural Artificial

- O cérebro humano consiste principalmente de células nervosas chamadas **neurônios**
- São ligados entre si através de fios de fibra chamados **axônios**
- Estes transmitem os impulsos nervosos quando o neurônio é estimulado
- Os **dendritos** conectam os neurônios
- A **sinapse** é o ponto de contato entre dendrito e um axônio



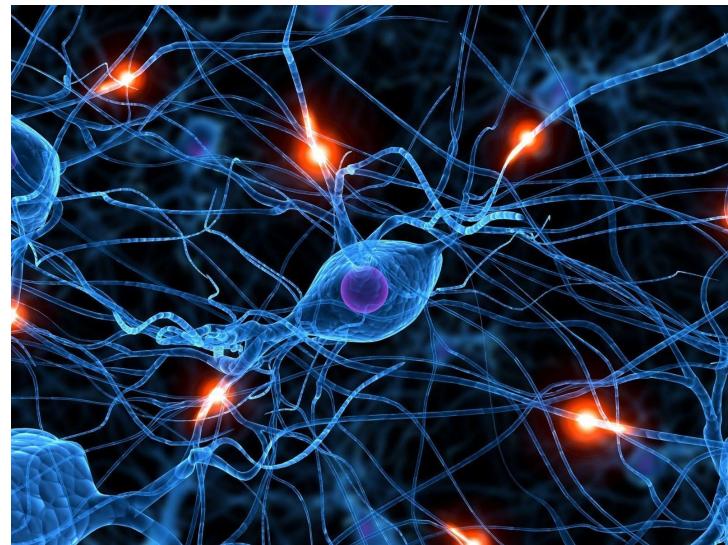
# Rede Neural Artificial

- O cérebro humano consiste principalmente de células nervosas chamadas **neurônios**
- São ligados entre si através de fios de fibra chamados **axônios**
- Estes transmitem os impulsos nervosos quando o neurônio é estimulado
- Os **dendritos** conectam os neurônios
- A **sinapse** é o ponto de contato entre dendrito e um axônio



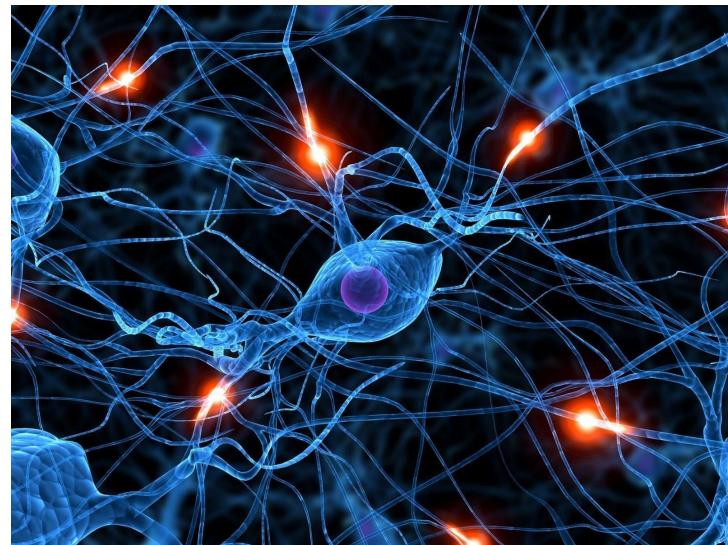
# Rede Neural Artificial

- O cérebro humano consiste principalmente de células nervosas chamadas **neurônios**
- São ligados entre si através de fios de fibra chamados **axônios**
- Estes transmitem os impulsos nervosos quando o neurônio é estimulado
- Os **dendritos** conectam os neurônios
- A **sinapse** é o ponto de contato entre dendrito e um axônio



# Rede Neural Artificial

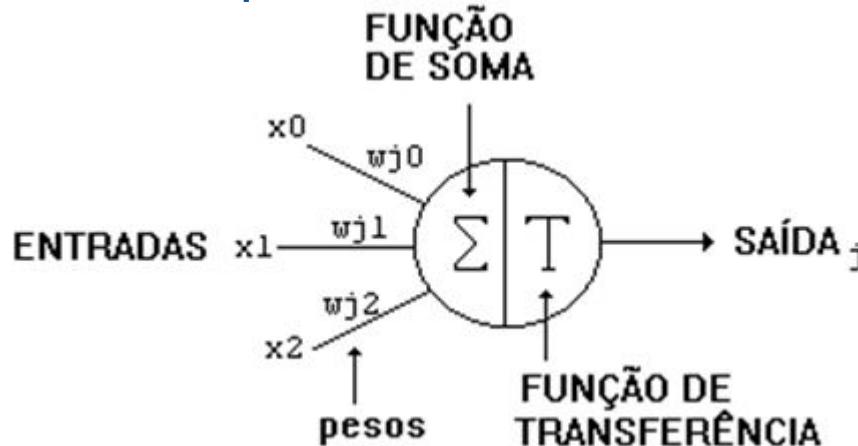
- O cérebro humano consiste principalmente de células nervosas chamadas **neurônios**
- São ligados entre si através de fios de fibra chamados **axônios**
- Estes transmitem os impulsos nervosos quando o neurônio é estimulado
- Os **dendritos** conectam os neurônios
- A **sinapse** é o ponto de contato entre dendrito e um axônio



# Rede Neural Artificial

Baseado no conceito matemático e computacional (1943) que visa descrever o modelo artificial para um neurônio biológico

Responde “ligando/desligando” os vários **neurônios interligados** e com isso classifica as características de entrada no rótulo predito pelo modelo



# Modelos Classificadores

1 – Introdução

2 – Preliminares

3 – Modelagem Descritiva

4 – Técnicas de Validação

5 – Algoritmos

6 – Aplicações



# Aplicações

HEY  
HO  
LET'S  
GO



# In Data Is New Black!

-  **Rafael Roberto Dias**
-  [rafael.dias@madeiramadeira.com.br](mailto:rafael.dias@madeiramadeira.com.br)
-  [rafael-roberto-dias-00b39123](https://www.linkedin.com/in/rafael-roberto-dias-00b39123)
-  **41 99672 7170**